

Лабораторная работа 3. Расчёт зависимости коэффициента липофильности от структуры молекул с помощью линейной регрессии

Отчёт. Оценка модели (2) методички

$$\log P = \beta_0 + \beta_1 x_1 + \dots + \beta_{24} x_{24} + \varepsilon$$

методом наименьших квадратов по выборке `lipo.csv` (82 вещества, 24 структурных дескриптора), доверительные интервалы коэффициентов, проверка условий применимости МНК и сравнение с работой [2].

Код: пакет `lipo_ols` (Python, NumPy/SciPy/Matplotlib). Все числа и рисунки ниже получены одной командой `python -m lipo_ols report` (≈ 5 с) и воспроизводятся до последнего знака. Полные таблицы: [results/tables.md](#), остатки по веществам: [results/residuals.csv](#), все числа: [results/summary.json](#).

Кратко о результатах

- Оценки (пункты 2–6).** $s^2 = 0.591$, $s = 0.769$, $R^2 = 0.838$, скорректированный $\bar{R}^2 = 0.770$. Регрессия в целом значима: $F = 12.28$ при критическом $F_{0.95}(24, 57) = 1.71$, $p = 9 \cdot 10^{-15}$. Но 95%-й доверительный интервал не содержит нуля только у **трёх** из 24 коэффициентов: HBA1, HBA2 и PSA.
- Адекватность.** Как *описание* выборки модель хороша: она объясняет 84 % дисперсии $\log P$. Как *инструмент прогноза* она заметно хуже. На веществах, не участвовавших в оценивании, ошибка равна 0.99 (скользящий контроль) и 1.05 (5-кратная перекрёстная проверка) против $s = 0.77$ на обучающей выборке. Модель переобучена: 25 коэффициентов на 82 наблюдения. Если исключить незначимые регрессоры, остаётся 7. Ошибка прогноза при этом *падает* до 0.85, а F-тест не отвергает гипотезу, что все 17 исключённых коэффициентов равны нулю ($p = 0.27$).
- Вклад регрессоров.** Наибольшие стандартизованные коэффициенты у числа атомов углерода C (+), HBA2 (+), площади полярной поверхности PSA (–), HBA1 (–) и мольной рефракции MR (–). Наименьшие — у RCHO, ROH, HBD, RCOOR, R2NH, RNH2. С теорией согласуется основное: липофильность растёт с неполярным углеродным скелетом и падает с полярностью, галогены повышают её в порядке $F < Cl < Br$, сера даёт больше, чем кислород. Знаки HBA2 (+) и MR (–) противоречат физике. Это следствие мультиколлинеарности (корреляции 0.97–0.99 с HBA1, PSA и C), а не реальный эффект.
- Условия МНК.** Предположения об *ошибках* выполняются: остатки нормальны (Шапиро–Уилк $p = 0.11$), гомоскедастичны (Бройш–Паган $p = 0.36$), нелинейность не обнаружена (RESET $p = 0.45$). Хуже с *матрицей регрессоров*: VIF до 1184, у трёх веществ рычаг $h = 1$ (единственные носители ROPO3, RCHO, RBr), на коэффициент приходится всего 3.3 наблюдения.
- Сравнение с [2].** Все напечатанные в статье статистики моделей MLR-1, MLR-2 и MLR-3 воспроизведены до последнего знака (R^2 , $\bar{R}^2$, RMSE, s , F , p). Наша модель (2) — это MLR-3 из статьи. Значения $\log P$ в файле — **десятичные** логарифмы, как и в статье (у бензола $\log_{10} P = 2.13$), а не натуральные, как сказано в методичке.

1. Выборка (пункт 1)

1.1. Что в файле

82 вещества: 50 содержат сульфонамидную группу (сульфаниламиды, противодиабетические сульфонилмочевины, диуретики, ингибиторы протеазы ВИЧ), остальные — небольшие молекулы с теми же функциональными группами: бензол и его производные, эфиры, тиоэфиры, кетоны, спирты. Отклик $\log P$ лежит в пределах от -1.80 (бринзоламид) до 6.90 (типранавир), среднее 1.56, стандартное отклонение 1.60. Пропусков нет.

Основание логарифма. Методичка называет $\log P$ натуральным логарифмом, но числа в файле — десятичные: $\log P = 2.13$ у бензола и 2.84 у хлорбензола — это общепринятые $\log_{10} P$, натуральные были бы в $\ln 10 \approx 2.3$ раза больше. Разности $\log P(C_6H_5X) - \log P(C_6H_6)$ в файле совпадают с классическими константами гидрофобности Ганча (например, -0.67 для OH, $+0.71$ для Cl). Работа [2] тоже использует десятичный логарифм. Для МНК основание не важно: оно лишь масштабирует y и все b_k . Важно оно для интерпретации: ошибка 1.0 означает ошибку в P в 10 раз, а не в e раз.

Таблица 1. Регрессоры (табл. 1 методички): y скольких веществ регрессор отличен от нуля, диапазон, среднее и корреляция с $\log P$.

#	имя	смысл	≠ 0 у	мин	макс	среднее	$r(x, \log P)$
1	RNH2	первичные аминогруппы	20	0	2	0.26	-0.33
2	R2NH	вторичные аминогруппы	24	0	2	0.35	+0.25
3	R3N	третичные аминогруппы	11	0	2	0.15	+0.39
4	ROPO3	фосфатные группы	1	0	1	0.01	+0.04
5	ROH	гидроксильные группы	11	0	1	0.13	+0.17
6	RCHO	альдегидные группы	1	0	1	0.01	-0.01
7	RCOR	кетонные группы	6	0	2	0.09	-0.05
8	RCOOH	кислотные (карбоксильные) группы	5	0	1	0.06	+0.07
9	RCOOR	сложноэфирные группы	4	0	1	0.05	+0.25
10	ROR	простые эфирные группы	28	0	3	0.46	+0.18
11	RSO2NR	сульфонамидные группы	50	0	2	0.66	+0.17
12	RSR	тиоэфирные группы	10	0	1	0.12	-0.06
13	RF	фторалкильные группы	3	0	3	0.09	+0.37
14	RCI	хлоралкильные группы	10	0	1	0.12	+0.08
15	RBr	бромалкильные группы	1	0	1	0.01	+0.10
16	RSO2R	сульфоновые группы	2	0	1	0.02	-0.00
17	C	атомы углерода	82	2.00	40.00	12.32	+0.71
18	RINGS	циклы (любые)	72	0	7	1.83	+0.59
19	AROMATIC	ароматические кольца	70	0	4	1.51	+0.59
20	HBA1	возможные точки образования водородной связи	76	0.00	18.00	4.98	+0.33
21	HBA2	атомы-акцепторы водородной связи	78	0.00	14.00	4.84	+0.32
22	HBD	атомы-доноры водородной связи	60	0	4	1.46	+0.15
23	PSA	площадь полярной поверхности, Å ²	78	0.00	198.03	81.43	+0.23
24	MR	молярная рефракция, см ³ /моль	82	12.89	211.96	70.50	+0.64




Рисунок 1. Слева — распределение $\log P$. Справа — у скольких веществ регрессор отличен от нуля. ROPO3, RCHO и RBr встречаются по одному разу, RSO2R — дважды.

1.2. Особенности, важные для регрессии

- **Редкие регрессоры.** Фосфатная, альдегидная и бромалкильная группы есть только у одного вещества каждая: фосампренавир, бензальдегид, бромбензол. Коэффициент при таком индикаторе подбирается так, чтобы это единственное вещество было описано *точно*. Его остаток равен нулю при любом $\log P$, а сам коэффициент — просто «поправка на одну точку» (раздел 4.3).
- **Повторы строк X.** Три группы изомеров имеют *одинаковые* значения всех 24 регрессоров, но разные $\log P$ (табл. 4). Например, сульфадимидин (0.89) и сульфизомидин (−0.33) отличаются только взаимным расположением метильных групп и атомов азота в пиримидиновом кольце. Никакая модель вида $\hat{y} = f(x_1, \dots, x_{24})$ не различит такие вещества. Разброс внутри групп — нижняя граница ошибки на этих дескрипторах (раздел 4.1).
- **Сильные корреляции регрессоров** (рис. 2): C и MR ($r = 0.985$), HBA2 и PSA (0.978), HBA1 и HBA2 (0.975), C и RINGS (0.91). Число атомов углерода и молярная рефракция по сути измеряют одно и то же — размер молекулы; HBA1, HBA2 и PSA — её полярность.
- **Неточности кодирования**, оставленные как есть, чтобы результаты были сравнимы с [2]. У тетрагидрофурана и тетрагидротиофена AROMATIC = 1, хотя это насыщенные циклы. Сульфоксиды (ДМСО, дифенилсульфоксид) закодированы как тиоэфиры (RSR = 1). У названий трёх веществ в файле концевые пробелы («Benzoic acid », «Ethanol », «Phenol »); при чтении они удаляются.

Таблица 4. Вещества с одинаковыми значениями всех 24 регрессоров.

вещества	$\log P$	среднее	вклад в SS_{re}
Sulfadimethoxine, Sulfadoxine	1.63, 0.70	1.165	0.4324
Sulfadimidine, Sulfisomidine	0.89, -0.33	0.280	0.7442
Sulfamethoxydiazine, Sulfamethoxypyridazine, Sulfametopyrazine	0.41, 0.32, 0.70	0.477	0.0789




Рисунок 2. Корреляции регрессоров между собой и с $\log P$ (последняя строка). Блок C, RINGS, AROMATIC, HBA1, HBA2, HBD, PSA, MR почти целиком тёмно-красный: эти дескрипторы растут вместе с размером молекулы.

2. Методика (пункты 2–6)

В матричной записи лекции 3 $y = X\beta + \varepsilon$, где X — матрица 82×25 (первый столбец — единицы для β_0), $K = 25$.

Величина	Формула (лекция 3)	Пункт
МНК-оценка	$X^T X b = X^T y$, т. е. $b = (X^T X)^{-1} X^T y = X^+ y$	2
остатки	$e = y - Xb$	3
дисперсия МНК-ошибки, SER	$s^2 = e^T e / (n - K)$, $s = \sqrt{s^2}$	4
коэффициент детерминации	$R^2 = 1 - \langle e^2 \rangle / (\langle y^2 \rangle - \langle y \rangle^2)$	5
стандартная ошибка b_k	$SE(b_k) = \sqrt{s^2 ((X^T X)^{-1})_{kk}}$	6
доверительный интервал	$[b_k - SE(b_k) t_{\alpha}^{n-K}, b_k + SE(b_k) t_{\alpha}^{n-K}]$	6

Доверительная вероятность $\alpha = 0.95$, число степеней свободы $n - K = 57$. Квантиль $t_{0.95}^{57}$ найден двумя способами:

- численным интегрированием плотности Стьюдента в форме лекции 3 (через Γ -функцию) и решением уравнения $\int_{-t}^t \rho_t^{57}(x) dx = 0.95$;
- функцией `scipy.stats.t.ppf`.

Оба дают $t_{0.95}^{57} = 2.002465$, расхождение $7 \cdot 10^{-14}$. Так же получен критический $F_{0.95}(24, 57) = 1.7098$ по формуле плотности Фишера из лекции.

Численная проверка. Нормальные уравнения, QR-разложение и псевдообратная матрица дают одинаковые b (расхождение $2.3 \cdot 10^{-12}$), хотя число обусловленности $X^T X$ велико: $5.9 \cdot 10^6$. Условия ортогональности выполняются: $\max_k |(X^T e)_k| = 4 \cdot 10^{-11}$, в частности сумма остатков равна нулю (в модели есть константа).

```
data = load_lipo()           # 1. выборка
fit = fit_ols_data(data)     # 2. b из нормальных уравнений
fit.residuals                # 3. e = y - Xb
fit.s2, fit.s                 # 4. s^2, s
fit.r2, fit.r2_adj            # 5. R^2, скорректированный R^2
fit.conf_int(0.95)           # 6. интервалы b ± SE · t
```

3. Результаты (пункты 2–6)

3.1. Коэффициенты и доверительные интервалы

В столбце β^* — стандартизованный коэффициент $\beta_k^* = b_k \sigma_{x_k} / \sigma_y$ (раздел 4.2), в столбце ΔR^2 — насколько упадёт R^2 , если убрать регрессор из модели.

Таблица 2. МНК-оценки b_k , стандартные ошибки, t-отношения, p-значения и 95%-е доверительные интервалы (пункты 2 и 6).

коэф.	b	SE(b)	t	p	95%-й интервал	β^*	ΔR^2	≠ 0?
const	0.0756	0.2537	0.30	0.767	[-0.432; 0.584]			нет
RNH2	0.1526	0.4261	0.36	0.722	[-0.701; 1.006]	0.04	0.0004	нет
R2NH	0.0970	0.3801	0.26	0.799	[-0.664; 0.858]	0.04	0.0002	нет
R3N	-0.2417	0.5350	-0.45	0.653	[-1.313; 0.830]	-0.06	0.0006	нет
ROPO3	1.1465	1.2217	0.94	0.352	[-1.300; 3.593]	0.08	0.0025	нет
ROH	0.0536	0.4448	0.12	0.904	[-0.837; 0.944]	0.01	4.1e-5	нет
RCHO	0.0546	0.8166	0.07	0.947	[-1.581; 1.690]	3.8e-3	1.3e-5	нет
RCOR	-0.5381	0.3483	-1.55	0.128	[-1.236; 0.159]	-0.11	0.0068	нет
RCOOH	0.9024	0.4882	1.85	0.070	[-0.075; 1.880]	0.14	0.0097	нет
RCOOR	0.2458	0.7943	0.31	0.758	[-1.345; 1.836]	0.03	0.0003	нет
ROR	-0.2740	0.1853	-1.48	0.145	[-0.645; 0.097]	-0.13	0.0062	нет
RSO2NR	0.4951	0.6962	0.71	0.480	[-0.899; 1.889]	0.18	0.0014	нет
RSR	1.3211	0.7827	1.69	0.097	[-0.246; 2.888]	0.27	0.0081	нет
RF	0.3831	0.2597	1.48	0.146	[-0.137; 0.903]	0.11	0.0062	нет
RCL	0.9564	0.5042	1.90	0.063	[-0.053; 1.966]	0.20	0.0102	нет
RBr	1.7566	0.9593	1.83	0.072	[-0.165; 3.678]	0.12	0.0095	нет
RSO2R	0.6558	0.8486	0.77	0.443	[-1.044; 2.355]	0.06	0.0017	нет
C	0.4278	0.2754	1.55	0.126	[-0.124; 0.979]	2.26	0.0069	нет
RINGS	-0.4145	0.2994	-1.38	0.172	[-1.014; 0.185]	-0.33	0.0054	нет
AROMATIC	0.2204	0.2867	0.77	0.445	[-0.354; 0.794]	0.13	0.0017	нет
HBA1	-0.4321	0.1853	-2.33	0.023	[-0.803; -0.061]	-1.07	0.0155	да
HBA2	1.0234	0.3856	2.65	0.010	[0.251; 1.796]	2.16	0.0200	да
HBD	0.0374	0.4596	0.08	0.935	[-0.883; 0.958]	0.03	1.9e-5	нет
PSA	-0.0533	0.0211	-2.52	0.014	[-0.096; -0.011]	-1.74	0.0181	да
MR	-0.0356	0.0648	-0.55	0.585	[-0.165; 0.094]	-1.01	0.0009	нет




Рисунок 3. Стандартизованные коэффициенты и их 95%-е доверительные интервалы. Синим — интервалы, не содержащие ноль. Самые широкие интервалы у C и MR: из-за корреляции $r = 0.985$ модель не может разделить их вклады.

3.2. Остатки, s^2 , s , R^2

Величина	Значение
сумма квадратов остатков $SSR = e^T e$	33.685
дисперсия МНК-ошибки $s^2 = SSR/57$ (пункт 4)	0.5910
стандартная ошибка регрессии s (пункт 4)	0.7687
ML-оценка $\hat{\sigma}^2 = SSR/n = \frac{n-K}{n} s^2$ (смещённая)	0.4108
RMSE на обучающей выборке $\sqrt{SSR/n}$	0.641
средний модуль остатка	0.502
коэффициент детерминации R^2 (пункт 5)	0.8380
скорректированный $\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-K}$	0.7698
нецентрированный $R_{ис}^2 = 1 - e^T e / y^T y$	0.9173
F для гипотезы $\beta_1 = \dots = \beta_{24} = 0$	12.28 ($p = 9.0 \cdot 10^{-15}$)

Остатки всех 82 веществ (пункт 3) приведены в приложении (табл. П1) и в файле [results/residuals.csv](#). Наибольшие по модулю остатки — у бринзоламида (−1.97), ДМСО (−1.54), этоксзоламида (+1.45), апри-коксиба (−1.39) и гликопирамида (−1.31). У бензальдегида, бромбензола и фосампренавира остаток равен нулю *по построению* (рычаг $h = 1$, раздел 4.3).




Рисунок 4. Синие точки — подгонка по всей выборке. Оранжевые — прогноз того же вещества моделью, оценённой без него (скользящий контроль). Расхождение синих и оранжевых точек показывает, насколько модель «подстраивается» под конкретные вещества.

4. Обсуждение (пункт 7)

4.1. Адекватно ли использование линейной модели?

В целом регрессия значима. F-тест лекции 3 с матрицей $R = [0 \mid I_{24}]$, $r = 0$ даёт $F = 12.28 \gg F_{0.95}(24, 57) = 1.71$. Гипотеза « $\log P$ не зависит от дескрипторов» отвергается с огромным запасом. $R^2 = 0.84$: модель объясняет 84 % разброса $\log P$. Ошибка модели $s = 0.77$ вдвое меньше разброса самого $\log P$ ($\sigma_y = 1.60$).

Но на новых веществах модель работает заметно хуже. R^2 на обучающей выборке растёт с каждым добавленным регрессором, поэтому качество проверено на веществах, не участвовавших в оценивании:

Модель	k	s (обучение)	RMSE скользящего контроля	Q^2	RMSE 5-кратной проверки
(2), все регрессоры	24	0.769	0.986	0.62	1.050 ± 0.066
после исключения незначимых	7	0.789	0.841	0.72	0.853 ± 0.027
только среднее $\bar{y}$	0	1.602	—	0	—

(5-кратная проверка — среднее и стандартное отклонение по 200 случайным разбиениям; $Q^2 = 1 - PRESS/TSS$.)

Ошибка прогноза полной модели в 1.3–1.4 раза больше, чем ошибка на обучающей выборке. Это признак переобучения: на 82 наблюдения приходится 25 коэффициентов (3.3 наблюдения на коэффициент вместо обычно рекомендуемых хотя бы 10). Часть коэффициентов описывает не закономерность, а шум конкретной выборки.

Пошаговое исключение. На каждом шаге убирался регрессор с наибольшим p -значением t -теста, пока все оставшиеся не стали значимы на уровне 0.05 (табл. 6, рис. 5). Первыми ушли RCHO ($p = 0.95$), HBD, ROH, RNH₂, R₂NH и MR. При исключении первых 10 регрессоров R^2 почти не меняется ($0.838 \rightarrow 0.833$), а ошибка прогноза падает с 1.05 до 0.86. Итоговая модель с 7 регрессорами хуже описывает выборку ($R^2 = 0.778$), но лучше предсказывает (RMSE 0.85). Совместный F-тест гипотезы «все 17 исключённых коэффициентов равны нулю» в *полной* модели даёт $F = 1.23$ при $F_{0.95}(17, 57) = 1.81$, $p = 0.27$: данные этой гипотезе не противоречат.

Таблица 6. Пошаговое исключение регрессоров: на каждом шаге убирается регрессор с наибольшим p -значением.

k	исключён	ero p	R^2	R^2_{adj}	s	RMSE LOO	RMSE 5-fold	BIC
24	—		0.838	0.770	0.769	0.986	1.050	274.3
23	RCHO	0.947	0.838	0.774	0.762	0.983	1.046	269.9
22	HBD	0.943	0.838	0.778	0.756	0.965	1.019	265.5
21	ROH	0.845	0.838	0.781	0.750	0.945	0.995	261.2
20	RNH ₂	0.699	0.837	0.784	0.744	0.931	0.978	257.0
19	R ₂ NH	0.775	0.837	0.787	0.739	0.910	0.957	252.7
18	MR	0.621	0.837	0.790	0.734	0.880	0.921	248.6
17	RSO ₂ NR	0.727	0.836	0.793	0.729	0.857	0.895	244.4
16	RSO ₂ R	0.582	0.835	0.795	0.725	0.854	0.889	240.3
15	RCOOR	0.574	0.835	0.797	0.722	0.845	0.875	236.3
14	AROMATIC	0.414	0.833	0.798	0.720	0.830	0.856	232.8
13	ROPO ₃	0.232	0.829	0.797	0.722	0.828	0.853	230.1
12	RF	0.087	0.822	0.791	0.733	0.834	0.855	229.3
11	RINGS	0.081	0.814	0.784	0.744	0.830	0.848	228.5
10	RB ₂	0.087	0.806	0.778	0.754	0.830	0.848	227.6
9	RCL	0.078	0.797	0.772	0.766	0.833	0.850	226.8
8	RCOOH	0.086	0.788	0.765	0.776	0.842	0.857	225.7
7	RSR	0.068	0.778	0.757	0.789	0.841	0.853	225.1




Рисунок 5. (а) R^2 монотонно падает при исключении регрессоров, а скорректированный $\bar{R}^2$ максимален при 14 регрессорах. (б) Ошибка на обучающей выборке (s) и на контроле. Контрольная ошибка падает, пока из модели уходят лишние регрессоры, и выходит на плато около 0.85 при 7–14 регрессорах.

Таблица 7. Модель после исключения: 7 регрессоров, все значимы на уровне 0.05.

коэф.	b	SE(b)	t	p	95%-й интервал
const	0.1490	0.2075	0.72	0.475	[-0.264; 0.562]
R3N	-0.7988	0.2899	-2.76	0.007	[-1.377; -0.221]
RCOR	-0.7747	0.2818	-2.75	0.007	[-1.336; -0.213]
ROR	-0.3353	0.1547	-2.17	0.033	[-0.644; -0.027]
C	0.2859	0.0231	12.35	< 0.001	[0.240; 0.332]
HBA1	-0.4925	0.1108	-4.44	< 0.001	[-0.713; -0.272]
HBA2	0.6390	0.2493	2.56	0.012	[0.142; 1.136]
PSA	-0.0297	0.0110	-2.69	0.009	[-0.052; -0.008]

Нижняя граница ошибки. Три группы изомеров с одинаковыми X (табл. 4) дают «чистую ошибку» $SS_{pe} = 1.256$ при 4 степенях свободы, $\sigma_{pe} = 0.56$. Это ошибка, которую никакая функция от этих 24 дескрипторов не устранил: часть различий в липофильности зависит от расположения групп, а дескрипторы его не видят. Тест на неадекватность сравнивает остальную часть остатков с чистой ошибкой: $F = (32.43/53)/(1.256/4) = 1.95$, $p = 0.27$. Систематическая неадекватность не обнаружена, но мощность теста мала (всего 4 степени свободы чистой ошибки).

Вывод. Линейная модель адекватна как описание: связь значима, предпосылки об ошибках выполнены (раздел 4.3), систематической нелинейности нет. Для прогноза $\log P$ новых веществ она пригодна с оговорками. Ошибка около 1 единицы $\log P$ означает ошибку в коэффициенте распределения P примерно в 10 раз. Модель с 7 регрессорами предсказывает лучше полной. Область применимости — вещества, похожие на обучающие (сульфонамиды и простые органические молекулы). Для групп, представленных одним-двумя веществами (Br, CHO, фосфат, сульфон), коэффициенты фактически не оценены.

4.2. Какие регрессоры вносят наибольший и наименьший вклад?

Сами b_k сравнивать нельзя: регрессоры измерены в разных единицах. Коэффициент при PSA (-0.053 на $\text{\AA}^2$) мал лишь потому, что PSA меняется от 0 до 198 $\text{\AA}^2$. Поэтому использовались:

- **стандартизованный коэффициент** $\beta_k^* = b_k \sigma_{x_k} / \sigma_y$: на сколько стандартных отклонений изменится $\log P$, если x_k увеличить на одно своё стандартное отклонение при прочих равных (рис. 3, табл. 2);
- **вклад при исключении** $\Delta R_k^2 = t_k^2(1 - R^2)/(n - K)$: какую долю дисперсии объясняет *только* этот регрессор сверх остальных;
- **парная корреляция** $r(x_k, \log P)$ (табл. 1);
- **пары молекул**: прогноз изменения $\log P$ при замене одной группы против эксперимента (табл. 8, рис. 6).

Наибольший вклад по $|\beta^*|$: C (+2.26), HBA2 (+2.16), PSA (-1.74), HBA1 (-1.07), MR (-1.01). По ΔR^2 впереди три значимых регрессора: HBA2 (0.020), PSA (0.018), HBA1 (0.015). По парной корреляции сильнее всего с $\log P$ связаны C ($r = 0.71$), MR (0.64), RINGS и AROMATIC (0.59).

Наименьший вклад: RCHO ($\beta^* = 0.004$), ROH (0.011), HBD (0.025), RCOOR (0.033), R2NH (0.036), RNH2 (0.044). Все они незначимы, и именно они первыми ушли при пошаговом исключении.

Согласуется ли это с теорией? Липофильность определяется балансом двух эффектов. Неполлярная поверхность молекулы (углеводородный скелет) нарушает структуру воды, и вещество выталкивается в октанол (гидрофобный эффект). Полярные группы, образующие водородные связи с водой, удерживают вещество в воде. Отсюда ожидания и проверка:

Ожидание	Результат модели	Согласие
$\log P$ растёт с числом атомов C	$b_C = +0.43$ на атом, самая сильная парная корреляция ($r = 0.71$)	да
$\log P$ падает с полярной поверхностью	$b_{PSA} = -0.053$ на $\text{\AA}^2$, значим	да
водородные связи понижают $\log P$	HBA1 -0.43 (значим), HBA2 +1.02 (значим!) , HBD ≈ 0	частично
галогены повышают $\log P$, $F < Cl < Br$	RF +0.38, RCl +0.96, RBr +1.76; H→Cl: модель +0.78, эксперимент +0.71	да
сера липофильнее кислорода	RSR +1.32; O→S в эфирах: модель +0.51, эксперимент +1.06 и +1.15	качественно да
замыкание цикла уменьшает поверхность	RINGS -0.41	да
поляризуемость (MR) повышает $\log P$	$b_{MR} = -0.036$, хотя $r(MR, \log P) = +0.64$	нет
карбоксильная группа понижает $\log P$	RCOOH +0.90; H→COOH: модель +0.32, эксперимент -0.26	нет

Противоречия объясняются **мультиколлинеарностью**. HBA2 коррелирует с HBA1 ($r = 0.975$) и с PSA (0.978), а MR — с C (0.985). Модель «делит» общий эффект полярности (или размера) между почти одинаковыми регрессорами, и отдельные коэффициенты получают компенсирующие друг друга знаки. Осмысленна только их сумма для реального изменения структуры. Например, добавление группы CH_2 увеличивает C на 1 и MR примерно на $4.65 \text{ см}^3/\text{моль}$, так что модель предсказывает $\Delta \log P = 0.428 - 0.036 \cdot 4.65 \approx +0.26$. Знак верный, но величина вдвое меньше классической гидрофобной константы метиленовой группы (около 0.5 по Ганчу и Лео). В выборке большие молекулы одновременно и более полярные (сульфонамидные лекарства), и разделить «размер» и «полярность» по 82 веществам трудно. Положительный RCOOH — та же история: полярность кислоты уже учтена через PSA, HBA и HBD, а индикатор играет роль поправки, оценённой по 5 веществам.




Рисунок 6. Изменение $\log P$ при замене одной группы: эксперимент (серый), модель (2) (синий) и модель с 7 регрессорами (оранжевый). « $h = 1$ » — одно из веществ пары подогнано точно, и совпадение там ничего не доказывает.

Таблица 8. Пары молекул: экспериментальная и предсказанная разности $\log P$; * — одно из веществ по-
догнано точно ($h = 1$).

замена	производное	Δ эксп.	Δ модель (2)	Δ модель 7	слагаемые Δ модели (2)
H $\rightarrow$ F	Fluorobenzene	0.14	0.38	0.00	RF +0.38, MR +0.00
H $\rightarrow$ Cl	Chlorobenzene	0.71	0.78	0.00	RCl +0.96, MR -0.18
H $\rightarrow$ Br	Bromobenzene	0.86	1.48 *	0.00	RBr +1.76, MR -0.27
H $\rightarrow$ OH	Phenol	-0.67	-0.47	-0.45	PSA -1.08, HBA2 +1.02, HBA1 -0.43, MR -0.07, ROH +0.05, HBD +0.04
H $\rightarrow$ NH ₂	Aniline	-1.23	-0.76	-0.63	PSA -1.39, HBA2 +1.02, HBA1 -0.43, MR -0.16, RNH2 +0.15, HBD +0.04
H $\rightarrow$ OCH ₃	Anisole	-0.02	0.02	-0.18	HBA2 +1.02, PSA -0.49, HBA1 -0.43, C +0.43, ROR -0.27, MR -0.23
H $\rightarrow$ CHO	Benzaldehyde	-0.65	-0.03 *	-0.07	HBA2 +1.02, PSA -0.91, HBA1 -0.43, C +0.43, MR -0.19, RCHO +0.05
H $\rightarrow$ COCH ₃	Acetophenone	-0.55	-0.36	-0.56	HBA2 +1.02, PSA -0.91, C +0.86, RCOR -0.54, HBA1 -0.43, MR -0.36
H $\rightarrow$ COOH	Benzoic acid	-0.26	0.32	-0.53	HBA2 +2.05, PSA -1.99, RCOOH +0.90, HBA1 -0.86, C +0.43, MR -0.25, HBD +0.04
O $\rightarrow$ S (эфир)	Diethyl thioether	1.06	0.51	-0.14	RSR +1.32, PSA -0.86, ROR +0.27, MR -0.23
O $\rightarrow$ S (цикл)	Tetrahydrothiophene	1.15	0.51	-0.14	RSR +1.32, PSA -0.86, ROR +0.27, MR -0.23
O $\rightarrow$ S (аромат.)	Thiophene	0.47	0.59	-0.11	RSR +1.32, PSA -0.80, ROR +0.27, MR -0.20
OH $\rightarrow$ NH ₂	Ethylamine	0.18	-0.26	-0.17	PSA -0.31, RNH2 +0.15, MR -0.05, ROH -0.05

Полная модель правильно передаёт знак и порядок величины эффектов OH, NH₂, COCH₃, Cl, F и O $\rightarrow$ S и почти нулевой эффект OCH₃, но ошибается со знаком для COOH и OH $\rightarrow$ NH₂. Модель с 7 регрессорами хорошо предсказывает эффект кетонной группы (–0.56 против –0.55). При этом она вообще «не знает» о галогенах: RF, RCl и RBr были исключены как незначимые, и её прогноз для замены H $\rightarrow$ Cl равен нулю. Статистическая незначимость здесь означает недостаток данных (галогены есть у 3, 10 и 1 вещества), а не отсутствие эффекта. Химически вклад галогенов хорошо известен.

4.3. Верны ли для выборки условия применимости МНК?

Лекция 3 перечисляет предположения классической линейной модели. Для t-статистик и доверительных интервалов нужна ещё нормальность ошибок.

Условие	Как проверено	Результат	Вывод
линейность	тест Рамсея (RESET): добавить в модель $\hat{y}^2, \hat{y}^3$	$F = 0.80, p = 0.45$; на рис. 7а остатки без тренда	выполнено
строгая экзогенность $\langle \varepsilon X \rangle = 0$	прямо не проверяется: $X^T e = 0$ по построению МНК	изомеры с одинаковыми X различаются по $\log P$ на величину до 1.2	сомнительно (раздел ниже)
отсутствие мультиколлинеарности	ранг X , VIF, число обусловленности	ранг полный (25); VIF до 1184 (табл. 3); $\kappa = 275$ после нормировки столбцов при пороге 30	формально выполнено, фактически сильная мультиколлинеарность
гомоскедастичность	тест Бройша–Пагана (Кёнкера)	$LM = 25.8, \chi^2_{24}, p = 0.36$	выполнено
нет корреляции наблюдений	смысл данных; Дарбин–Уотсон	наблюдения — разные вещества, $DW = 2.08$	выполнено (с оговоркой)
нормальность ошибок	Шапиро–Уилк, Харке–Бера, Q-Q (рис. 7б)	$W = 0.975, p = 0.11$; $JB = 4.40, p = 0.11$; асимметрия -0.53	выполнено
нет точек, определяющих модель	рычаги, расстояние Кука (рис. 7г)	3 точки с $h = 1$; $\max D = 0.27 < 1$ (бринзоламид)	частично
$n \gg K$	число наблюдений на коэффициент	$82/25 = 3.3$	нет

Таблица 3. Коэффициенты увеличения дисперсии $VIF_j = 1/(1 - R_j^2)$.

регрессор	VIF	регрессор	VIF
MR	1183.8	RNH2	5.4
C	746.6	RCOOR	4.1
HBA2	232.7	RC1	3.8
PSA	167.3	ROH	3.2
HBA1	74.2	ROR	2.6
HBD	34.4	ROP03	2.5
RSO2NR	21.7	RSO2R	2.4
RINGS	20.6	RF	2.1
AROMATIC	9.8	RCOOH	1.9
RSR	9.1	RCOR	1.7
R2NH	7.0	RBr	1.5
R3N	5.9	RCHO	1.1




Рисунок 7. (а) Остатки против прогноза: тренда и «воронки» нет. (б) Q-Q график: точки на прямой, кроме бринзоламида внизу слева. (в) Гистограмма остатков и плотность $N(0, s^2)$. (г) Рычаги и студентизированные остатки, серые кривые — уровни расстояния Кука.

Комментарии к пунктам таблицы.

- **Мультиколлинеарность** не смещает оценки и не мешает прогнозу, но раздувает дисперсии отдельных коэффициентов. Дисперсия b_{MR} в 1184 раза больше, чем была бы при регрессоре, некоррелированном с остальными. Отсюда классический симптом: регрессия в целом высоко значима ($p = 10^{-14}$), а из 24 отдельных коэффициентов значимы только 3. Отсюда же неустойчивые и «нефизические» знаки (раздел 4.2).
- **Рычаги** $h = 1$. Фосампренавир, бензальдегид и бромбензол — единственные носители ROP3, RCHO и RBr. Для них $h_{ii} = 1$: проектор $P = X(X^T X)^{-1} X^T$ переводит y_i в $\hat{y}_i = y_i$, и остаток равен нулю при любом наблюдаемом значении. Эти три вещества ничего не говорят об остальных коэффициентах. Их коэффициенты (и их стандартные ошибки) опираются на одну точку и не имеют смысла как «вклад группы». Ещё 5 веществ имеют большой рычаг $h > 2K/n = 0.61$ (типранавир 0.67, делавирдин, целекоксиб, дапсон, дифенилсульфон). Но ни одно наблюдение не влияет на модель чрезмерно: максимальное расстояние Кука 0.27 у бринзоламида.
- **Строгая экзогенность** требует, чтобы ошибка не зависела от регрессоров. Её нарушают пропущенные переменные, коррелирующие с включёнными. Повторы строк X показывают, что такие факторы есть: положение заместителей, внутримолекулярные водородные связи, ионизация. Кислоты и основания в воде частично ионизованы, и измеряемая величина ближе к $\log D$, чем к $\log P$. Если эти факторы связаны, например, с RSO2NR или PSA, коэффициенты при них смещены. Кроме того, экспериментальные значения собраны авторами [2] из разных источников и могут иметь разную точность.
- **Некоррелированность наблюдений**. Выборка не временной ряд, порядок строк алфавитный, поэтому $DW = 2.08$ ожидаем и мало что доказывает. Возможная корреляция другая: близкие по строению вещества (серии сульфаниламидов) могут иметь сходные ошибки, а выборка не случайна из какой-то генеральной совокупности, а подобрана авторами.

Вывод. Предположения об ошибках (линейность, гомоскедастичность, нормальность, независимость) выполняются, поэтому t -интервалы и F -тесты формально корректны. Слабое место — матрица регрессоров: сильная мультиколлинеарность, точно подогнанные индикаторы и малое число наблюдений на коэффициент. Это не смещает b , но делает отдельные коэффициенты ненадёжными и ухудшает прогноз (раздел 4.1).

4.4. Сходятся ли результаты с работой [2]?

Авторы [2] построили на тех же 82 веществах три вложенные модели: MLR-1 (регрессоры 1–19), MLR-2 (+ HBA1, HBA2, HBD) и MLR-3 (все 24). Наша модель (2) совпадает с MLR-3.

Таблица 5. Наш расчёт / числа из статьи [2] для трёх вложенных моделей и ошибка прогноза на контроле.

модель	k	R^2	R^2_{adj}	RMSE	s	F	p(F)	RMSE LOO	RMSE 5-fold
MLR-1	19	0.794 / 0.79	0.731 / 0.73	0.722 / 0.72	0.831 / 0.83	12.60 / 12.6	1.02e-14 / 1.02e-14	0.962	0.999
MLR-2	22	0.819 / 0.82	0.752 / 0.75	0.677 / 0.68	0.798 / 0.80	12.16 / 12.2	1.30e-14 / 1.30e-14	0.950	1.002
MLR-3	24	0.838 / 0.84	0.770 / 0.77	0.641 / 0.64	0.769 / 0.77	12.28 / 12.3	9.00e-15 / 9.00e-15	0.986	1.050

Все статистики, напечатанные в статье, совпадают с нашими при округлении до того же числа знаков: R^2 , $\bar{R}^2$, RMSE, s, F, p-значение. Это верно для всех трёх моделей. Совпадают и коэффициенты детерминации парных регрессий, приведённые в тексте статьи: C — 0.50, MR — 0.41, AROMATIC — 0.34, HBA1 — 0.11, HBA2 — 0.10. Таблица коэффициентов MLR-3 вынесена в приложение к статье (Table S3), но сравнивать её нет необходимости. При полном ранге X МНК-решение единственно, а совпадение R^2 , s и F до третьего знака на тех же данных означает ту же модель.

Дополнительно к статье:

- **Нужны ли HBA1, HBA2, HBD, PSA, MR?** F-тест гипотезы, что их коэффициенты в MLR-3 равны нулю, даёт $F = 3.07$ при $F_{0.95}(5, 57) = 2.38$, $p = 0.016$: вместе они значимы. Переход MLR-2 → MLR-3 (PSA и MR) значим на грани: $F = 3.29$ при критическом 3.16, $p = 0.044$.
- **Прогноз.** Авторы оценивали MLR-3 на 5 отложенных сульфонидах (RMSE 0.20) и на 22 N-ацилсульфонидах конкурса SAMPL7 (RMSE 0.58, лучший результат среди эмпирических методов). Наша перекрёстная проверка даёт заметно большую ошибку, 1.05. Противоречия здесь нет. Тестовые вещества статьи — сульфонидами, похожие на обучающие, а при перекрёстной проверке в контрольную часть попадают и «уникальные» вещества (единственные носители групп, типранавир, бринзоламид), на которых модель экстраполирует. Это ещё раз показывает узкую область применимости модели.
- **Основание логарифма.** Статья использует десятичный $\log P$, как и файл с данными. Слова методички о натуральном логарифме не соответствуют числам.

5. Выводы

1. МНК-оценки модели (2) получены по нормальным уравнениям и проверены QR-разложением и псевдообратной матрицей. $s^2 = 0.591$, $s = 0.769$, $R^2 = 0.838$ ($\bar{R}^2 = 0.770$). Доверительные интервалы построены по t -статистике с квантилем $t_{0.95}^{57} = 2.0025$, найденным по формуле плотности Стьюдента из лекции.
2. Регрессия в целом высоко значима, но по отдельности значимы лишь HBA1, HBA2 и PSA. Причина — сильная мультиколлинеарность ($C \approx MR$, $HBA1 \approx HBA2 \approx PSA$) и три точно подогнанных индикатора.
3. Модель адекватно описывает выборку, но переобучена. Ошибка прогноза (≈ 1.0) больше ошибки на обучении (0.77). Модель с 7 регрессорами предсказывает лучше (≈ 0.85) и не хуже согласуется с данными по F-тесту.

4. Главные факторы липофильности в модели — размер углеродного скелета (+) и полярность (–). Это согласуется с представлением о гидрофобном эффекте. Знаки галогенов, серы и замыкания цикла тоже верны. Знаки HBA2, MR и RCOOH — артефакты коллинеарности.
5. Предпосылки об ошибках (нормальность, гомоскедастичность, линейность) выполнены; условия на матрицу регрессоров — лишь формально.
6. Результаты полностью воспроизводят модели MLR-1, MLR-2 и MLR-3 работы [2].

Список литературы

1. ГОСТ 32291-2013. Методы испытаний химической продукции, представляющей опасность для окружающей среды. Определение коэффициента распределения н-октанол/вода методом медленного перемешивания.
2. K. López, S. Pinheiro, W. J. Zamora. Multiple linear regression models for predicting the n-octanol/water partition coefficients in the SAMPL7 blind challenge // J. Comput.-Aided Mol. Des. 2021. V. 35. P. 923–931. doi:10.1007/s10822-021-00409-2.
3. Е. П. Андреева, О. А. Раевский. Расчёт липофильности органических соединений на основе структурного сходства и молекулярных физико-химических дескрипторов // Хим.-фарм. журнал. 2009. Т. 43, № 5. С. 28–32.
4. C. Hansch, A. Leo. Substituent Constants for Correlation Analysis in Chemistry and Biology. New York: Wiley, 1979.
5. Лекция 3 «Классическая линейная модель регрессии», курс «Нейронные сети глубокого обучения».

Приложение. МНК-остатки по веществам (пункт 3)

$e_i = y_i - \hat{y}_i$; h — рычаг (диагональ матрицы-проектора).

Таблица П1. Экспериментальные значения, прогноз модели (2), остатки и рычаги.

вещество	logP	$\hat{y}$	e	h
Acetamide	-1.26	-0.67	-0.595	0.38
Acetanilide	1.16	1.62	-0.460	0.14
Acetazolamide	-0.26	-0.95	0.685	0.43
Acetic acid	-0.17	0.59	-0.756	0.27
Acetohexamide	2.44	1.25	1.186	0.28
Acetone	-0.24	-0.09	-0.147	0.15
Acetophenone	1.58	1.14	0.436	0.13
Amprenavir	2.20	2.69	-0.486	0.45
Aniline	0.90	0.75	0.154	0.12
Anisole	2.11	1.53	0.580	0.08
Apricoxib	1.73	3.12	-1.386	0.34
Benzaldehyde	1.48	1.48	0 (h = 1)	1.00
Benzene	2.13	1.51	0.623	0.10
Benzoic acid	1.87	1.82	0.047	0.24
Benzophenone	3.18	2.39	0.791	0.23
Benzothiazole	2.01	2.02	-0.007	0.21
Bosentan	3.70	3.79	-0.093	0.45
Brinzolamide	-1.80	0.17	-1.974	0.39
Bromobenzene	2.99	2.99	0 (h = 1)	1.00
Bumetanide	2.60	2.29	0.307	0.38
Butanedione	-1.34	-0.70	-0.641	0.53
Carbutamide	1.01	0.68	0.329	0.15
Celecoxib	3.53	4.03	-0.504	0.62
Chlorobenzene	2.84	2.29	0.554	0.23
Chlorpropamide	2.27	1.96	0.306	0.22
Chlorthalidone	0.85	1.29	-0.444	0.30
Dapsone	0.97	0.79	0.177	0.62
Darunavir	1.89	1.78	0.107	0.53
Delavirdine	2.80	2.43	0.375	0.63
Diethyl ether	0.89	0.81	0.076	0.14
Diethyl thioether	1.95	1.32	0.628	0.19
Dioxane	-0.27	0.26	-0.532	0.26
Diphenyl sulfone	2.14	2.32	-0.177	0.62
Diphenyl sulfoxide	2.06	2.75	-0.688	0.27
DMSO	-1.34	0.20	-1.539	0.21
Dofetilide	2.10	2.49	-0.388	0.40
Dronedarone	4.63	5.62	-0.985	0.47
Ethanol	-0.31	0.08	-0.387	0.19
Ethanolamine	-1.31	-0.62	-0.686	0.26
Ethoxzolamide	2.01	0.56	1.450	0.20
Ethylamine	-0.13	-0.19	0.057	0.12
Fluorobenzene	2.27	1.89	0.378	0.14
Fosamprenavir	2.20	2.20	0 (h = 1)	1.00
Furan	1.34	0.98	0.364	0.12
Glimepiride	3.50	2.73	0.775	0.30
Glipizide	1.91	2.90	-0.987	0.31

вещество	logP	$\hat{y}$	e	h
Gliquidone	4.50	3.87	0.632	0.37
Glyburide	3.75	4.34	-0.582	0.36
Glycopyramide	0.87	2.18	-1.314	0.37
Hydrochlorothiazide	-0.07	-0.85	0.777	0.39
Ibutilide	4.60	3.65	0.945	0.41
Indapamide	2.20	2.44	-0.239	0.31
Mefruside	1.54	1.23	0.314	0.43
Metolazone	2.50	2.13	0.371	0.24
Oxetane	-0.14	0.22	-0.358	0.19
Paritaprevir	3.10	3.91	-0.811	0.51
Phenol	1.46	1.04	0.420	0.19
Probenecid	3.21	2.80	0.413	0.42
Simeprevir	5.16	4.37	0.794	0.48
Sulfacetamide	-0.96	-0.06	-0.900	0.12
Sulfadiazine	-0.09	0.31	-0.399	0.09
Sulfadimethoxine	1.63	0.35	1.277	0.14
Sulfadimidine	0.89	0.81	0.079	0.10
Sulfadoxine	0.70	0.35	0.347	0.14
Sulfamethoxazole	0.89	0.75	0.143	0.12
Sulfamethoxydiazine	0.41	0.33	0.079	0.08
Sulfamethoxypyridazine	0.32	0.33	-0.011	0.08
Sulfametopyrazine	0.70	0.33	0.369	0.08
Sulfamoxole	0.68	0.72	-0.044	0.11
Sulfanilamide	-0.62	-0.99	0.371	0.20
Sulfasalazine	2.50	2.51	-0.012	0.39
Sulfisomidine	-0.33	0.81	-1.141	0.10
Sumatriptan	0.93	1.63	-0.695	0.21
Tamsulosin	2.30	2.18	0.124	0.42
Tetrahydrothiophene	1.61	1.20	0.407	0.17
THF	0.46	0.70	-0.235	0.10
Thiophene	1.81	1.57	0.243	0.18
Tipranavir	6.90	6.52	0.378	0.67
Tolazamide	2.69	2.17	0.522	0.34
Tolbutamide	2.34	1.69	0.646	0.14
Xipamide	2.19	1.93	0.256	0.29
Zonisamide	0.50	0.19	0.309	0.28