

Лабораторная работа 4. Расчёт зависимости коэффициента липофильности от структуры молекул с помощью двухслойного перцептрона

Сукин Иван Андреевич

1 Теоретическая часть

1.1 Коэффициент липофильности

Липофильностью вещества называется его сродство к жирам. Условно принято считать, что чем выше липофильность некоторого вещества, тем больше его способность проникать сквозь клеточные мембраны, поэтому определение уровня липофильности имеет большое значение в экологии, токсикологии и медицине.

Классическим экспериментальным методом определения липофильности является измерение коэффициента распределения тестируемого вещества между водой и *n*-октанолом — липофильным растворителем. Эта величина P равна отношению равновесных концентраций тестируемого вещества, соответственно, в *n*-октаноле и воде:

$$P = \frac{C_{oct}}{C_{water}}. \quad (1)$$

На практике же чаще пользуются величиной $\log P$, где логарифм подразумевается натуральным [1]. В дальнейшем будем называть эту величину *коэффициентом липофильности*.

1.2 Зависимость липофильности от структуры молекул

В соответствии с представлением о функциональных группах обычно предполагают, что свойства вещества зависят от наличия этих групп в

молекуле и их количества. Также важными являются хиральные и оптические свойства молекул, а также их полярность. В работе [2] выделено 24 основных переменных, которые, как считают авторы, влияют на липофильность молекул (см. табл. 1).

#	Переменная	Физический смысл
1	RNH ₂	Количество первичных аминогрупп
2	R ₂ NH	Количество вторичных аминогрупп
3	R ₃ N	Количество третичных аминогрупп
4	ROPO ₃	Количество фосфатных групп
5	ROH	Количество гидроксильных групп
6	RCHO	Количество альдегидных групп
7	RCOR	Количество кетонных групп
8	RCOOH	Количество кислотных групп
9	RCOOR	Количество сложных эфирных групп
10	ROR	Количество простых эфирных групп
11	RSO ₂ NR	Количество сульфонамидных групп
12	RSR	Количество тиоэфирных групп
13	RF	Количество фторалкильных групп
14	RCI	Количество хлоралкильных групп
15	RBr	Количество бромалкильных групп
16	RSO ₂ R	Количество сульфоновых групп
17	C	Количество атомов углерода
18	RINGS	Количество циклов (любых)
19	AROMATIC	Количество бензольных колец
20	HBA1	Количество возможных точек образования водородной связи
21	HBA2	Количество атомов-акцепторов водородной связи

22	HBD	Количество атомов-доноров водородной связи
23	PSA	Суммарная площадь полярных атомов, Å ²
24	MR	Мольная рефракция, см ³ /моль

Таблица 1: Основные переменные, влияющие на липофильность молекул по [2].

Если обозначить каждую из этих переменных x_i в соответствии с её порядковым номером, то можно построить модель двухслойного перцептрона:

$$\log P = b_1^2 + (\mathbf{w}^2)^T \text{relu}(\mathbf{w}^1 \mathbf{x} + \mathbf{b}^1). \quad (2)$$

2 Задание

1. Изучите файл `lipo.csv`, содержащий данные о выборке по значениям регрессоров и коэффициента липофильности для различных веществ
2. Составьте несколько моделей двухслойного перцептрона с различным числом нейронов на скрытом слое: 2, 4, 8, 16, 32
3. Зафиксируйте скорость обучения ε и точность δ
4. С помощью метода градиентного спуска найдите оценки $\mathbf{b}$ и $\mathbf{w}$ значений весов двухслойного перцептрона, используя выборку из файла `lipo.csv`
5. Прокомментируйте полученные результаты:
 - Сколько итераций в каждом случае потребовалось, чтобы алгоритм градиентного спуска сошёлся? Сошёлся ли он в итоге?
 - Проведите эксперименты с уменьшением скорости обучения на каждой итерации
 - Если Вы знакомы с одной из библиотек для работы с нейросетевыми моделями (например `scikit-learn`), постройте модель двухслойного перцептрона с её помощью и сравните полученные результаты с результатами, полученными Вами вручную

- Адекватно ли использование модели двухслойного перцептрона для описания зависимости коэффициента липофильности от структуры молекул?
- Какие регрессоры вносят наибольший вклад в коэффициент липофильности, а какие наименьший? Согласуется ли это с Вашими теоретическими представлениями о причинах липофильности?
- Как соотносятся результаты, полученные с использованием двухслойного перцептрона с результатами, полученными с помощью линейной регрессии?

Список литературы

- [1] ГОСТ 32291-2013 *Методы испытаний химической продукции, представляющей опасность для окружающей среды. Определение коэффициента распределения n-октанол/вода методом медленного перемешивания.*
- [2] K. Lopez, S. Pinheiro, W.J. Zamora *Multiple linear regression models for predictiong the n-octanol/water partition coefficients in the SAMPL7 blind challenge* // Journal of Computer-Aided Molecular Design, 2021. — V. 35. — pp. 923–931.
- [3] Е.П. Андреева, О.А. Раевский *Расчет липофильности органических соединений на основе структурного сходства и молекулярных физико-химических дескрипторов* // Химико-фармацевтический журнал, 2009. — Т. 43, №5. — с. 28–32.