

Лабораторная работа 4. Расчёт зависимости коэффициента липофильности от структуры молекул с помощью двухслойного перцептрона

Отчёт. Двухслойный перцептрон (2) методички

$$\log P = b_1^2 + (w^2)^T \text{relu}(w^1 x + b^1)$$

с 2, 4, 8, 16 и 32 нейронами скрытого слоя обучается градиентным спуском по выборке `lipo.csv` (82 вещества, 24 структурных дескриптора). Исследуются сходимость, уменьшение скорости обучения, сравнение с `MLPRegressor` из `scikit-learn`, обобщающая способность и вклад регрессоров. Итог сравнивается с линейной регрессией из ЛРЗ.

Код: пакет `lipo_mlp` (Python, NumPy; `scikit-learn` только для сравнения). Все числа и рисунки получены командой `python -m lipo_mlp report` (≈ 6 мин на 8 ядрах; 165 запусков обучения по до $3 \cdot 10^5$ итераций) и воспроизводятся до последнего знака. Полные таблицы: [results/tables.md](#), все числа: [results/summary.json](#).

Кратко о результатах

- Сколько итераций и сошёлся ли спуск.** При $\varepsilon = 0.1$, $\delta = 10^{-4}$ сети с $H = 8, 16, 32$ сошлись в 13 из 15 запусков за $5.7 \cdot 10^4$ – $2.4 \cdot 10^5$ итераций. Медиана — около 10^5 – $2 \cdot 10^5$, разброс между начальными весами в 2–4 раза. Они пришли в **глобальный минимум** ошибки на обучающей выборке: $\text{RMSE} = 0.1237$. Это наименьшее возможное значение: сеть точно описывает все вещества, кроме изомеров с одинаковыми дескрипторами. Сети с $H = 2$ и $H = 4$ не сошлись ни разу. Их минимум лежит на изломе ReLU, где градиент не обращается в ноль, поэтому критерий $\|DJ\| < \delta$ недостижим при любой скорости обучения.
- Уменьшение скорости обучения.** Медленное убывание (экспоненциальное с $\gamma = 0.99999$) ускорило и сделало надёжнее сходимость $H = 16$: 5 из 5 запусков, медиана $4.7 \cdot 10^4$ итераций против 4 из 5 и $1.0 \cdot 10^5$ при постоянном шаге. Слишком быстрое убывание (сумма шагов конечна или почти конечна) останавливает спуск на полпути. Расходимость при слишком большом $\varepsilon_0 = 0.5$ уменьшение шага не спасает: она развивается за 5–6 итераций. При обучении по мини-пакетам уменьшение шага необходимо: с постоянным шагом норма градиента застревает на уровне шума $\approx 2 \cdot 10^{-2}$.
- scikit-learn.** При одинаковых начальных весах `MLPRegressor` с полнопакетным SGD проходит ту же траекторию, что и наш спуск. После 2000 итераций веса совпадают побитово. Это независимая проверка ручных формул градиента. Встроенный критерий остановки библиотеки срабатывает уже через ~ 300 итераций, далеко от минимума. L-BFGS доходит до минимума за 300–1040 итераций.
- Адекватность.** Как описание обучающей выборки перцептрон «слишком хорош»: $R^2 = 0.994$ при 209–833 параметрах на 82 наблюдения. Он запоминает выборку. На контроле (5-кратная перекрёстная проверка) его ошибка 1.5–2.1 — хуже линейной регрессии (1.04) и даже хуже прогноза средним (1.59) при $H = 2, 4$. Ранняя остановка и L2-регуляризация в лучшем случае доводят ошибку до уровня линейной модели (≈ 1.0), но не лучше модели из 7 регрессоров (0.85). **Для этой выборки двухслойный перцептрон не адекватен:** данных слишком мало, а нелинейность не подтверждается.
- Вклад регрессоров.** Главные те же, что у линейной модели: площадь полярной поверхности PSA (–), HBA1 (–), HBA2 (+), число атомов углерода C (+), затем MR и HBD. Наименьший — у редких индикаторов (RCHO, RBr, ROPO3, RCOOH, RCOR, RF). Ранговая корреляция перестановочной важности с $|\beta^*|$ линейной модели 0.54–0.55.
- Сравнение с линейной регрессией.** Линейная регрессия — частный случай перцептрона без скрытого слоя (лекция 4). Перцептрон лучше описывает обучающую выборку (RMSE 0.12 против 0.64), но хуже предсказывает новые вещества, требует 10^5 итераций вместо одной системы уравнений, его ре-

шение зависит от начальных весов, и для него нет доверительных интервалов. На этих данных предпочтительна линейная модель.

1. Модель и данные (пункты 1–2)

Модель. Для вектора дескрипторов $x \in \mathbb{R}^{24}$ скрытый слой вычисляет $z = w^1 x + b^1$ (w^1 — матрица $H \times 24$) и $\text{relu}(z) = \max(0, z)$ поэлементно, выходной нейрон — $\hat{y} = b_1^2 + (w^2)^T \text{relu}(z)$. Всего $H(d+2) + 1$ параметров:

H	2	4	8	16	32
параметров	53	105	209	417	833
параметров на одно наблюдение	0.65	1.3	2.5	5.1	10.2

Уже при $H = 4$ параметров больше, чем наблюдений (82). У линейной модели ЛРЗ их было 25.

Подготовка данных. Особенности выборки разобраны в отчёте ЛРЗ (раздел 1). Для перцептрона важны две:

- **Разные масштабы.** Индикаторы групп принимают значения 0–3, число атомов углерода — до 40, площадь PSA — до 198 Å². При одной скорости обучения для всех весов шаг, подходящий для PSA, был бы ничтожен для индикаторов, и наоборот. Поэтому каждый регрессор и сам $\log P$ стандартизуются (среднее 0, дисперсия 1). Прогнозы переводятся обратно, и все ошибки ниже указаны в единицах $\log P$. При перекрёстной проверке параметры стандартизации оцениваются только по обучающей части.
- **Повторы.** Три группы изомеров (7 веществ) имеют одинаковые дескрипторы, но разные $\log P$. Любая функция $f(x)$ выдаёт для них одно значение, лучшее из возможных — среднее по группе. Поэтому ошибка на обучающей выборке не может быть меньше $\sqrt{SS_{pe}/n} = \sqrt{1.2555/82} = 0.1237$ («чистая ошибка» ЛРЗ).

2. Алгоритм и выбор ε, δ (пункты 3–4)

Функция потерь и градиент. Минимизируется среднеквадратичная ошибка

$$J = \frac{1}{2n} \sum_{i=1}^n L_i^2, \quad L_i = y_i - b_1^2 - (w^2)^T \text{relu}(w^1 x_i + b^1).$$

Множитель $\frac{1}{2n}$ вместо суммы из лекции 4 не меняет точку минимума, но делает градиент независимым от числа веществ. Тогда одна и та же ε годится и для всей выборки, и для её частей при перекрёстной проверке. Кроме того, это в точности функция потерь MLPRegressor. Градиент — по формулам лекции 4 с $V_i = w^2 \circ H(w^1 x_i + b^1)$, где H — функция Хевисайда (производная ReLU):

$$D_{b^2} J = -\frac{1}{n} \sum_i L_i, \quad D_{w^2} J = -\frac{1}{n} \sum_i \text{relu}(w^1 x_i + b^1) L_i, \quad D_{b^1} J = -\frac{1}{n} \sum_i V_i L_i, \quad D_{w^1} J = -\frac{1}{n} \sum_i V_i L_i \otimes x_i.$$

Алгоритм — ровно шаги 1–3.5 лекции. Начальные веса задаются случайно, по Хе: $w_{jk}^1 \sim N(0, 2/d)$, $w_j^2 \sim N(0, 1/H)$, смещения нулевые. Нулевые веса не годятся: все нейроны были бы одинаковы и такими бы и остались. Для каждой конфигурации — 5 запусков с разными начальными весами (зёрна 0–4). Остановка: $\|DJ[j]\| < \delta$ (евклидова норма вектора всех производных) или предел в $3 \cdot 10^5$ итераций.

Проверка градиента. (1) Сравнение с центральными конечными разностями: расхождение не больше 10^{-10} для $H = 1 \dots 32$. (2) Траектория MLPRegressor с теми же начальными весами совпадает с нашей побитово (раздел 5).

Выбор ε . Ориентир даёт линейная модель на тех же стандартизованных признаках. Её гессиан $X^T X/n$ имеет собственные числа от $\lambda_{\min} = 4.9 \cdot 10^{-4}$ до $\lambda_{\max} = 8.31$. Градиентный спуск устойчив при $\varepsilon < 2/\lambda_{\max} = 0.24$. Для перцептрона граница оказалась немного выше: при $\varepsilon \leq 0.4$ все запуски устойчивы, при $\varepsilon = 0.5$ три из пяти разошлись за 5–6 итераций (табл. 2, рис. 2б). Выбрано $\varepsilon = 0.1$ — с запасом в 2.4 раза до границы для линейной модели.

Таблица 2. Постоянная скорость обучения, $H = 16$, 5 запусков на значение.

ε	сошлось	итераций: медиана (мин–макс)	RMSE обучения
0.01	1 из 5	246 555	0.125
0.03	5 из 5	114 367 (82 051–214 020)	0.124
0.1	4 из 5	101 229 (57 403–142 469)	0.124
0.2	5 из 5	114 330 (76 379–157 118)	0.124
0.3	5 из 5	90 959 (40 934–125 209)	0.124
0.4	5 из 5	54 993 (30 326–115 439)	0.124
0.5	2 из 5, разошлись 3	50 462 (31 321–69 603)	0.124

Выбор δ . В начале обучения $\|DJ\| \approx 1\text{--}4$. $\delta = 10^{-4}$ означает уменьшение градиента на 4–5 порядков. При этом потери уже не меняются в первых 4–5 значащих цифрах.

Почему итераций так много. Отношение $\lambda_{\max}/\lambda_{\min}$ гессиана линейной части равно $1.7 \cdot 10^4$. Это мультиколлинеарность из ЛРЗ ($C \approx MR$, $HBA1 \approx HBA2 \approx PSA$), только в другом обличье. При устойчивом шаге $\varepsilon < 2/\lambda_{\max}$ ошибка вдоль самого «пологого» направления убывает в $(1 - \varepsilon\lambda_{\min})$ раз за итерацию. Чтобы уменьшить её в e раз, нужно $1/(\varepsilon\lambda_{\min}) \approx 2 \cdot 10^4$ итераций. Градиентный спуск с одним шагом для всех направлений плохо подходит для таких задач.

3. Сходимость при разном числе нейронов (пункт 5, первый вопрос)

Таблица 1. Обучение при $\varepsilon = 0.1$, $\delta = 10^{-4}$, 5 запусков на размер. RMSE — среднее (мин–макс) по запускам; $R^2 = 1 - RMSE^2/\sigma_y^2$; $\|DJ\|$ — медиана в момент остановки.

H	параметров	сошлось	итераций: медиана (мин–макс)	RMSE обучения	R^2	$\ DJ\ $ в конце
2	53	0 из 5	—	0.597 (0.447–0.840)	0.851	5.5e-02
4	105	0 из 5	—	0.258 (0.153–0.429)	0.970	1.5e-01
8	209	4 из 5	196 919 (90 780–239 364)	0.124 (0.124–0.124)	0.994	1.0e-04
16	417	4 из 5	101 229 (57 403–142 469)	0.124 (0.124–0.124)	0.994	1.0e-04
32	833	5 из 5	117 951 (70 766–147 590)	0.124 (0.124–0.124)	0.994	1.0e-04




Рисунок 1. Обучение с $\varepsilon = 0.1$ (зерно 0). (а) Ошибка на обучающей выборке. Оранжевая линия — линейная регрессия ЛРЗ, серая — нижняя граница 0.1237. (б) Норма градиента и порог δ ; точка — момент остановки.




Рисунок 2. Число итераций до $\|DJ\| < \delta$ в каждом запуске. (а) По размеру скрытого слоя. (б) По скорости обучения для $H = 16$. $\circ$ — не сошёлся за $3 \cdot 10^5$ итераций, $\times$ — разошёлся.

$H \geq 8$: **сошёлся в глобальный минимум**. Из 15 запусков 13 остановились по критерию за 57 403–239 364 итерации (табл. 1). В двух оставшихся (по одному для $H = 8$ и $H = 16$) ошибка тоже вышла на 0.124, но норма градиента к $3 \cdot 10^5$ итераций ещё не опустилась до 10^{-4} . Во всех этих запусках RMSE на обучающей выборке равна 0.1237, то есть нижней границе из раздела 1. Значит, найден **глобальный** минимум J : сеть описывает 75 веществ точно, а для трёх групп изомеров выдаёт средние по группе. Кривые на рис. 1 проходят три стадии:

1. быстрое убывание ошибки за первые 10^2 – 10^3 итераций;
2. неустойчивый участок (10^3 – 10^4): норма градиента *растёт* на 1–2 порядка и скачет. В острых направлениях шаг оказывается на грани устойчивости, и ошибка временами подскакивает (пики на рис. 1а);
3. медленное «доползание» вдоль пологих направлений, которое и занимает основное время.

Число итераций зависит от начальных весов в 2–4 раза. Перцептрон — невыпуклая задача, и из разных начальных точек спуск идёт к разным (хотя одинаково хорошим) минимумам. Большее H не ускоряет сходимость заметно: медианы $2.0 \cdot 10^5$, $1.0 \cdot 10^5$ и $1.2 \cdot 10^5$ итераций для $H = 8, 16, 32$.

$H = 2$ и $H = 4$: **не сошёлся**. Ни один запуск не достиг $\|DJ\| < \delta$ за $3 \cdot 10^5$ итераций. Ошибка при этом давно перестала уменьшаться (RMSE 0.45–0.84 при $H = 2$ и 0.15–0.43 при $H = 4$, в зависимости от начальных весов), а норма градиента колеблется около 0.02–0.2 и не убывает (рис. 1б). Причина — **излом ReLU**. Узкая сеть не может пройти через все точки, и её минимум лежит там, где у части нейронов $z_{ik} = (w^1 x_i + b^1)_k \approx 0$. В такой точке функция потерь не дифференцируема. Слева и справа от излома градиенты разные и оба не равны нулю. Спуск с любым шагом перескакивает через излом туда и обратно, нейроны переключаются, и градиент не может стать меньше δ (рис. 3а).




Рисунок 3. Продолжение спуска из конечной точки на 300 шагов. (а) Норма градиента: у $H = 2, 4$ она колеблется около 0.02–0.2, у сошедшейся $H = 16$ — около 10^{-4} . (б) Скачок градиента при переключении нейрона пропорционален $|L_i w_k^2|$. Переключения есть у всех сетей, но у широкой сети они происходят на веществе с нулевым остатком L_i и на градиент не влияют.

Переключения нейронов происходят и у сошедшихся широких сетей: от 5 до 55 пар «вещество–нейрон» имеют $|z| < 10^{-3}$. Но там сеть уже прошла через все точки: остатки $|L_i| \sim 10^{-5}$, и скачок градиента $\propto |L_i w_k^2| \sim 10^{-6}–10^{-4}$ (рис. 3б). У узких сетей остатки большие, и скачок 0.1–0.4 — того же порядка, что и сам градиент.

Ответ на вопрос. При $H \geq 8$ спуск сошёлся, в 13 из 15 запусков — по заданному критерию, за $10^5–2.4 \cdot 10^5$ итераций, к глобальному минимуму ошибки на обучающей выборке. При $H \leq 4$ он не сошёлся по критерию градиента и в принципе не может сойтись: ошибка стабилизировалась, но в негладкой точке. Для ReLU-сетей разумнее останавливать обучение по изменению J , как это делает scikit-learn, или по ошибке на контрольной выборке (раздел 6).

4. Уменьшение скорости обучения на каждой итерации (второй вопрос)

Проверены законы ε_j с разной скоростью убывания (рис. 4б). Важная характеристика — сумма шагов $\sum_j \varepsilon_j$: она ограничивает путь, который может пройти алгоритм, $\|\theta[J] - \theta[0]\| \leq \sum_j \varepsilon_j \|DJ[j]\|$.

Таблица 3. Законы уменьшения скорости обучения; по 5 запусков на закон.

сеть	закон ε_j	$\Sigma \varepsilon_j$	сошлось	итераций: медиа-на (мин–макс)	RMSE обучения	IIDJII в конце
H = 16	постоянная $\varepsilon = 0.1$	∞	4 из 5	101 229 (57 403–142 469)	0.1237	1.0e-04
H = 16	$\varepsilon_0/(1 + j/\tau)$, $\varepsilon_0 = 0.1$, $\tau = 10000$	∞	3 из 5	224 031 (107 541–299 283)	0.1246	1.0e-04
H = 16	$\varepsilon_0/(1 + j/\tau)$, $\varepsilon_0 = 0.1$, $\tau = 1000$	∞	0 из 5	—	0.1647	4.0e-03
H = 16	$\varepsilon_0 \cdot \gamma^j$, $\varepsilon_0 = 0.1$, $\gamma = 0.99999$	10000	5 из 5	47 110 (33 231–127 059)	0.1239	1.0e-04
H = 16	$\varepsilon_0 \cdot \gamma^j$, $\varepsilon_0 = 0.1$, $\gamma = 0.9999$	1000	0 из 5	—	0.1374	1.7e-03
H = 16	$\varepsilon_0 \cdot \gamma^{\lfloor j/m \rfloor}$, $\varepsilon_0 = 0.1$, $\gamma = 0.5$, $m = 20000$	4000	3 из 5	54 025 (37 567–85 202)	0.1247	1.0e-04
H = 16, большой ε_0	постоянная $\varepsilon = 0.5$	∞	2 из 5, разошлись 3	50 462 (31 321–69 603)	0.1237	1.0e-04
H = 16, большой ε_0	$\varepsilon_0/(1 + j/\tau)$, $\varepsilon_0 = 0.5$, $\tau = 1000$	∞	0 из 5, разошлись 3	—	0.1245	4.8e-04
H = 16, большой ε_0	$\varepsilon_0 \cdot \gamma^j$, $\varepsilon_0 = 0.5$, $\gamma = 0.9999$	5000	1 из 5, разошлись 3	27 834	0.1239	1.0e-04
H = 4	постоянная $\varepsilon = 0.1$	∞	0 из 5	—	0.2583	1.5e-01
H = 4	$\varepsilon_0/(1 + j/\tau)$, $\varepsilon_0 = 0.1$, $\tau = 1000$	∞	0 из 5	—	0.3533	2.0e-02
H = 4	$\varepsilon_0 \cdot \gamma^j$, $\varepsilon_0 = 0.1$, $\gamma = 0.99999$	10000	0 из 5	—	0.2574	2.4e-03
H = 4	$\varepsilon_0 \cdot \gamma^{\lfloor j/m \rfloor}$, $\varepsilon_0 = 0.1$, $\gamma = 0.5$, $m = 20000$	4000	0 из 5	—	0.2702	7.3e-03
H = 16, мини-пакеты по 16	постоянная $\varepsilon = 0.05$	∞	0 из 5	—	0.1245	1.7e-02
H = 16, мини-пакеты по 16	$\varepsilon_0/(1 + j/\tau)$, $\varepsilon_0 = 0.05$, $\tau = 20000$	∞	0 из 5	—	0.1250	2.2e-03




Рисунок 4. Норма градиента при разных законах ϵ_j (зерно 0). (а) $H = 16$. (б) Сами законы. (в) $H = 4$. (г) Обучение по мини-пакетам из 16 веществ: норма полного градиента.

Выводы по экспериментам:

- Медленное убывание помогает.** Экспоненциальный закон с $\gamma = 0.99999$ (шаг уменьшается вдвое за $7 \cdot 10^4$ итераций) дал сходимость во всех 5 запусках с медианой $4.7 \cdot 10^4$ итераций — вдвое быстрее, чем при постоянном шаге. Ступенчатый закон (вдвое каждые $2 \cdot 10^4$ итераций) — 3 из 5, медиана $5.4 \cdot 10^4$. Уменьшающийся шаг гасит колебания неустойчивого участка (стадия 2 в разделе 3), но первые $5 \cdot 10^4$ итераций остаётся не меньше 0.06 и не замедляет движение вдоль пологих направлений. Различия медиан при 5 запусках и разбросе в 2–4 раза — скорее тенденция, чем строгий результат.
- Слишком быстрое убывание вредит.** Обратный закон с $\tau = 10^3$ и экспоненциальный с $\gamma = 0.9999$ ($\sum \epsilon_j = 1000$) не сошлись ни разу. Спуск останавливается на полпути: норма градиента $\sim 2\text{--}4 \cdot 10^{-3}$, ошибка 0.14–0.16 вместо 0.124 (рис. 4а). Даже при бесконечной сумме, растущей как $\ln j$ (обратный закон), путь за разумное число итераций практически конечен. Обратный закон с $\tau = 10^4$ сходится, но медленнее постоянного шага (медиана $2.2 \cdot 10^5$, 3 из 5).
- Расходимость уменьшением шага не лечится.** При $\epsilon_0 = 0.5$ три запуска из пяти разошлись за 5–6 итераций — и с постоянным шагом, и с убывающим. Ошибка растёт как $|1 - \epsilon \lambda|^j$, и за несколько итераций шаг не успевает уменьшиться. Спасает только меньший начальный шаг (или адаптивные методы).
- В изломе уменьшение шага не помогает достичь δ .** Для $H = 4$ убывающий шаг уменьшает норму градиента с 0.15 до $2 \cdot 10^{-3}\text{--}2 \cdot 10^{-2}$: колебания вокруг излома становятся мельче. Но до 10^{-4} она не доходит ни при каком законе, и ошибка остаётся прежней (0.26–0.35, рис. 4в). Односторонние градиенты в изломе от шага не зависят.
- Для мини-пакетов уменьшение шага необходимо.** Если веса обновлять по градиенту 16 случайных веществ (лекция 4, «мини-пакет»), шаг содержит случайную ошибку. При постоянном ϵ веса «дрожат» вокруг минимума, и полный градиент застревает на уровне $\approx 2 \cdot 10^{-2}$. С законом

$\varepsilon_0/(1 + j/\tau)$ (условия Роббинса–Монро $\sum \varepsilon_j = \infty$, $\sum \varepsilon_j^2 < \infty$) дрожание затухает: за то же число итераций норма уменьшилась в 8 раз и продолжает убывать (рис. 4г).

Итог. Для полного (не стохастического) градиентного спуска уменьшение шага не обязательно. Медленное убывание может ускорить сходимость, быстрое останавливает спуск раньше времени. Для стохастического спуска по мини-пакетам уменьшение шага необходимо.

5. Сравнение с scikit-learn (третий вопрос)

`MLPRegressor(hidden_layer_sizes=(H,), activation="relu")` — та же модель (2). При $\alpha=0$ его функция потерь совпадает с нашей J . Сравнение проведено в два этапа.

Та же траектория. Настройки `solver="sgd"`, `batch_size=82` (полный пакет), `momentum=0`, постоянная скорость обучения 0.1, начальные веса — наши (подставлены через `warm_start`). После 2000 итераций $\max|w_{\text{наш}} - w_{\text{sklearn}}| = 0$ для $H = 4 \dots 32$ и $1.6 \cdot 10^{-15}$ для $H = 2$ (табл. 5). Библиотека выполняет ровно тот же алгоритм, а наш вывод градиента по формулам лекции верен.

Практические настройки.

Таблица 5. Сверка траекторий и три настройки MLPRegressor на всей выборке.

H	max Δw после 2000 итераций	sgd (как у нас, остановка sklearn): итераций / RMSE	adam (по умолчанию): итераций / RMSE	lbfgs: итераций / RMSE
2	1.6e-15	264 / 0.950	764 / 1.045	572 / 0.436
4	0.0e+00	367 / 0.539	774 / 0.705	1037 / 0.172
8	0.0e+00	357 / 0.531	628 / 0.635	303 / 0.128
16	0.0e+00	268 / 0.424	481 / 0.482	411 / 0.124
32	0.0e+00	291 / 0.423	404 / 0.429	376 / 0.124

- **SGD с остановкой scikit-learn.** Тот же спуск останавливается, когда J 10 эпох подряд уменьшается меньше чем на 10^{-4} . Это происходит уже через 260–370 итераций, при ошибке 0.42–0.95: на медленной стадии спуска J меняется на 10^{-5} – 10^{-6} за итерацию. Наш критерий по градиенту гораздо строже.
- **Adam** (по умолчанию: шаг 10^{-3} , адаптивный для каждого веса, $\alpha = 10^{-4}$) останавливается через 400–770 итераций, RMSE 0.43–1.05.
- **L-BFGS** (квазиньютоновский метод: учитывает кривизну и поэтому не страдает от плохой обусловленности) доходит до той же нижней границы 0.124 за 300–1040 итераций — в 100–1000 раз быстрее градиентного спуска. При $H = 2, 4$ он находит минимумы лучше наших (0.44 и 0.17).

Ранняя остановка scikit-learn неожиданно оказывается полезной: эти модели лучше предсказывают новые вещества (RMSE контроля 1.16–1.29, табл. 4), чем доведённые до минимума (L-BFGS — 1.76–1.84, наш спуск — 1.51–1.56). Недообучение работает как регуляризация (раздел 6).

6. Адекватна ли модель двухслойного перцептрона? (четвёртый вопрос)

На обучающей выборке сети с $H \geq 8$ дают $R^2 = 0.994$. Это не достоинство: при 209–833 параметрах на 82 вещества сеть может провести поверхность почти через любые точки (теорема об универсальной аппроксимации, лекция 4). Вопрос в том, что она выучила — закономерность или шум. Проверка — 5-кратная перекрёстная проверка, повторённая дважды: сеть обучается на 4/5 веществ и предсказывает оставшуюся 1/5.

Таблица 4. RMSE на обучающей выборке и на контроле (5-кратная перекрёстная проверка, 2 повторения, одни и те же разбиения для всех моделей).

модель	параметров	RMSE обучения	RMSE контроля	лучшая RMSE контроля по ходу обучения
МНК, 24 регрессора	25	0.641	1.036	—
МНК, 7 регрессоров (ЛРЗ)	8	0.750	0.845	—
перцептрон $H = 2$	53	0.597	1.660	1.301 (итерация 407)
перцептрон $H = 4$	105	0.258	2.113	1.118 (итерация 327)
перцептрон $H = 8$	209	0.124	1.560	1.148 (итерация 727)
перцептрон $H = 16$	417	0.124	1.521	1.224 (итерация 53)
перцептрон $H = 32$	833	0.124	1.511	1.272 (итерация 40)
sklearn sgd (как у нас, остановка sklearn), $H = 8$	209	0.531	1.286	—
sklearn sgd (как у нас, остановка sklearn), $H = 32$	833	0.423	1.160	—
sklearn adam (по умолчанию), $H = 8$	209	0.635	1.245	—
sklearn adam (по умолчанию), $H = 32$	833	0.429	1.173	—
sklearn lbfgs, $H = 8$	209	0.128	1.836	—
sklearn lbfgs, $H = 32$	833	0.124	1.759	—




Рисунок 5. (а) Ошибка на обучении ($\circ$) и на контроле ($\bullet$). (б) Ошибка на контроле по ходу обучения перцептрона. Горизонтальные линии — линейные модели ЛРЗ.

- **Обученные до конца сети предсказывают плохо:** RMSE контроля 1.51–2.11 против 1.04 у полной линейной модели и 0.85 у модели из 7 регрессоров. Сети с $H = 2$ и $H = 4$ на контроле хуже, чем простой прогноз средним значением ($\sigma_y = 1.59$).

- **Ранняя остановка.** Ошибка на контроле минимальна уже через 40–730 итераций (рис. 5б), а дальше растёт: сеть начинает подгонять шум. Но и в минимуме она 1.12–1.30, хуже линейной модели.
- **L2-регуляризация.** Добавление $\frac{\alpha}{2n}\|W\|^2$ к функции потерь штрафует большие веса (табл. 4б).

Таблица 4б. L2-регуляризация (MLPRegressor, L-BFGS): RMSE на обучении и на контроле.

α	H = 8: обучение	H = 8: контроль	H = 32: обучение	H = 32: контроль
0	0.129	1.815	0.124	1.765
0.01	0.125	1.185	0.124	1.193
0.1	0.162	1.118	0.159	1.165
1	0.350	1.050	0.334	1.013
3	0.542	1.022	0.494	1.000
10	0.787	1.047	0.783	1.049
30	0.980	1.168	0.977	1.167

Лучший результат — $\text{RMSE} \approx 1.00\text{--}1.02$ при $\alpha = 1\text{--}3$ — совпадает с полной линейной моделью. При этом и ошибка на обучении (0.33–0.54) становится сопоставимой с линейной (0.64). Сильная регуляризация делает сеть почти линейной, и лучше линейной модели из 7 регрессоров она не становится ни при каком α .

Вывод. Для этой выборки двухслойный перцептрон не адекватен как модель зависимости $\log P$ от структуры. Он способен описать выборку сколь угодно точно, но то, что он выучивает сверх линейной зависимости, — шум. В данных нет подтверждения нелинейных эффектов: регуляризованная сеть предсказывает не лучше линейной регрессии, а сеть без ограничений — хуже. Для обучения нелинейной модели нужно на порядки больше веществ, чем 82 (или сильная регуляризация, после которой сеть становится почти линейной).

7. Вклад регрессоров (пятый вопрос)

У перцептрона нет одного коэффициента на регрессор: вклад x_j зависит от того, какие нейроны активны. Используются две меры, обе в стандартизованных единицах, чтобы их можно было сравнить со стандартизованными коэффициентами β^* линейной модели:

- **средняя производная** $\langle \partial \hat{y} / \partial x_j \rangle$ по всем веществам (и её модуль). Для ReLU-сети $\nabla_x \hat{y} = (w^1)^T (w^2 \circ H(w^1 x + b^1))$, для линейной модели производная постоянна и равна β_j^* ;
- **перестановочная важность** — рост среднеквадратичной ошибки, если значения x_j случайно перемешать между веществами (30 перемешиваний).

Меры посчитаны для ансамбля из 5 сошедшихся сетей (зёрна 0–4) при $H = 8$ и $H = 32$.

Таблица 6. Вклад регрессоров: стандартизованный коэффициент МНК β^* , средняя производная $\langle \partial \hat{y} / \partial x \rangle$, её модуль и перестановочная важность (рост MSE).

регрессор	МНК β^*	МНК перест.	H=8 $\langle \partial \hat{y} / \partial x \rangle$	H=8 $\langle \partial \hat{y} / \partial x \rangle$	H=8 перест.	H=32 $\langle \partial \hat{y} / \partial x \rangle$	H=32 $\langle \partial \hat{y} / \partial x \rangle$	H=32 перест.
C	+2.26	10.289	+0.68	0.95	1.221	+0.99	1.04	2.336
HBA2	+2.16	9.458	+1.71	1.81	6.255	+1.34	1.34	3.899
PSA	-1.74	6.058	-1.54	1.88	8.007	-1.45	1.55	5.436
HBA1	-1.07	2.317	-1.64	1.70	7.510	-1.60	1.60	4.880
MR	-1.01	2.037	+0.91	0.98	1.754	+0.78	0.85	1.380
RINGS	-0.33	0.220	-0.37	0.61	0.331	-0.22	0.37	0.239
RSR	+0.27	0.143	+0.07	0.48	0.241	+0.19	0.33	0.169
RCI	+0.20	0.080	+0.13	0.47	0.143	+0.04	0.29	0.071
RSO2NR	+0.18	0.066	+0.10	0.75	0.224	+0.14	0.50	0.431
RCOOH	+0.14	0.040	+0.11	0.27	0.047	+0.07	0.25	0.039
AROMATIC	+0.13	0.036	-0.05	0.72	0.487	-0.08	0.39	0.145
ROR	-0.13	0.030	+0.18	0.51	0.144	+0.17	0.33	0.093
RBr	+0.12	0.030	+0.12	0.36	0.015	+0.25	0.36	0.010
RF	+0.11	0.025	+0.12	0.44	0.103	+0.14	0.38	0.036
RCOR	-0.11	0.023	+0.16	0.45	0.046	+0.12	0.34	0.023
ROPO3	+0.08	0.011	-0.01	0.37	0.010	+0.14	0.43	0.072
RSO2R	+0.06	0.008	+0.25	0.43	0.122	+0.22	0.36	0.050
R3N	-0.06	0.008	+0.10	0.68	0.243	-0.25	0.47	0.222
RNH2	+0.04	0.004	-0.20	0.61	0.292	-0.27	0.39	0.230
R2NH	+0.04	0.002	-0.09	0.62	0.178	-0.22	0.41	0.153
RCOOR	+0.03	0.002	+0.28	0.53	0.259	+0.17	0.49	0.103
HBD	+0.03	0.002	+0.69	0.89	1.145	+0.71	0.75	1.327
ROH	+0.01	0.000	-0.08	0.43	0.125	-0.18	0.40	0.079
RCHO	+0.00	0.000	+0.08	0.29	0.008	+0.09	0.34	0.010




Рисунок 6. (а) Средний эффект регрессора со знаком. (б) Перестановочная важность в процентах от суммы по всем регрессорам.

- **Наибольший вклад** у обеих сетей вносят PSA, HBA1, HBA2 и C (вместе около 80 % суммарной важности), затем MR и HBD. У линейной модели первые пять те же, хотя порядок другой: у неё на первом месте C и HBA2.
- **Наименьший вклад** — у редких индикаторов: RCHO, RBr, ROPO3 (по одному веществу), RCOOH, RCOR, RF. При перемешивании такой столбец почти не меняется, и сеть их практически не использует.
- **Знаки.** Как и в линейной модели: $\log P$ растёт с C и падает с PSA и HBA1. HBA2 снова получает «нефизический» знак плюс: это та же компенсация коллинеарных регрессоров, что и в ЛРЗ. Интересно различие для MR: у сети эффект положительный (+0.8...+0.9), у линейной модели отрицательный (−1.0). Физически ожидается плюс, поскольку более поляризуемые молекулы липофильнее. Но при корреляции C и MR 0.985 разделение их вкладов произвольно, и разные модели делят его по-разному. Для HBD сеть даёт заметный положительный эффект (+0.7), хотя доноры водородной связи должны *понижать* $\log P$. Это тоже артефакт.
- **Согласие мер.** Ранговая корреляция Спирмена перестановочной важности сети и $|\beta^*|$ линейной модели — 0.54 ($H = 8$) и 0.55 ($H = 32$): общая картина совпадает, детали нет.

Согласуется ли это с теорией? В главном — да. Как и в ЛРЗ, модель выделяет два фактора: размер углеродного скелета повышает липофильность (гидрофобный эффект), а полярность и способность к водородным связям (PSA, акцепторы) понижают. Вклады отдельных функциональных групп сеть надёжно не определяет: многие группы представлены единицами веществ. Кроме того, эти меры описывают переобученную функцию.

8. Сравнение с линейной регрессией (шестой вопрос)

	Линейная регрессия (ЛРЗ)	Двухслойный перцептрон
модель	$\log P = \beta_0 + \beta^T x$; перцептрон без скрытого слоя с $f_A(z) = z$ (лекция 4)	кусочно-линейная функция, H нейронов ReLU
параметров	25 (или 8 после исключения)	53–833
обучение	одна система нормальных уравнений, решение единственно	10^5 – $3 \cdot 10^5$ итераций спуска; невыпуклая задача, результат зависит от начальных весов
RMSE на обучении	0.641 (0.750 для 7 регрессоров)	0.124 при $H \geq 8$ (нижняя граница)
RMSE на контроле	1.04 (0.85 для 7 регрессоров)	1.51–2.11; с ранней остановкой 1.12–1.30; с L2-регуляризацией ≈ 1.00
выводы о коэффициентах	t-статистики, доверительные интервалы, F-тесты	нет (параметров больше, чем наблюдений)
главные факторы	C (+), HBA2 (+), PSA (–), HBA1 (–), MR (–)	PSA (–), HBA1 (–), HBA2 (+), C (+), MR (+), HBD (+)
влияние мультиколлинеарности	раздутые SE, «нефизические» знаки	те же компенсирующие знаки; плохая обусловленность замедляет спуск

Перцептрон включает линейную модель как частный случай. Если все нейроны активны на всех веществах, сеть линейна. Поэтому на обучающей выборке он не может быть хуже и действительно лучше в 5 раз по RMSE. Но на новых веществах линейная модель, особенно сокращённая до 7 регрессоров, предсказывает лучше. Она проще, её решение единственно и интерпретируемо, а неопределённость коэффициентов известна. Обе модели сходятся в главном выводе о природе липофильности и одинаково страдают от коллинеарности дескрипторов.

9. Выводы

1. Двухслойный перцептрон (2) реализован с ручным градиентом по формулам лекции 4. Градиент проверен конечными разностями (10^{-10}) и полным совпадением траектории с MLPRegressor.
2. При $\varepsilon = 0.1$, $\delta = 10^{-4}$ спуск сходится для $H = 8, 16, 32$ за 10^5 – $2.4 \cdot 10^5$ итераций, к глобальному минимуму ошибки на обучении (RMSE 0.124 — предел, задаваемый изомерами с одинаковыми дескрипторами). Для $H = 2, 4$ он не сходится: минимум лежит на изломе ReLU. Медленность объясняется плохой обусловленностью ($\lambda_{\max}/\lambda_{\min} = 1.7 \cdot 10^4$) — следствием мультиколлинеарности дескрипторов.
3. Медленное уменьшение скорости обучения ускоряет сходимость, быстрое останавливает спуск преждевременно, а от расходимости при слишком большом ε_0 не спасает. Для обучения по мини-пакетам уменьшение шага необходимо.
4. Перцептрон переобучается. На контроле он хуже линейной регрессии, и даже с ранней остановкой или L2-регуляризацией лишь догоняет её. Для 82 веществ эта модель не адекватна.
5. Главные факторы липофильности у перцептрона те же, что у линейной модели: размер молекулы (+) и полярность (–).

Список литературы

1. ГОСТ 32291-2013. Определение коэффициента распределения н-октанол/вода методом медленного перемешивания.
2. K. López, S. Pinheiro, W. J. Zamora. Multiple linear regression models for predicting the n-octanol/water partition coefficients in the SAMPL7 blind challenge // J. Comput.-Aided Mol. Des. 2021. V. 35. P. 923–931.
3. Е. П. Андреева, О. А. Раевский. Расчёт липофильности органических соединений на основе структурного сходства и молекулярных физико-химических дескрипторов // Хим.-фарм. журнал. 2009. Т. 43, № 5. С. 28–32.

4. Лекции 4–5 курса «Нейронные сети глубокого обучения»: простые нейросетевые модели; глубокие модели и функции потерь.
5. Документация scikit-learn: `sklearn.neural_network.MLPRegressor`.