Лабораторная работа 6. Стохастический градиентный спуск и его модификации

Отчёт. Решены пять задач из lab6b.pdf:

1. найден минимум функции одной переменной методами золотого сечения и Брента [2, разд. 10.1–10.3];
2. три модели обучены классическим градиентным спуском, производные вычислены численно [2, разд. 5.7];
3. те же модели обучены стохастическим градиентным спуском (СГС) с мини-пакетами разного размера;
4. то же сделано с импульсом Нестерова и методом Adam, результаты задач 2–4 сравнены;
5. задачи 2–4 решены с квадратичным штрафом на веса (задача 5*).

Опора — лекция 6 [3] и книга Гудфеллоу, Бенджио, Курвилля [1]: гл. 4.3 (градиентная оптимизация, гессиан), 7.1 (штрафы на норму параметров), 8.1–8.5 (СГС, импульс, Нестеров, Adam).

Код: пакет `sgd_lab` (Python, NumPy; SciPy — только для проверки). Все числа и рисунки получены командой `python -m sgd_lab report` (≈ 4 мин на 8 ядрах, около 15 000 запусков обучения) и воспроизводятся до последнего знака. Полные таблицы: results/tables.md, все числа: results/summary.json.

Кратко о результатах

1. **Задача 1.** У функции $f(z)$ **один** минимум: $z^* = 0.3803215288$, $f(z^*) = 0.3286036575$. Возле $z \approx 0.6$ только «полка»: f' там падает до 0.0033, но в ноль не обращается. Золотое сечение нашло минимум за 43 вычисления f, метод Брента — за 15. Ошибка обоих — 10^{-10}–10^{-11}, не хуже предела $\sqrt{2\varepsilon_{\text{маш}}|f|/f''} \approx 2 \cdot 10^{-9}$, который не обходится уменьшением допуска.
2. **Задача 2.** Для моделей 1 и 2 градиентный спуск сходится к решению МНК (до $3 \cdot 10^{-8}$). Число итераций точно совпадает с теоретическим: 111 и 2417. Модель 2 медленнее в 22 раза из-за плохой обусловленности: $\kappa = 278$ против 12.5. Спуск устойчив только при $\varepsilon < 2/\lambda_{max}$. Сеть ReLU (модель 3) невыпукла: из 100 начальных точек спуск ни разу не дошёл до глобального минимума (SSE = 0.0644). В 15 % случаев он нашёл модель лучше квадратичной, в 34 % — прямую, в 17 % — константу или «мёртвую» сеть.
3. **Задача 3.** Мини-пакеты дают больше обновлений за эпоху при той же цене эпохи. Поэтому в начале СГС быстрее, но он останавливается на «уровне шума», и этот уровень тем выше, чем меньше пакет. Скорость из задачи 2 для малых пакетов слишком велика: для модели 2 при $m = 1, 2$ СГС расходится. Уменьшение скорости $\varepsilon_0/(1 + e/\tau)$ убирает шум и доводит СГС до 10^{-4}–10^{-6}. Слишком быстрое уменьшение останавливает медленную модель 2. Для сети ReLU размер пакета почти не влияет на то, в какой минимум придёт обучение.
4. **Задача 4.** При полном пакете импульс Нестерова — лучший метод. Для плохо обусловленной модели 2 он доходит до 10^{-6} за 136 эпох, против 1761 у спуска и 518 у Adam. С мини-пакетами все три метода упираются в шум, и нужно уменьшать ε; Adam с мини-пакетами хуже остальных. Для сети ReLU Adam лучше всех находит хорошие минимумы: 37 % запусков лучше квадратичной модели против 14–22 % у остальных. **Итог сравнения задач 2–4:** на 12 точках полный пакет выгоднее мини-пакетов, а выбор метода важнее выбора размера пакета.
5. **Задача 5.** Штраф $\lambda \sum w^2$ уменьшает веса, увеличивает ошибку обучения и улучшает обусловленность: для модели 2 при $\lambda = 0.1$ κ падает с 278 до 193, итераций спуска — с 2417 до 1675. Все методы сходятся к одному решению — гребневой регрессии. Для моделей 1–2 штраф прогноз не улучшает (скользящий контроль). Для сети ReLU он полезен. Уже $\lambda = 0.001$ уменьшает $\sum w^2$ с 52 до 3.2 при той же SSE:

штраф выбирает из семейства эквивалентных сетей ту, где у каждого нейрона $|w_{\text{вх}}| = |w_{\text{вых}}|$. Ошибка скользящего контроля падает с 0.189 до 0.140 — уровня квадратичной модели.

0. Данные и модели

Выборка — 12 точек (x_i, y_i) из задания. Функция потерь — сумма квадратов ошибок (SSE):

$$J(w) = \sum_{i=1}^{12} \big(y_i - \widehat{y}(x_i; w)\big)^2.$$

Модели: (1) $\widehat{y} = w_1 x + b_1$ — 2 параметра; (2) $\widehat{y} = w_1 x^2 + w_2 x + b_1$ — 3 параметра; (3) $\widehat{y} = \mathrm{ReLU}(w_{21}\mathrm{ReLU}(w_{11}x + b_{11}) + w_{22}\mathrm{ReLU}(w_{12}x + b_{12}) + b_{21})$ — 7 параметров, сеть 1–2–1. Модели 1 и 2 линейны по параметрам, их J — выпуклая квадратичная функция с точным минимумом (МНК): $J^* = 0.19987$ и 0.09088. Сеть 3 — кусочно-линейная функция с двумя изломами скрытого слоя и «срезом» снизу на выходе, её J невыпукла. Эталон глобального минимума найден симплекс-методом Нелдера — Мида из 100 случайных точек: $J^* = 0.06442$ — ломаная из трёх участков.

1. Задача 1: золотое сечение и метод Брента

Функция. $f(z)$ — единица минус две «ямы» Гаусса: широкая глубины 0.5 у $z = 0.65$ и узкая глубины 0.45 у $z = 0.35$ (рис. 1а). Ямы перекрываются, и широкая «съедает» второй минимум. Производная

$$f'(z) = 10(z - 0.65)e^{-10(z-0.65)^2} + 45(z - 0.35)e^{-50(z-0.35)^2}$$

меняет знак ровно один раз (это проверяет тест). На «полке» у $z \approx 0.606$ f' падает до 0.0033, но остаётся положительной. Значит, минимум **единственный**, а функция унимодальна. Это условие, при котором метод золотого сечения гарантированно сходится. Эталон $z^* = 0.380321528824$ получен как корень $f'(z) = 0$: корень производной находится с машинной точностью, а минимум по значениям f — нет (ниже).

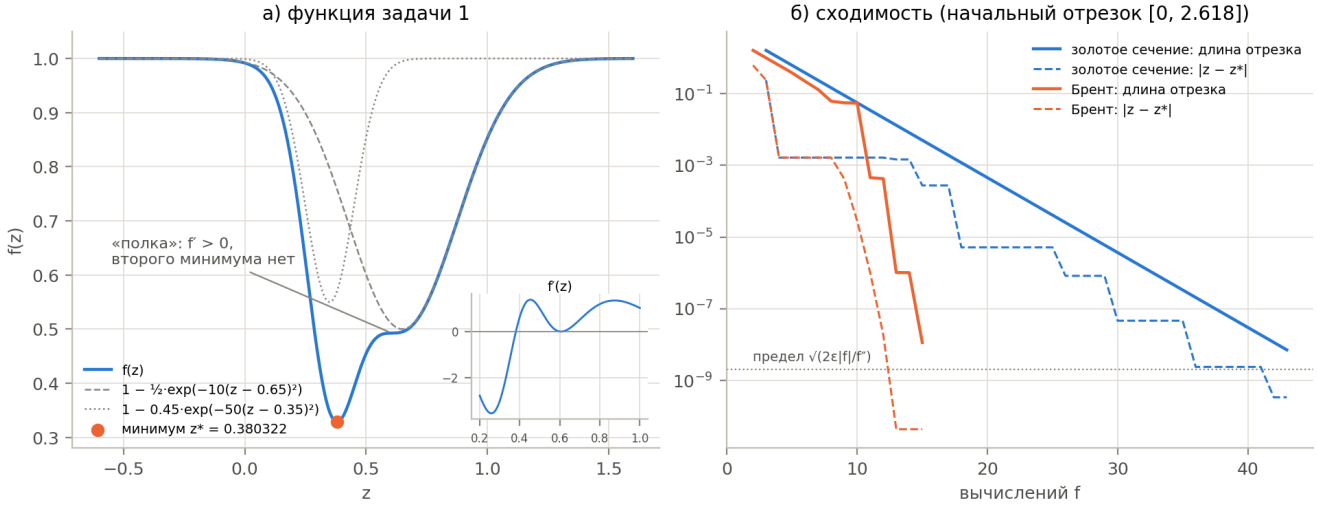


Рис. 1. а) $f(z)$, её слагаемые и производная (вставка); б) длина отрезка неопределённости и ошибка $|z - z^*|$ в зависимости от числа вычислений f.

Алгоритмы [2, гл. 10].

- **Начальный отрезок** (`mnbrak`, разд. 10.1). Нужна тройка $a < b < c$ с $f(b) < f(a), f(c)$. Из точек 0 и 1 процедура идёт под уклон, увеличивая шаг в $\varphi = 1.618$ раза, и за 3 вычисления находит $(0,\ 1,\ 2.618)$.
- **Золотое сечение** (`Golden`, разд. 10.2). Новая точка ставится на долю 0.382 большего из отрезков $[a, b]$, $[b, c]$. Одна из старых точек остаётся внутренней, поэтому на каждый шаг нужно одно вычисление f,

а отрезок сокращается ровно в $1/0.618 = \varphi$ раз (рис. 1б, прямая линия). Сходимость линейная: чтобы сжать отрезок 2.618 до $2\,\mathrm{tol}\,|z| \approx 2 \cdot 10^{-8}$, нужно $\ln(1.15 \cdot 10^{8})/\ln\varphi \approx 39$ шагов. В опыте — 41.

- **Метод Брента** (`Brent`, разд. 10.3). Через три лучшие точки проводится парабола, следующей точкой берётся её вершина. Шаг принимается, только если вершина внутри отрезка и шаг меньше половины позапрошлого. Иначе делается шаг золотого сечения. Вблизи гладкого минимума функция почти квадратична, и параболические шаги сходятся сверхлинейно. Из 14 итераций 9 были параболическими, 5 — золотыми.

Таблица 1. Минимум $f(z)$: свои реализации и `scipy.optimize.minimize_scalar` с тем же начальным отрезком.

метод	z*	f(z*)	|z − z*|	итераций	вычислений f
золотое сечение (своё)	0.3803215292	0.3286036575	3.4e-10	41	43
Брент (своё)	0.3803215288	0.3286036575	4.3e-11	14	15
золотое сечение (SciPy)	0.3803215280	0.3286036575	8.1e-10	41	46
Брент (SciPy)	0.3803215288	0.3286036575	3.9e-11	14	17

Свои реализации совпадают с SciPy по числу итераций: 41 и 14 (это проверяет тест). Брент тратит в 3 раза меньше вычислений f.

Предел точности. Вблизи минимума $f(z) \approx f(z^*) + \frac{1}{2}f''(z^*)(z - z^*)^2$. Значения f в точках, отстоящих от z^* меньше чем на

$$\delta z \approx \sqrt{2\varepsilon_{\text{маш}}|f(z^*)|/f''(z^*)} = \sqrt{2 \cdot 2.2 \cdot 10^{-16} \cdot 0.329/36.8} \approx 2 \cdot 10^{-9},$$

в арифметике двойной точности неразличимы ((10.1.2) в [2]). Поэтому допуск по умолчанию $\mathrm{tol} = 3 \cdot 10^{-8} \approx \sqrt{\varepsilon_{\text{маш}}}$. Табл. 2 это подтверждает: при уменьшении tol ниже 10^{-8} число вычислений растёт, а ошибка остаётся на уровне 10^{-10}–10^{-9}. Если она падает ниже δz, это случайность, а не гарантия.

Таблица 2. Допуск, ошибка и число вычислений f.

tol	золотое сечение: |z − z*|	вычислений f	Брент: |z − z*|	вычислений f
1e-2	2.7e-4	15	1.6e-3	9
1e-3	5.1e-6	19	2.8e-5	11
1e-4	5.1e-6	24	9.9e-6	12
1e-5	8.2e-7	29	1.0e-6	13
1e-6	4.6e-8	34	1.9e-8	14
1e-7	2.4e-9	39	1.9e-8	14
3e-8	2.4e-9	41	4.3e-11	14
1e-9	5.9e-11	48	4.3e-11	18
1e-10	5.9e-11	53	7.6e-10	24
1e-12	5.9e-11	62	7.9e-10	34

Начальные точки (табл. 3). Из любых точек, где f заметно меняется, `mnbrak` находит отрезок с минимумом, и оба метода приходят в z^*. Даже старт $(2, 3)$ работает: там f отличается от 1 на 10^{-9}. Старт $(5, 6)$ — пример отказа. Там $e^{-10(z-0.65)^2} < 10^{-80}$, и в машинной арифметике $f(5) = f(6) = f(7.6) = 1$ ровно. Направления спуска нет, «отрезок» $(5, 6, 7.6)$ минимума не содержит, и методы возвращают произвольную точку. Методы одномерного поиска не отличают плато от минимума. Начальный отрезок нужно выбирать там, где функция меняется. То же верно для градиентных методов на плато (раздел 2.3).

Таблица 3. Поиск отрезка из разных начальных точек.

начальные точки	отрезок (a, b, c)	вычислений f (mnbrak)	Брент: z	золотое сечение: z
0, 1	0, 1, 2.618	3	0.38032153	0.38032153
0.6, 0.7	0.1764, 0.4382, 0.6	4	0.38032153	0.38032153
-3, -2	-2, -0.382, 2.236	4	0.38032153	0.38032153
2, 3	-2.236, 0.382, 2	4	0.38032153	0.38032153
5, 6	5, 6, 7.618	3	7.61803378	5.00000008

2. Задача 2: классический градиентный спуск

Алгоритм — лекция 6, [1, разд. 4.3]: $w_{j+1} = w_j - \varepsilon D_w J(w_j)$, градиент по всей выборке, остановка при $\left\|D_w J\right\| < \delta = 10^{-6}$ (не позже 10^5 итераций).

Численный градиент [2, разд. 5.7]. Производные вычисляются центральной разностью

$$\frac{\partial J}{\partial w_k} \approx \frac{J(w + h_k e_k) - J(w - h_k e_k)}{2h_k}, \qquad h_k = \varepsilon_{\text{маш}}^{1/3} \max(|w_k|, 1) \approx 6 \cdot 10^{-6} \max(|w_k|, 1).$$

Такой шаг уравновешивает погрешность усечения $\sim h^2 J'''$ и округления $\sim \varepsilon_{\text{маш}} J/h$ (формула (5.7.8) [2]). Шаг делается точно представимым: `h = (w + h) - w` (5.7.4). Все $2p$ значений J вычисляются одним векторизованным вызовом. Сверка с аналитическим градиентом (табл. 4): относительная ошибка не больше $2 \cdot 10^{-10}$. Для обучения это то же самое, что точный градиент. Метод Риддерса (`dfridr`, там же) даёт 10^{-14}–10^{-15}, но требует до 10 пар вычислений J вместо одной, и при обучении не нужен.

Таблица 4. Ошибка численного градиента в 20 случайных точках каждой модели.

модель	max |ошибка|	max отн. ошибка	метод Риддерса: |ошибка| $\partial J/\partial w_1$
1 (линейная)	3.1e-9	2.6e-11	2.1e-14
2 (квадратичная)	6.7e-9	3.4e-11	1.4e-14
3 (сеть ReLU)	1.6e-9	1.7e-10	1.6e-15

2.1. Модели 1 и 2: выбор скорости обучения

Для квадратичной J с гессианом $H = 2A^TA$ (строки A — $(x_i, 1)$ или $(x_i^2, x_i, 1)$) градиент $g_j = H(w_j - w^*)$, и шаг спуска даёт

$$g_{j+1} = (I - \varepsilon H)\, g_j \quad \Rightarrow \quad \left\|g_j\right\| \le \rho^j \left\|g_0\right\|, \qquad \rho = \max_i |1 - \varepsilon\lambda_i|.$$

Отсюда три вывода [1, разд. 4.3.1, 8.2.1]:

- спуск устойчив, только если $\varepsilon < 2/\lambda_{max}$;
- лучшая гарантия — при $\varepsilon = 2/(\lambda_{min} + \lambda_{max})$, тогда $\rho = (\kappa - 1)/(\kappa + 1)$, где $\kappa = \lambda_{max}/\lambda_{min}$ — число обусловленности;
- число итераций $\approx \ln(\left\|g_0\right\|/\delta)/\ln(1/\rho) \approx \frac{\kappa}{2}\ln(\left\|g_0\right\|/\delta)$ растёт пропорционально κ.

Таблица 5. Градиентный спуск при $\varepsilon = 2/(\lambda_{min} + \lambda_{max})$ из начальной точки $w_0 \sim \mathcal{N}(0, 1)$ (зерно 0).

модель	λmin(H)	λmax(H)	κ	2/λmax	ε = 2/(λmin+λmax)	итераций	оценка ⌈ln(δ/‖DJ₀‖)/ln ρ⌉	max |w − w_МНК|	SSE
1 (линейная)	3.994	50.03	12.5	0.03998	0.03702	111	111	1.9e-8	0.19987
2 (квадратичная)	0.410	114.21	278.4	0.01751	0.01745	2 417	2 417	2.7e-8	0.09088

Оба спуска сошлись к решению МНК. Число итераций **в точности** совпало с оценкой: 111 и 2417. При оптимальной ε обе крайние компоненты градиента убывают с одним множителем ρ, и оценка становится точной.

Модель 2 медленнее в 22 раза, потому что у неё $\kappa = 278$. Столбцы x^2, x, 1 на отрезке $[0, 2]$ почти линейно зависимы, и гессиан плохо обусловлен [1, разд. 4.2, 8.2.1]. Вдоль направления с малым $\lambda_{min} = 0.41$ спуск ползёт (рис. 2а, длинный пологий участок). Каждый шаг уменьшает градиент лишь в 1/0.9928 раза.

Таблица 6. Скорость обучения и число итераций; в скобках — оценка $\lceil \ln(\delta / \|g_0\|) / \ln\rho \rceil$.

ε / (2/λmax)	модель 1: ε	ρ	итераций	модель 2: ε	ρ	итераций
0.05	0.00200	0.9920	1 800 (2 203)	0.00088	0.9996	36 627 (48 332)
0.1	0.00400	0.9840	896 (1 097)	0.00175	0.9993	18 310 (24 162)
0.25	0.00999	0.9601	355 (434)	0.00438	0.9982	7 321 (9 660)
0.5	0.01999	0.9202	174 (213)	0.00876	0.9964	3 657 (4 826)
0.9	0.03598	0.8563	93 (114)	0.01576	0.9935	2 029 (2 677)
0.99	0.03958	0.9800	874 (874)	0.01734	0.9929	1 844 (2 433)
1.02	0.04078	1.0400	расходится	0.01786	1.0400	расходится
2/(λmin+λmax): 0.926 и 0.9964	0.03702	0.8521	111 (111)	0.01745	0.9928	2 417 (2 417)

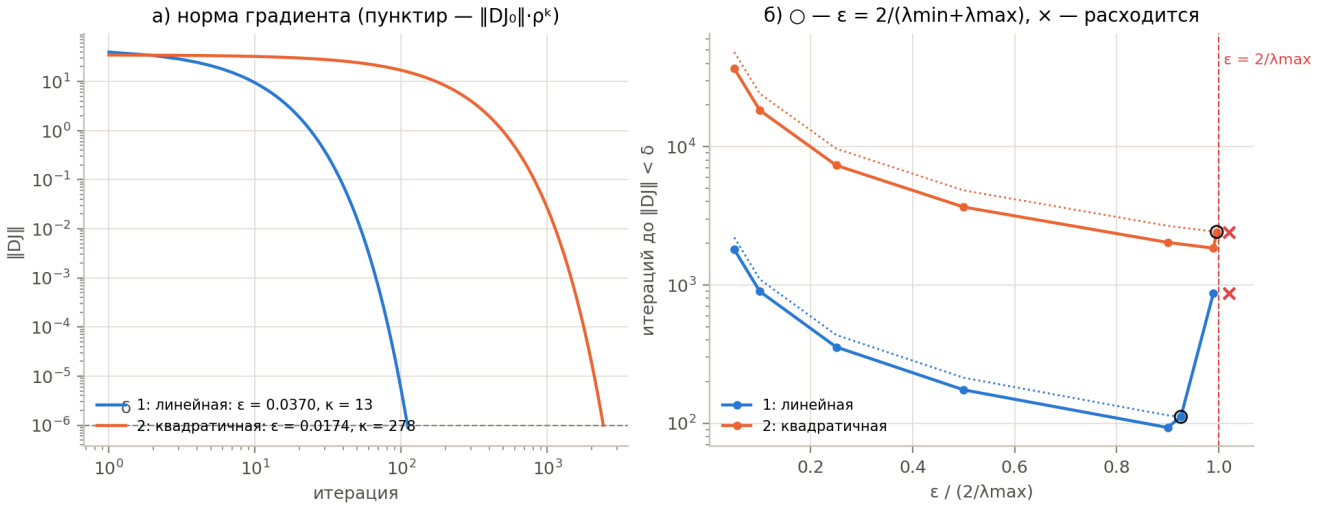


Рис. 2. а) Норма градиента по итерациям при оптимальной ε (пунктир — оценка $\|g_0\|\rho^k$); б) число итераций в зависимости от ε.

Табл. 6 и рис. 2б показывают три режима:

- **Малые ε.** Итераций $\propto 1/\varepsilon$: 1800 при $0.05 \cdot 2/\lambda_{max}$ против 174 при $0.5 \cdot 2/\lambda_{max}$.
- **Предел $\varepsilon \to 2/\lambda_{max}$.** Компонента вдоль λ_{max} начинает колебаться с множителем $1 - \varepsilon\lambda_{max} \to -1$, и для модели 1 число итераций снова растёт до 874.
- **$\varepsilon > 2/\lambda_{max}$.** Спуск расходится, уже при превышении на 2 %.

Оценка по ρ — верхняя. При $0.9 \cdot 2/\lambda_{max}$ итераций даже меньше, чем при «оптимальной» ε: 93 против 111 и 2029 против 2417. Компонента градиента вдоль λ_{min} с самого начала мала ($g = H(w - w^*)$ умножает её на λ_{min}), поэтому важнее быстро погасить компоненту вдоль λ_{max}.

2.2. Найденные зависимости

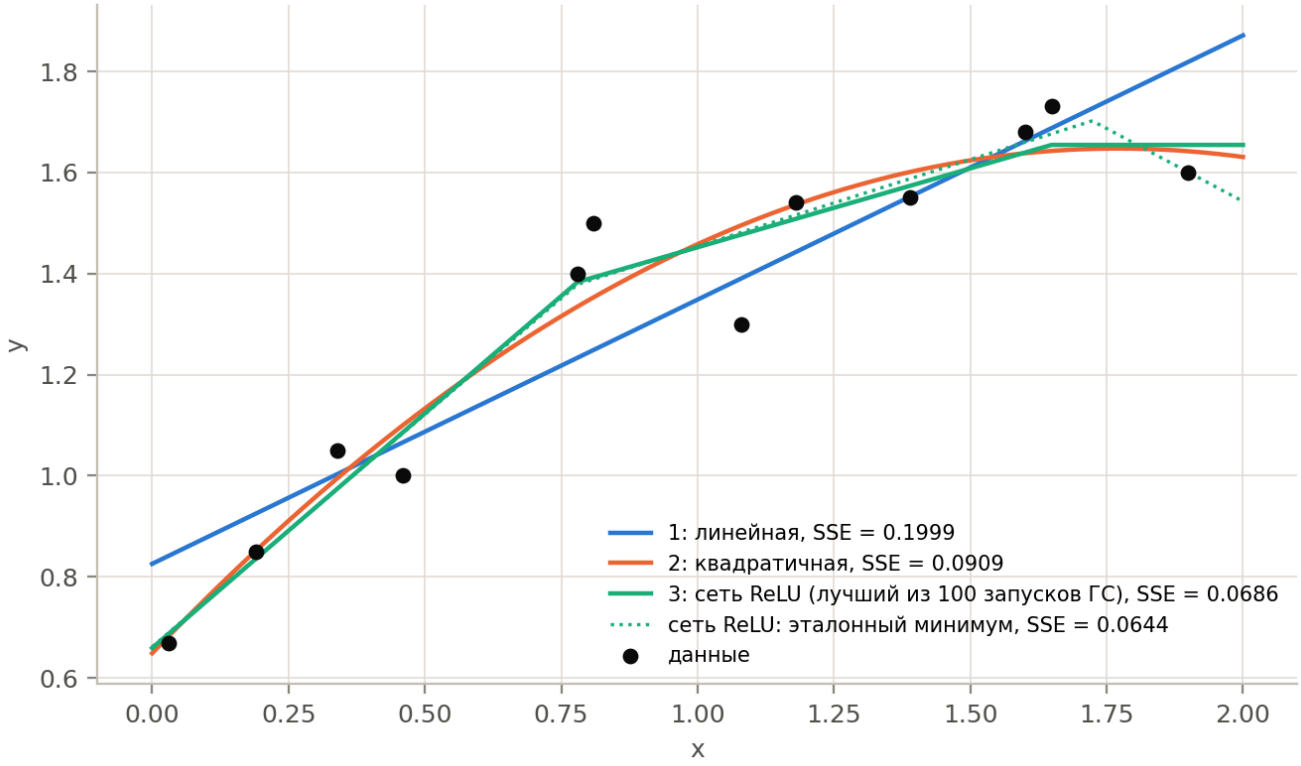


Рис. 3. Данные и модели, обученные градиентным спуском. Для сети ReLU показан лучший из 100 запусков спуска и эталонный глобальный минимум.

Прямая (SSE = 0.200) не описывает насыщения y при больших x. Квадратичная модель (0.091) описывает выпуклую вверх форму. Сеть ReLU строит ломаную: рост, затем меньший рост, затем полка (0.064–0.069). Это лучшее описание обучающей выборки, но ценой 7 параметров на 12 точек (о прогнозе — раздел 5).

2.3. Модель 3: невыпуклая функция потерь

Инициализация. Применена инициализация Xe [1, разд. 8.4]: $w \sim \mathcal{N}(0, 2/n_{\text{вх}})$, смещения скрытых нейронов 0.1, смещение выхода $\bar{y} = 1.32$ («по маргинальной статистике выхода», там же). Если смещение выхода тоже взять 0.1, в **23 %** начальных точек выходной ReLU «мёртв» на всей выборке. Тогда $D_w J = 0$ точно, спуск останавливается на нулевой итерации по критерию $\|DJ\| < \delta$, и $\widehat{y} \equiv 0$. Это плато, а не минимум [1, разд. 6.3.1, 8.2.3], как плато $f \equiv 1$ в задаче 1. При смещении $\bar{y}$ мёртвых начальных точек нет.

Таблица 7. Куда приходит градиентный спуск ($\varepsilon = 0.01$, $\delta = 10^{-6}$, не больше $5 \cdot 10^4$ итераций) из 100 начальных точек.

куда пришёл спуск	SSE	запусков	доля
глобальный минимум	⩽ 0.0651	0	0 %
лучше квадратичной	0.0651–0.0909	15	15 %
между квадр. и линейной	0.0909–0.1979	32	32 %
≈ линейная модель	≈ 0.1999	34	34 %
хуже линейной	прочие	2	2 %
константа $\bar{y}$	≈ 1.3352	15	15 %
мёртвая сеть ($\hat{y} \equiv 0$)	≈ 22.32	2	2 %

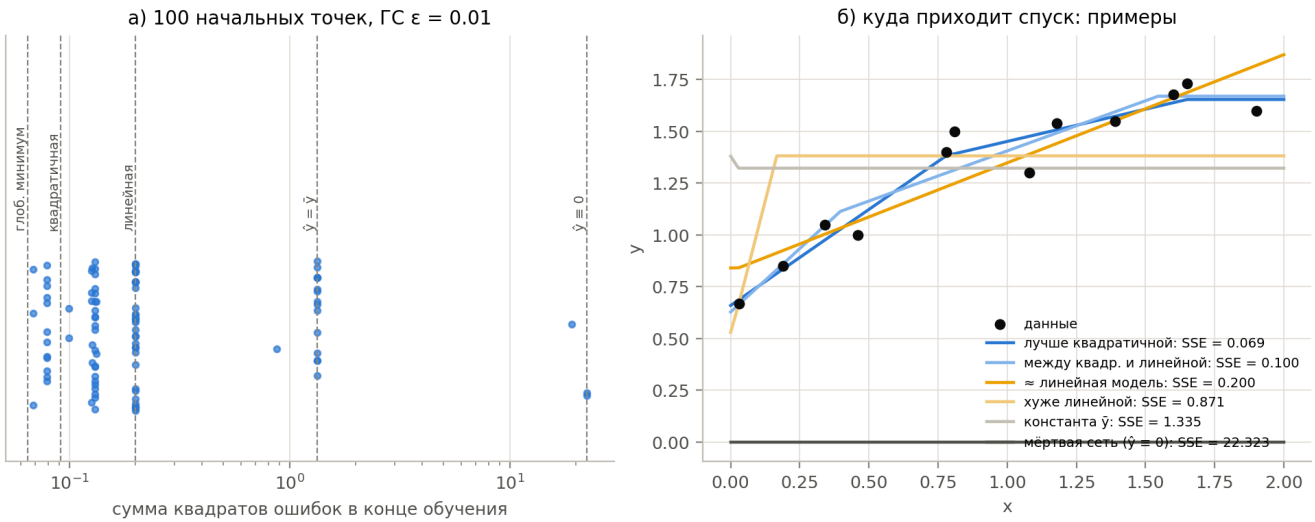


Рис. 4. а) Сумма квадратов ошибок в конце обучения для 100 начальных точек; б) примеры найденных зависимостей разного типа.

84 запуска остановились по критерию $\|DJ\| < \delta$ (медиана — 316 итераций), 16 не успели за $5 \cdot 10^4$. Остановка по малому градиенту **не означает** глобального минимума. Лекция 6 предупреждает: «мы можем найти только некий локальный минимум». Типы конечных точек:

- **Ломаная из трёх участков** (15 %, лучшая — SSE = 0.0686, эталон — 0.0644). Минимумов такого типа много: излом может оказаться между разными соседними точками выборки. Эталонный поиск нашёл значения 0.0644, 0.0686, 0.0778, 0.0788, 0.0995, …
- **Ломаная из двух участков** (SSE от 0.091 до 0.198, 32 %). Один нейрон работает линейно на всей выборке.
- **Прямая** (34 %). Оба нейрона активны везде или один выключен. Сеть вырождается в модель 1, SSE = 0.1999.
- **Константа** $\bar{y}$ (15 %). Оба скрытых нейрона погасли на всей выборке, градиент по их весам равен нулю.
- **Мёртвая сеть** (2 %). Выходной ReLU погас уже *в ходе* обучения.

Ни один из 100 запусков не дошёл до глобального минимума. В эталонном минимуме $w_{22} = -7.1$ и $\sum w^2 = 52$: веса «недопустимо большие» (лекция 6), к этому вернёмся в задаче 5.

3. Задача 3: СГС с мини-пакетами

Алгоритм (лекция 6, «Минипакеты»; [1, разд. 8.1.3, 8.3.1]). На каждом шаге градиент считается по случайному мини-пакету B из m наблюдений. Пакеты выбираются без повторений, пока не будет обойдена вся выборка (эпоха), затем выборка перемешивается заново (это проверяет тест). Чтобы скорость ε имела один смысл при любом m, по пакету вычисляется *несмещённая* оценка той же функции потерь:

$$J_B(w) = \frac{n}{m} \sum_{i \in B} (y_i - \widehat{y}_i)^2, \qquad \mathbb{E}\, D_w J_B = D_w J.$$

Размеры пакета — делители 12: $m = 1, 2, 3, 4, 6, 12$ (при $m = 12$ это задача 2). **Цена эпохи одинакова при любом m:** численный градиент по пакету стоит $2p \cdot m$ вычислений невязки, за эпоху — $2p \cdot n$. Поэтому сравнение по эпохам — это сравнение при равных вычислениях. Меньший пакет даёт за ту же цену больше обновлений ($12/m$), но каждое — по шумной оценке градиента.

Таблица 8. Модель 1: СГС с мини-пакетами (20 запусков, 2000 эпох). Уровень шума — среднее $(J - J^*)/J^*$ за последние 10 % эпох; «начиная с эпохи» — эпоха, после которой $(J - J^*)/J^*$ остаётся ниже 10^{-3} до конца.

m	обновлений за эпоху	граница ε (худший пакет)	ε = 0.0370 (из задачи 2): (J−J*)/J*	ε = 0.01: уровень шума (J−J*)/J*	⩽ 10^{-3} начиная с эпохи	ε = 0.01/(1 + e/200): (J−J*)/J*	⩽ 10^{-3} начиная с эпохи
1	12	0.0181	1.0e2	3.7e-1	не дост.	4.8e-4	2 000
2	6	0.0200	1.3e0	1.2e-1	не дост.	1.0e-4	1 676
3	4	0.0210	4.8e-1	4.8e-2	не дост.	2.4e-5	979
4	3	0.0225	5.1e-1	2.2e-2	не дост.	8.6e-6	678
6	2	0.0260	8.3e-1	6.4e-3	не дост.	1.8e-6	343
12	1	0.0400	2.1e-16	2.8e-16	99	2.8e-16	128

Таблица 9. Модель 2: то же.

m	обновлений за эпоху	граница ε (худший пакет)	ε = 0.0174 (из задачи 2): (J−J*)/J*	ε = 0.0025: уровень шума (J−J*)/J*	⩽ 10^{-3} начиная с эпохи	ε = 0.0025/(1 + e/200): (J−J*)/J*	⩽ 10^{-3} начиная с эпохи
1	12	0.0047	∞, разошлись 20	1.1e-1	не дост.	7.3e-5	1 674
2	6	0.0058	∞, разошлись 15	2.2e-2	не дост.	4.7e-3	не дост.
3	4	0.0064	3.9e0	6.7e-3	не дост.	3.6e-2	не дост.
4	3	0.0074	4.5e0	2.7e-3	2 000	9.8e-2	не дост.
6	2	0.0095	1.4e0	1.4e-3	не дост.	2.7e-1	не дост.
12	1	0.0175	5.9e-11	3.9e-2	не дост.	7.2e-1	не дост.

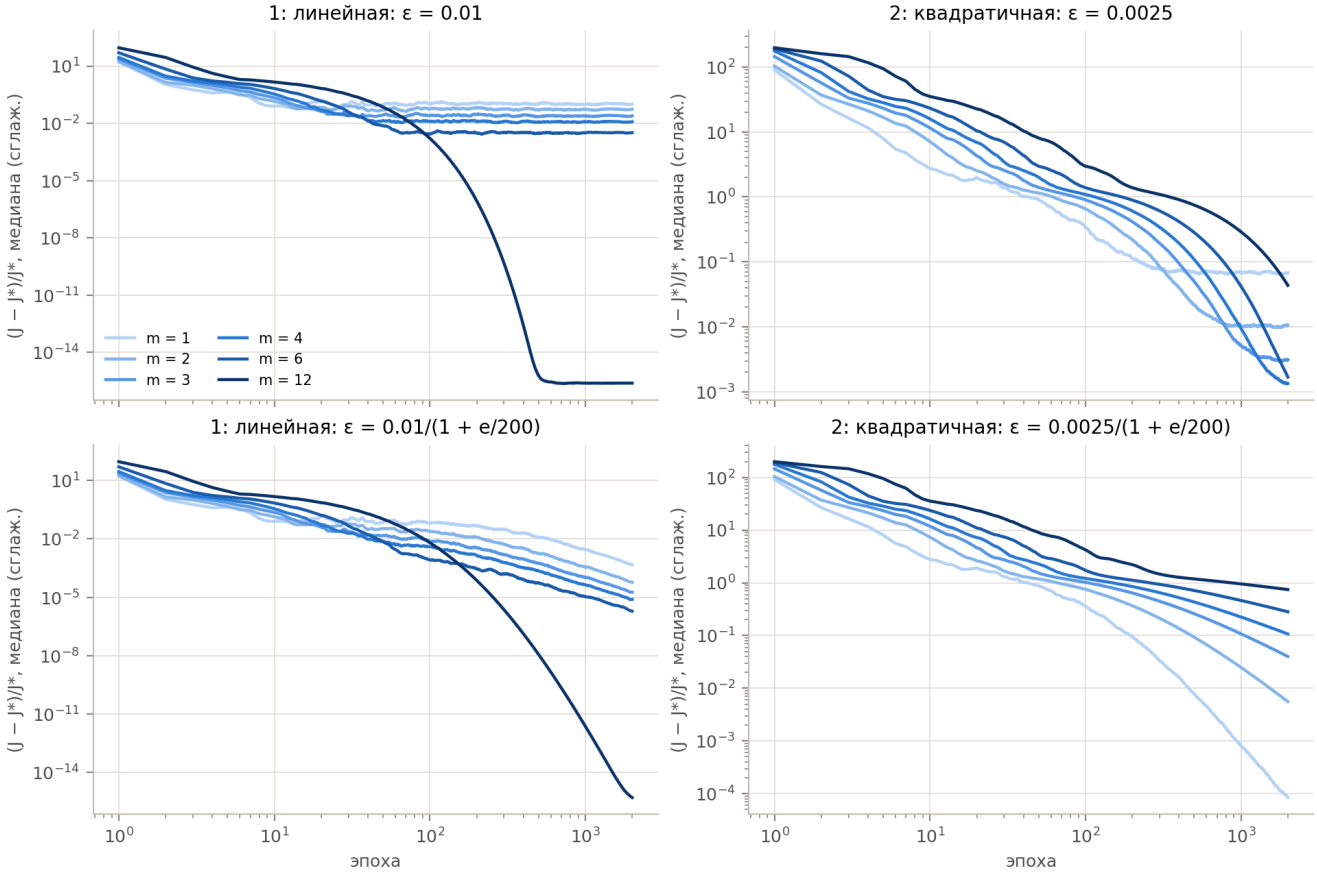


Рис. 5. Медиана $(J - J^*)/J^*$ по 20 запускам (сглажена в логарифмическом масштабе); сверху — постоянная скорость, снизу — убывающая.

Выводы:

1. **Скорость из задачи 2 для мини-пакетов слишком велика.** Гессиан оценки по пакету $\frac{2n}{m} A_B^T A_B$ имеет большее λ_{max}, чем полный. Граница устойчивости для худшего пакета (3-й столбец) при $m = 1$ вдвое ниже для модели 1 и вчетверо — для модели 2. С $\varepsilon = 0.0174$ из задачи 2 СГС для модели 2 рас-

ходится при $m = 1$ (20 из 20) и $m = 2$ (15 из 20). Для модели 1 при $m = 1$ ошибка в 100 раз больше минимума. Поэтому ниже взята общая скорость, устойчивая для всех m: половина границы при $m = 1$, то есть 0.01 и 0.0025.

2. **В начале меньший пакет быстрее, но останавливается на шуме.** Рис. 5 сверху: за первые 100 эпох кривые с $m = 1$ ниже всех, потому что обновлений в 12 раз больше. Затем каждая выходит на свой уровень шума, тем выше, чем меньше m: для модели 1 от 0.37 при $m = 1$ до $6 \cdot 10^{-3}$ при $m = 6$. Только полный пакет сходится до 10^{-16}. В окрестности минимума средний градиент мал, а разброс градиентов по пакетам — нет. СГС «не сходится в классическом смысле» (лекция 6). Разброс оценки при выборе без повторений $\propto (n - m)/(m(n - 1))$, при $m = n$ он ноль. Для модели 2 при $\varepsilon = 0.0025$ полный спуск за 2000 эпох доходит лишь до $4 \cdot 10^{-2}$: у этой модели $\kappa = 278$, и малая скорость тормозит. Здесь меньшие пакеты выигрывают, при $m = 4$–6 — $(1.4$–$2.7) \cdot 10^{-3}$.
3. **Уменьшение скорости убирает шум** (рис. 5 снизу). При $\varepsilon_e = \varepsilon_0/(1 + e/\tau)$ выполнены условия $\sum \varepsilon = \infty$, $\sum \varepsilon^2 < \infty$ [1, (8.12)–(8.13)]. Для модели 1 ошибка в конце упала с уровня шума до $4.8 \cdot 10^{-4}$ ($m = 1$) и $1.8 \cdot 10^{-6}$ ($m = 6$) и продолжает падать. Но уменьшение — не бесплатное: $\sum_e \varepsilon_e$ за 2000 эпох вчетверо меньше, чем при постоянной скорости. Для медленной модели 2 это критично: при $m \geq 2$ ошибка с уменьшением **хуже**, чем без него. Выиграл только $m = 1$, у него больше всего обновлений: $7.3 \cdot 10^{-5}$. Закон уменьшения нужно согласовывать с обусловленностью задачи.
4. **Модель 3** (табл. 10). Доля запусков лучше квадратичной модели — 10–18 % при любом m и любом законе скорости. Глобального минимума не нашёл ни один запуск. Разница между строками — в пределах статистической погрешности: при 100 запусках и доле около 15 % стандартная ошибка ±3.6 п. п. Лекция 6 говорит, что СГС «в целом позволяет избегать локальных минимумов». Здесь это не проявилось. Минимумы сети разделены переключением нейронов (включён/выключен на части выборки), и шума мини-пакетов на 12 точках не хватает, чтобы перевести нейрон через такой барьер.

Таблица 10. Модель 3: исходы СГС для разных размеров пакета.

m	ε	глобальный минимум	лучше квадратичной модели	медиана SSE	ŷ = const
1	постоянная	0 %	10 %	0.2026	8 %
1	/(1 + e/300)	0 %	18 %	0.1999	25 %
2	постоянная	0 %	16 %	0.2008	11 %
2	/(1 + e/300)	0 %	15 %	0.1999	20 %
3	постоянная	0 %	18 %	0.1995	16 %
3	/(1 + e/300)	0 %	15 %	0.1999	18 %
4	постоянная	0 %	17 %	0.2000	18 %
4	/(1 + e/300)	0 %	13 %	0.1999	18 %
6	постоянная	0 %	16 %	0.1664	17 %
6	/(1 + e/300)	0 %	14 %	0.1999	17 %
12	постоянная	0 %	14 %	0.1999	17 %
12	/(1 + e/300)	0 %	10 %	0.1999	17 %

4. Задача 4: импульс Нестерова и Adam

Формулы лекции 6 ($g = D_w J_B$):

$$\text{Нестеров:}\quad m_{j+1} = \beta m_j + (1 - \beta)\, g(w_j - \varepsilon\beta m_j), \qquad w_{j+1} = w_j - \varepsilon m_{j+1};$$

$$\text{Adam:}\quad m_{j+1} = \beta m_j + (1 - \beta)g, \quad v_{j+1} = \gamma v_j + (1 - \gamma)g^2, \quad w_{j+1} = w_j - \varepsilon \frac{m_{j+1}/(1 - \beta^{j+1})}{\sqrt{v_{j+1}/(1 - \gamma^{j+1})} + \varepsilon},$$

$\beta = 0.9$, $\gamma = 0.999$, $\varepsilon = 10^{-8}$. Оба метода реализованы по формулам; тест сверяет два шага с ручным вычислением.

Замечание о записи импульса. В лекции у градиента стоит множитель $(1-\beta)$, у Гудфеллоу [1, алгоритм 8.3] его нет: $v \leftarrow \alpha v - \varepsilon' g(\theta + \alpha v)$. Записи эквивалентны при $v = -\varepsilon m$ и $\varepsilon' = (1-\beta)\varepsilon$. Поэтому «лекционная» ε для Нестерова в $1/(1-\beta) = 10$ раз больше той же по смыслу величины у Гудфеллоу. Это объясняет, почему наилучшие ε для Нестерова (0.1–0.2) больше границы $2/\lambda_{max}$ для простого спуска. Первый шаг Adam после коррекции смещения — ровно $\varepsilon \cdot \mathrm{sign}(g)$ по каждой координате (это проверяет тест).

Постановка сравнения. Для каждой модели, метода и размера пакета $m \in \{1, 4, 12\}$ скорость ε выбиралась по сетке $0.0005, 0.001, 0.002, 0.005, \ldots, 0.5$. Для $m < 12$ дополнительно пробовался закон $\varepsilon_0/(1 + e/\tau)$. Критерий для моделей 1–2 — медиана ошибки в конце (10 зёрен), при равенстве — скорость достижения 10^{-6}. Для сети — доля запусков лучше квадратичной модели (100 начальных точек). Затем выбранные настройки прогнаны на 20 новых зёрнах (табл. 11, 12). Без подбора скорости сравнение методов бессмысленно: у каждого своя «естественная» шкала ε [1, разд. 8.5.4, 11.4.1].

Таблица 11. Модели 1 и 2: лучшие настройки методов. «Начиная с эпохи» — эпоха, после которой $(J - J^*)/J^*$ остаётся ниже порога до конца; «не дост.» — у большинства запусков не достигнуто.

модель	метод	m	ε	(J−J*)/J* в конце	⩽ 10^{-3} начиная с эпохи	⩽ 10^{-6} начиная с эпохи	дошли до 10^{-6}
1 (линейная)	ГС / СГС	1	0.005/(1 + e/10)	4.8e-6	70	не дост.	1 из 20
1 (линейная)	ГС / СГС	4	0.02/(1 + e/10)	3.6e-6	70	не дост.	2 из 20
1 (линейная)	ГС / СГС	12	0.02	4.9e-16	48	90	20 из 20
1 (линейная)	Нестеров	1	0.005/(1 + e/10)	1.7e-5	104	не дост.	2 из 20
1 (линейная)	Нестеров	4	0.02/(1 + e/10)	6.9e-6	43	не дост.	4 из 20
1 (линейная)	Нестеров	12	0.2	2.8e-16	38	80	20 из 20
1 (линейная)	Adam	1	0.05/(1 + e/10)	1.2e-4	290	не дост.	0 из 20
1 (линейная)	Adam	4	0.2/(1 + e/10)	4.7e-5	228	не дост.	0 из 20
1 (линейная)	Adam	12	0.2	1.5e-12	110	178	19 из 20
2 (квадратичная)	ГС / СГС	1	0.005/(1 + e/70)	4.6e-5	1 300	не дост.	1 из 20
2 (квадратичная)	ГС / СГС	4	0.02/(1 + e/70)	3.5e-5	1 316	не дост.	0 из 20
2 (квадратичная)	ГС / СГС	12	0.01	1.4e-7	921	1 761	18 из 20
2 (квадратичная)	Нестеров	1	0.005/(1 + e/70)	8.6e-5	1 880	не дост.	0 из 20
2 (квадратичная)	Нестеров	4	0.02/(1 + e/70)	3.2e-5	1 012	не дост.	0 из 20
2 (квадратичная)	Нестеров	12	0.1	-5.3e-16	62	136	20 из 20
2 (квадратичная)	Adam	1	0.02/(1 + e/70)	2.4e-4	1 994	не дост.	0 из 20
2 (квадратичная)	Adam	4	0.05/(1 + e/70)	3.3e-4	1 990	не дост.	0 из 20
2 (квадратичная)	Adam	12	0.1	3.1e-16	358	518	19 из 20

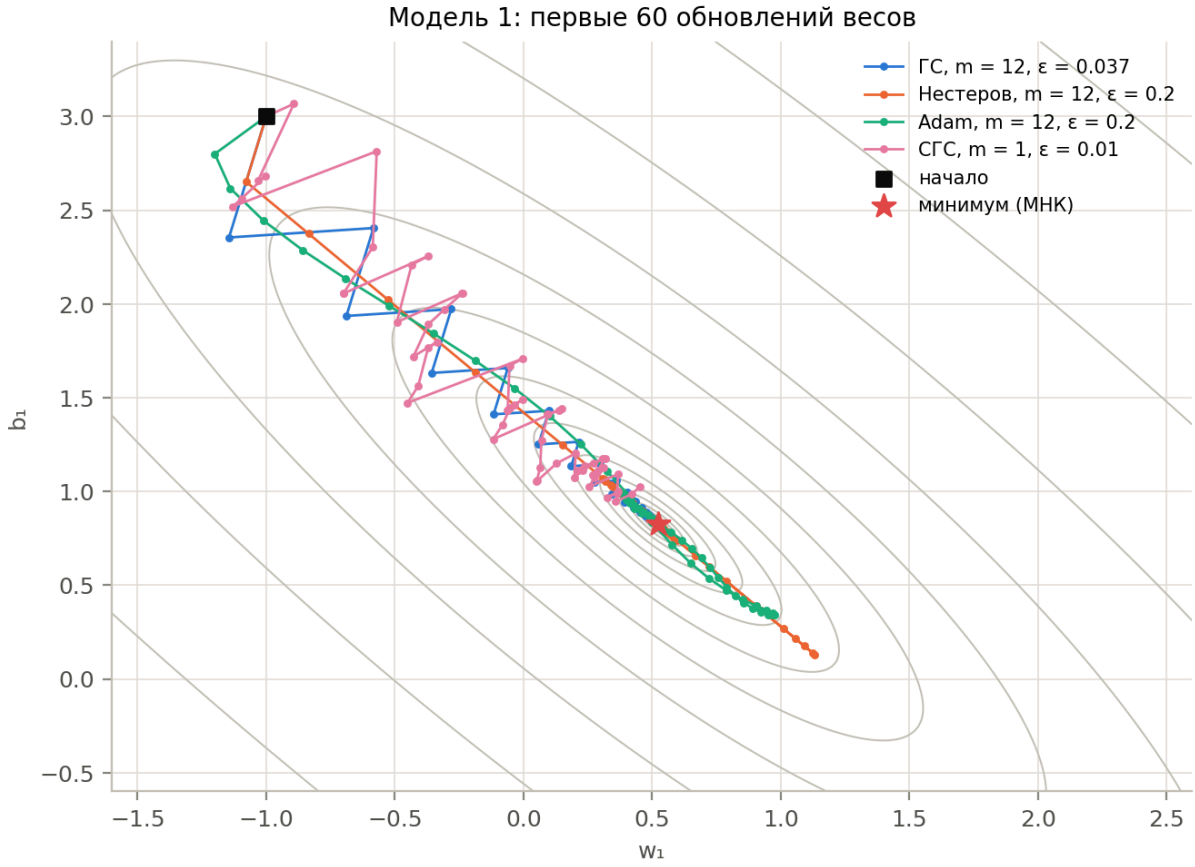


Рис. 6. Первые 60 обновлений весов модели 1 на линиях уровня $J(w_1, b_1)$.

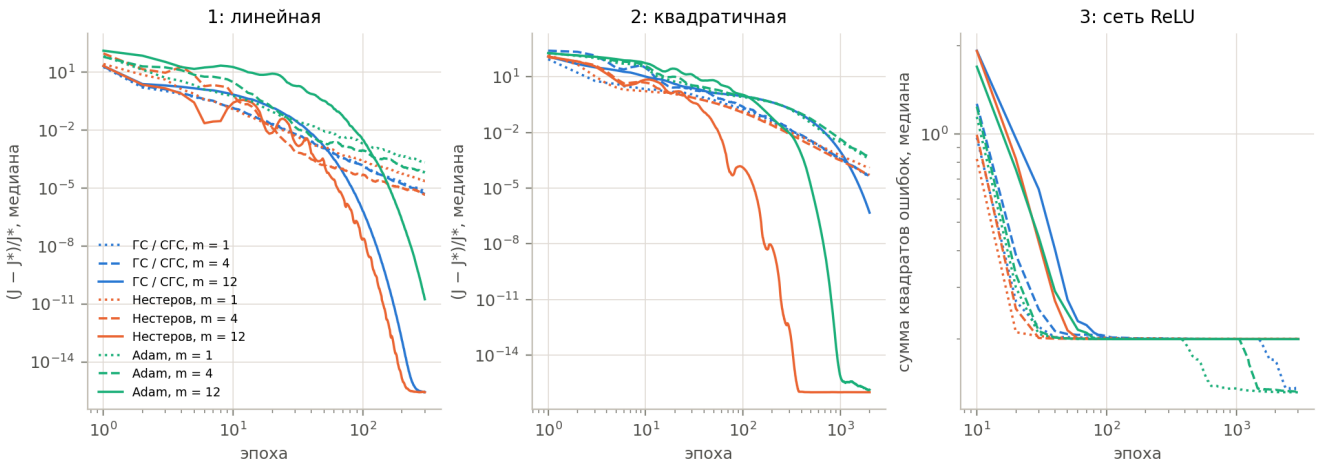


Рис. 7. Медианные кривые обучения выбранных настроек: сплошные — $m = 12$, штриховые — $m = 4$, пунктир — $m = 1$.

Полный пакет ($m = 12$):

- **Нестеров — лучший.** Для модели 2 ошибка $\leq 10^{-6}$ держится с эпохи 136, у спуска — с 1761 (13× медленнее), у Adam — с 518. Импульс накапливает шаги вдоль пологого направления (малое λ_{min}) и гасит колебания вдоль крутого. Для квадратичной функции это заменяет зависимость числа итераций от κ на $\sqrt{\kappa}$ [1, разд. 8.3.2–8.3.3; 4]. На рис. 6 спуск идёт зигзагом поперёк узкой долины, а Нестеров — почти по её дну.
- **Adam** частично компенсирует плохую обусловленность: делит шаг каждой координаты на $\sqrt{v}$. Но шаг Adam при постоянной ε имеет порядок ε вблизи минимума, и метод колеблется вокруг него (лекция 6, «алгоритм нормировки … колеблется»). Убывающий вес импульса это гасит, но медленно: модель 1 — 178 эпох до 10^{-6} против 80 у Нестерова.

Мини-пакеты ($m = 1, 4$). Все три метода упираются в шум, и лучшие настройки в сетке — с убывающей скоростью. За отведённые эпохи медианная ошибка 10^{-6}–10^{-4}, порог 10^{-6} держат лишь единицы из 20 запусков. Импульс шума не убирает: он усредняет градиенты, но за $\sim 1/(1-\beta) = 10$ шагов, а это меньше одной эпохи при $m = 1$. Adam с мини-пакетами хуже остальных: $5 \cdot 10^{-5}$–$3 \cdot 10^{-4}$ против $4 \cdot 10^{-6}$–$9 \cdot 10^{-5}$ у спуска и Нестерова. Нормировка $m/\sqrt{v}$ делает шаг порядка ε *независимо* от величины градиента, и у минимума, где средний градиент мал, а шум — нет, Adam шагает в основном по шуму.

Таблица 12. Модель 3: исходы при лучших настройках методов (100 начальных точек).

метод	m	ε	глобальный минимум	лучше квадратичной модели	медиана SSE	ŷ = const
ГС / СГС	1	0.003	0 %	22 %	0.1331	14 %
ГС / СГС	4	0.01	0 %	17 %	0.2000	18 %
ГС / СГС	12	0.01	0 %	14 %	0.1999	17 %
Нестеров	1	0.01	0 %	19 %	0.2007	16 %
Нестеров	4	0.03	0 %	17 %	0.1999	22 %
Нестеров	12	0.03	0 %	13 %	0.1999	23 %
Adam	1	0.01	0 %	37 %	0.1314	13 %
Adam	4	0.03	0 %	29 %	0.1329	16 %
Adam	12	0.03	4 %	22 %	0.1999	15 %

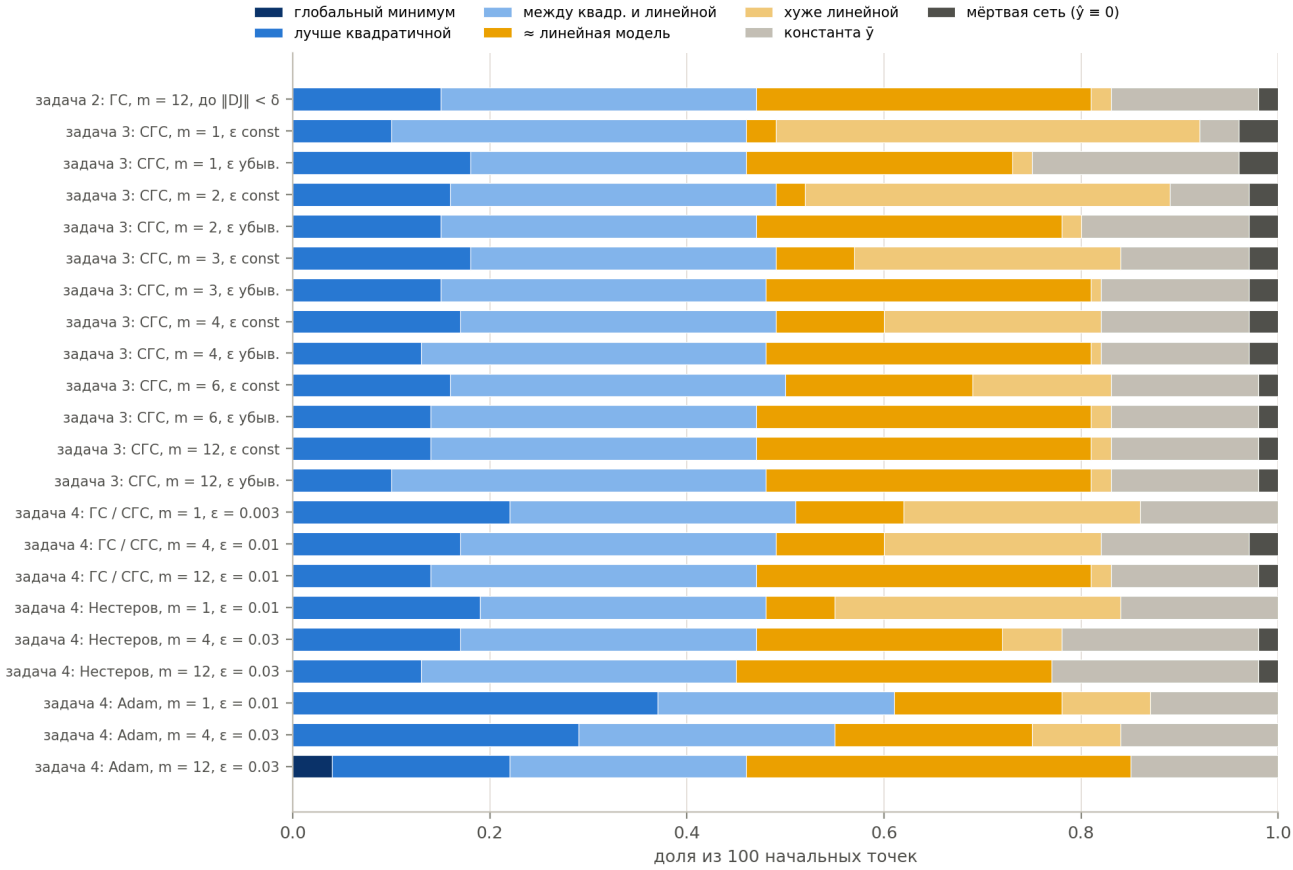


Рис. 8. Модель 3: доли типов конечных точек во всех опытах задач 2–4.

Сеть ReLU. Здесь важна не скорость, а то, *в какой* минимум придёт обучение. **Adam лучше остальных:** лучше квадратичной модели — 37 % при $m = 1$, 29 % при $m = 4$, 22 % при $m = 12$ (из них 4 % — глобальный минимум). У спуска и Нестерова — 13–22 %. Разница 37 % против 22 % больше двух стандартных ошибок ($\approx \pm 6$ п. п.). Вероятное объяснение: у почти выключенного нейрона градиент по его весам мал, простой спуск и Нестеров едва его сдвигают, а Adam нормирует шаг и двигает такие веса со скоростью

$\sim\varepsilon$. Так он чаще выводит нейрон на нужный участок x. Доля константы и мёртвых сетей у всех методов одинакова: 13–23 %. Если нейроны погасли на всей выборке, градиент *точно* ноль, и нормировка не помогает.

Сравнение задач 2, 3 и 4

	модель 1	**модель 2**	**модель 3**
ГС, полный пакет (задача 2)	сходится, 111 итераций	сходится, но медленно (2417, $\kappa = 278$)	локальные минимумы; лучше квадратичной — 14–15 %
СГС, мини-пакеты (задача 3)	быстрее в начале, затем шум; нужно уменьшать ε	при ε из задачи 2 расходится; при меньшей — быстрее полного в начале	10–18 %, от m не зависит
Нестеров (задача 4)	лучший при $m = 12$	лучший при $m = 12$: в 13 раз быстрее спуска	13–19 %
Adam (задача 4)	хорош при $m = 12$, худший при малых m	второй при $m = 12$	**лучший: 22–37 %**

Главные выводы:

1. На выборке из 12 точек **полный пакет выгоднее мини-пакетов.** Преимущество СГС — цена обновления не зависит от n [1, разд. 8.1.3]. Оно проявляется при больших выборках, а здесь эпоха и так дешёвая. Шум мини-пакетов приходится гасить уменьшением скорости, и за то же число эпох СГС приходит к менее точному решению.
2. **Выбор метода важнее размера пакета.** Для плохо обусловленной выпуклой задачи нужен импульс, для невыпуклой сети — адаптивный шаг (Adam).
3. Во всех задачах **скорость обучения — главный гиперпараметр.** Она ограничена сверху устойчивостью ($2/\lambda_{max}$ для полного пакета, меньше для мини-пакетов), а снизу — бюджетом итераций.

5. Задача 5*: квадратичный штраф

К функции потерь добавлен штраф Тихонова на **веса** (лекция 6, «L^2-регуляризация»; [1, разд. 7.1.1]):

$$\tilde{J}(w) = \sum_i (y_i - \widehat{y}_i)^2 + \lambda \sum_{k \in \text{веса}} w_k^2.$$

Смещения $b_1, b_{11}, b_{12}, b_{21}$ не штрафуются. Штраф на смещение мешал бы сдвинуть зависимость по вертикали, но не делал бы её глаже. При мини-пакетах штраф входит в каждую оценку $\tilde{J}_B$ целиком. Для моделей 1 и 2 минимум точный — гребневая регрессия $(A^TA + \lambda D)w = A^Ty$, где D — диагональная маска весов. Для сети — лучший из многократного поиска Нелдера — Мида и 100 запусков Adam. Качество прогноза оценивалось скользящим контролем (LOO): каждая точка прогнозируется моделью, обученной на остальных 11. Для сети в каждом из 12 обучений брался лучший из 30 запусков Adam.

Таблица 13. Модели 1 и 2: путь регуляризации (точное решение) и число итераций спуска при $\varepsilon = 2/(\lambda_{min} + \lambda_{max})$.

λ	мод. 1: w_1	SSE	LOO	мод. 2: w_1	w_2	b_1	SSE	LOO	к	итераций ГС
0	0.5222	0.1999	0.3076	-0.3181	1.1268	0.6491	0.0909	0.1449	278	2 417
0.001	0.5221	0.1999	0.3076	-0.3159	1.1222	0.6506	0.0909	0.1453	277	2 406
0.003	0.5219	0.1999	0.3075	-0.3114	1.1131	0.6536	0.0909	0.1460	275	2 385
0.01	0.5210	0.1999	0.3073	-0.2963	1.0827	0.6637	0.0914	0.1494	267	2 314
0.03	0.5185	0.1999	0.3069	-0.2578	1.0048	0.6896	0.0950	0.1636	246	2 133
0.1	0.5100	0.2005	0.3060	-0.1606	0.8080	0.7551	0.1192	0.2270	193	1 675
0.3	0.4871	0.2050	0.3087	-0.0272	0.5353	0.8475	0.1882	0.3559	120	1 042
1	0.4211	0.2425	0.3552	0.0917	0.2805	0.9410	0.2907	0.4925	53	457
3	0.3035	0.3990	0.5592	0.1338	0.1558	1.0070	0.3632	0.5524	22	191

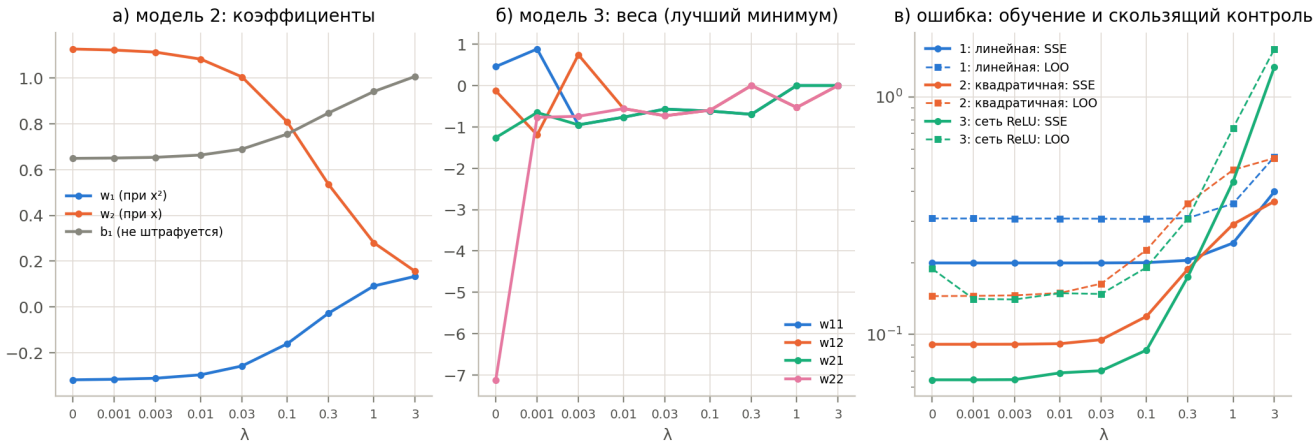


Рис. 9. а) Коэффициенты модели 2 и б) веса сети ReLU в зависимости от λ; в) ошибка на обучающей выборке и при скользящем контроле.

Модели 1 и 2.

- **Веса уменьшаются, смещение растёт.** Смещение компенсирует уменьшение наклона, чтобы средний прогноз остался равен $\bar{y}$. При $\lambda \to \infty$ модель вырождается в константу $\bar{y}$.
- **SSE растёт** — это цена штрафа. Квадратичная модель при $\lambda = 0.3$ почти сравнялась с прямой без штрафа (0.188 против 0.200).
- **Обусловленность улучшается.** Штраф добавляет 2λ к собственным числам гессиана по весам [1, разд. 7.1.1]: κ модели 2 падает с 278 до 193 при $\lambda = 0.1$ и до 22 при $\lambda = 3$. Итераций спуска — с 2417 до 1675 и 191. Штраф сильнее всего сжимает компоненты вдоль собственных векторов с малыми λ_i, то есть плохо определяемые данными комбинации весов.
- **Прогноз не улучшается.** Для модели 1 LOO почти не меняется: минимум 0.3060 при $\lambda = 0.1$ против 0.3076 без штрафа. Для модели 2 LOO монотонно растёт с λ. Три параметра на 12 точек не переобучаются, и штраф лишь смещает оценку. По LOO квадратичная модель (0.145) вдвое лучше прямой (0.308).

Таблица 14. Модель 3: лучший найденный минимум $\tilde{J}$ при разных λ.

λ	SSE	J̃	Σw²	w₁₁; w₁₂	w₂₁; w₂₂	Adam: доля дошедших до J̃*	LOO
0	0.0644	0.0644	52.42	0.46; -0.13	-1.26; -7.11	5 %	0.1889
0.001	0.0644	0.0676	3.22	0.88; -1.19	-0.65; -0.77	3 %	0.1411
0.003	0.0645	0.0733	2.92	-0.95; 0.74	-0.95; -0.74	3 %	0.1403
0.01	0.0689	0.0868	1.80	-0.77; -0.56	-0.77; -0.56	8 %	0.1491
0.03	0.0704	0.1219	1.72	-0.57; -0.73	-0.57; -0.73	7 %	0.1480
0.1	0.0860	0.2337	1.48	-0.62; -0.60	-0.62; -0.60	6 %	0.1914
0.3	0.1748	0.4657	0.97	-0.70; 0.00	-0.70; 0.00	43 %	0.3073
1	0.4401	1.0041	0.56	-0.00; -0.53	-0.00; -0.53	88 %	0.7391
3	1.3352	1.3352	0.00	-0.00; 0.00	-0.00; 0.00	100 %	1.5890

Модель 3 — здесь штраф работает иначе и полезнее.

- **Он устраняет вырождение.** ReLU положительно однороден: $\mathrm{ReLU}(ct) = c\,\mathrm{ReLU}(t)$ при $c > 0$. Поэтому замена $(w_{1j}, b_{1j}, w_{2j}) \to (cw_{1j}, cb_{1j}, w_{2j}/c)$ не меняет сеть, и при $\lambda = 0$ минимумов бесконечно много. Эталонный минимум имеет $w_{12} = -0.13$, $w_{22} = -7.11$, $\sum w^2 = 52$. Штраф $c^2 w_{1j}^2 + w_{2j}^2/c^2$ минимален при $|cw_{1j}| = |w_{2j}/c|$. Из всех эквивалентных сетей выбирается та, где **у каждого нейрона входной и выходной веса равны по модулю**. Табл. 14 это показывает: уже при $\lambda = 0.001$ $\sum w^2$ падает с 52 до 3.2 при той же SSE = 0.0644, а при $\lambda \geq 0.003$ $|w_{11}| = |w_{21}|$ и $|w_{12}| = |w_{22}|$ с точностью до двух знаков. Это то самое ограничение «недопустимо больших весов» из лекции, и почти бесплатное.

- **Прогноз улучшается.** LOO падает с 0.189 ($\lambda = 0$) до 0.140 ($\lambda = 0.003$) — уровня квадратичной модели (0.145). У сети 7 параметров на 12 точек, и без штрафа она переобучается: изломы подстраиваются под отдельные точки. При $\lambda \geq 0.3$ — недообучение: при 0.3 один нейрон выключается ($w_{12} = w_{22} = 0$), при 1 остаётся почти прямая, при 3 все веса нулевые, и $\widehat{y} = \bar{y}$.
- **Обучение становится надёжнее при сильном штрафе.** Доля запусков Adam, дошедших до $\tilde{J}^*$, — 3–8 % при $\lambda \leq 0.1$, но 43 % при $\lambda = 0.3$ и 88 % при $\lambda = 1$. Штраф добавляет $2\lambda I$ к гессиану по весам и «выпрямляет» функцию потерь. Но это происходит при тех λ, где модель уже недообучена.

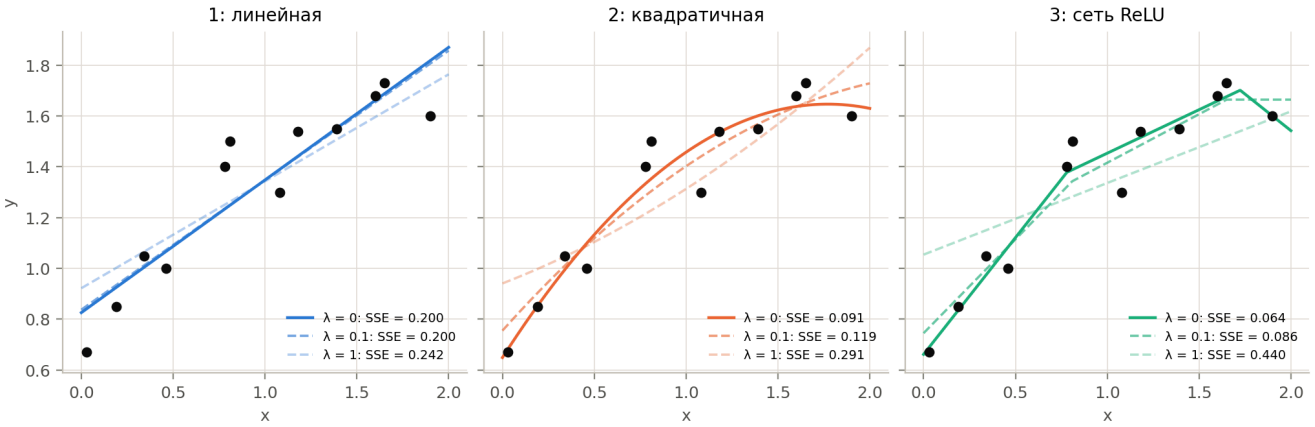


Рис. 10. Зависимости при $\lambda = 0$ (сплошные), 0.1 и 1 (штриховые).

Задачи 2–4 со штрафом ($\lambda = 0.1$, настройки методов — из задачи 4).

Таблица 15. Все методы на функции $\tilde{J}$; w^* — точное решение гребневой регрессии (модели 1–2), $\tilde{J}^*$ — лучший найденный минимум (модель 3).

модель	метод	m	ε	$(\tilde{J}-\tilde{J})/\tilde{J}$, медиана	max|w − w*|, медиана	дошли до 1 % от $\tilde{J}^*$	SSE, медиана	сошлось по δ
1 (линейная)	ГС / СГС	12	0.03688	3.9e-14	2.0e-8	100 %	0.2005	20 из 20
1 (линейная)	ГС / СГС	1	0.005/(1 + e/10)	3.3e-6	3.8e-4	100 %	0.2005	—
1 (линейная)	Нестеров	1	0.005/(1 + e/10)	1.5e-5	3.4e-4	100 %	0.2005	—
1 (линейная)	Нестеров	12	0.2	0	6.3e-13	100 %	0.2005	—
1 (линейная)	Adam	1	0.05/(1 + e/10)	1.1e-4	1.1e-3	100 %	0.2005	—
1 (линейная)	Adam	12	0.2	1.3e-12	1.5e-7	100 %	0.2005	—
2 (квадратичная)	ГС / СГС	12	0.0174	2.4e-14	1.1e-8	100 %	0.1192	20 из 20
2 (квадратичная)	ГС / СГС	1	0.005/(1 + e/70)	4.3e-5	3.4e-3	100 %	0.1186	—
2 (квадратичная)	Нестеров	1	0.005/(1 + e/70)	6.4e-5	1.5e-3	100 %	0.1190	—
2 (квадратичная)	Нестеров	12	0.1	1.5e-16	1.2e-12	100 %	0.1192	—
2 (квадратичная)	Adam	1	0.02/(1 + e/70)	1.8e-4	1.3e-3	100 %	0.1191	—
2 (квадратичная)	Adam	12	0.1	3.0e-16	2.4e-12	100 %	0.1192	—
3 (сеть ReLU)	ГС / СГС	12	0.01	2.9e-1	—	7 %	0.1809	73 из 100
3 (сеть ReLU)	ГС / СГС	1	0.003	3.0e-1	—	6 %	0.1504	—
3 (сеть ReLU)	Нестеров	1	0.01	2.9e-1	—	3 %	0.2022	—
3 (сеть ReLU)	Нестеров	12	0.03	2.9e-1	—	7 %	0.2023	—
3 (сеть ReLU)	Adam	1	0.01	9.5e-2	—	7 %	0.1384	—
3 (сеть ReLU)	Adam	12	0.03	2.9e-1	—	5 %	0.2022	—

- **Модели 1 и 2:** все методы сходятся к **одному** решению — гребневой регрессии. Полный пакет — с точностью 10^{-8}–10^{-12} по весам, все 20 спусков сошлись по δ. Мини-пакеты — до 10^{-4}–10^{-3}, это тот же уровень шума, что и без штрафа. Порядок методов тот же, что в задаче 4. Штраф меняет не алгоритм, а функцию, которую он минимизирует.
- **Модель 3:** до $\tilde{J}^*$ (в пределах 1 %) дошли 3–7 % запусков любого метода, остальные — в локальных минимумах. Медианная SSE лучше всего у Adam с $m = 1$: 0.138. Как и без штрафа, для сети выбор на-

чальной точки и метода важнее, чем для выпуклых моделей.

Выводы

1. **Задача 1.** У $f(z)$ единственный минимум $z^* = 0.38032153$, $f(z^*) = 0.32860366$. Возле 0.6 только «полка» без второго минимума. Метод Брента нашёл минимум за 15 вычислений f, золотое сечение — за 43. Точность обоих ограничена величиной $\sqrt{\varepsilon_{\text{маш}}}$ — свойство поиска по значениям функции. На плато ($f \equiv 1$ в машинной арифметике) методы бессильны.
2. **Задача 2.** Спуск сходится, если $\varepsilon < 2/\lambda_{max}$. Число итераций $\propto \varkappa$ и совпадает с теорией: 111 и 2417 итераций. Численный градиент (центральные разности, ошибка 10^{-10}) для обучения не хуже аналитического. У сети ReLU множество локальных минимумов и плато. Остановка по малому градиенту не гарантирует даже хорошего минимума: из 100 начальных точек ни одна не привела в глобальный.
3. **Задача 3.** Мини-пакеты ускоряют начало обучения, но оставляют шум. Его уровень растёт с уменьшением пакета и не исчезает без уменьшения скорости. Допустимая скорость для малых пакетов ниже: скорость из задачи 2 приводит к расходимости. Слишком быстрое уменьшение скорости тормозит плохо обусловленную задачу.
4. **Задача 4.** Импульс Нестерова — лучший метод для выпуклых моделей при полном пакете: в 13 раз быстрее спуска на модели 2 ($\varkappa = 278$). Adam лучше всех обучает сеть ReLU, но при мини-пакетах у минимума выпуклой функции шагает по шуму. На 12 точках полный пакет выгоднее мини-пакетов.
5. **Задача 5.** Квадратичный штраф уменьшает веса, улучшает обусловленность и ускоряет спуск. Все методы сходятся к одному решению — гребневой регрессии. Для простых моделей он прогноз не улучшает, для сети ReLU — улучшает: скользящий контроль 0.189 → 0.140. Кроме того, он устраняет вырождение масштаба весов: при той же ошибке веса из «недопустимо больших» ($\sum w^2 = 52$) становятся умеренными (3.2).

Список литературы

1. Гудфеллоу Я., Бенджио И., Курвилль А. Глубокое обучение / пер. с англ. А. А. Слинкина. — 2-е изд. — М.: ДМК Пресс, 2018. — 652 с. Главы 4.2–4.3, 6.3, 7.1, 8.1–8.5.
2. Press W. H., Teukolsky S. A., Vetterling W. T., Flannery B. P. Numerical Recipes. The Art of Scientific Computing. 3rd ed. — Cambridge University Press, 2007. Разделы 5.7, 10.1–10.3.
3. Сукин И. А. Нейронные сети глубокого обучения. Лекция 6: Градиентный спуск и его особенности. Регуляризация. — РХТУ им. Д. И. Менделеева.
4. Нестеров Ю. Е. Метод решения задачи выпуклого программирования со скоростью сходимости $O(1/k^2)$ // Доклады АН СССР. 1983. Т. 269, № 3. С. 543–547.
5. Kingma D. P., Ba J. Adam: A Method for Stochastic Optimization // ICLR 2015. arXiv:1412.6980.
6. Brent R. P. Algorithms for Minimization without Derivatives. — Prentice-Hall, 1973.
7. Документация SciPy: `scipy.optimize.minimize_scalar`, `scipy.optimize.minimize` (Nelder-Mead).