

# Нейронные сети глубокого обучения Статистика и теория информации

Лекция 2

19 февраля 2026 г.

Сукин Иван Андреевич

РХТУ им. Д.И. Менделеева

 [sukin.i.a@muctr.ru](mailto:sukin.i.a@muctr.ru)

Вся информация, доступная нам, несёт в себе долю неопределённости. Её источники:

- Стохастичность системы
  - Настоящая (?) стохастичность — квантовая механика
  - Детерминированная стохастичность — сложные хаотические системы
- Неполнота данных — мы не знаем всех переменных, определяющих поведение (Сложно! Системы со скрытыми параметрами )
- Неточность измерений параметров
- Неполнота модели

# Физический смысл вероятности

- Частотная вероятность — оценка частоты некоторого события
- Байесовская вероятность — оценка правдоподобия некоторого события
- Теория вероятностей должна обеспечивать согласованность этих двух представлений
  - Сложно! Аксиоматика Колмогорова или аксиоматика Джейнса?
- Теория вероятностей — обобщение логики:
  - Сложно! «Правдоподобные рассуждения» Поппера

Случайная величина  $\xi$  характеризуется тем, что её точное значение неизвестно

- Известны лишь способы её получения при определённых устойчивых условиях опыта
- Конкретное значение принимаемое случайной величиной — её реализация
- Большое количество реализаций представляет собой статистический ансамбль
- Случайные величины бывают дискретными и непрерывными

# Характеристики случайной величины

- Простейшая характеристика — среднее значение:

$$\langle \xi \rangle = \lim_{n \rightarrow \infty} \frac{\xi_1 + \xi_2 + \dots + \xi_n}{n}$$

- Этот предел всегда существует и не зависит от способа выбора реализаций
- Можно усреднить функцию случайной величины:

$$\langle f(\xi) \rangle = \lim_{n \rightarrow \infty} \frac{f(\xi_1) + f(\xi_2) + \dots + f(\xi_n)}{n}$$

# Функция распределения

Рассмотрим случайную величину  $\varepsilon = \zeta(x - \xi)$ , где  $\zeta(z) = 1$ , если  $z > 0$  и  $0$  в противном случае

- Её среднее:

$$P\{\xi < x\} = \langle \zeta(x - \xi) \rangle = \lim_{n \rightarrow \infty} \frac{m}{n} = F_\xi(x)$$

это функция распределения

- $m$  — число случаев, когда неравенство  $\xi_i < x$  выполняется,  $n$  — число всех случаев

# Плотность распределения

- Плотность распределения — производная функции распределения:

$$\rho_{\xi}(x) = \frac{d}{dx}F_{\xi}(x)$$

- Физический смысл имеет только интеграл плотности

$$P\{a \leq \xi \leq b\} = \int_a^b \rho_{\xi}(x) dx$$

# Плотность распределения

- Плотность распределения связана с дельта-функцией Дирака:

$$\rho_{\xi}(x) = \langle \delta(\xi - x) \rangle, \quad \int_{-\infty}^{+\infty} f(z) \delta(z - z_0) dz = f(z_0)$$

- **Сложно!** Как понятие распределения обобщает понятие функции?

# Свойства плотности распределения

- Плотность распределения нормирована:

$$\int_{-\infty}^{+\infty} \rho(x) dx = 1$$

- Зная плотность, можно усреднить любую функцию:

$$\langle f(\xi) \rangle = \int_{-\infty}^{+\infty} f(x) \rho_{\xi}(x) dx$$

- **Сложно!** Разница между ДПВ и НПВ практически нивелируется, если рассматривать интегралы как интегралы Римана-Стилтьеса

# Маржинальное распределение

- Распределение вероятности может относиться к нескольким случайным величинам  $\rho_{\xi^1, \xi^2, \dots}(x_1, x_2, \dots)$
- Часть переменных можно исключить, например:

$$\rho_{\xi^1}(x_1) = \int_{-\infty}^{+\infty} \rho_{\xi^1, \xi^2}(x_1, x_2) dx_2$$

- Далее будем также писать  $\rho(\xi^i) = \rho_{\xi^i}(x_i)$

# Условная вероятность

Пусть есть распределение  $\rho(\xi^1, \xi^2)$

- Узнав реализацию случайной величины  $\xi^2$ , можно получить частичную информацию о  $\xi^1$
- Условная вероятность определяется как

$$\rho(\xi^1|\xi^2) = \frac{\rho(\xi^1, \xi^2)}{\int_{-\infty}^{+\infty} \rho(\xi^1, \xi^2) d\xi_1}$$

- Не стоит путать условную вероятность с причинностью

# Независимость случайных величин

- Если знание  $\xi^2$  не добавляет информации о  $\xi^1$ , величины независимы и:

$$\rho(\xi^1|\xi^2) = \rho(\xi^1), \quad \rho(\xi^1, \xi^2) = \rho(\xi^1)\rho(\xi^2)$$

- Противоположный случай — тождественная связанность (одна величина полностью определяет другую):

$$\rho(\xi^1, \xi^2) = \delta(\xi^1 - f(\xi^2))\rho(\xi^2)$$

# Моменты случайной величины

- Поведение случайной величины полностью определяются её моментами
- $i$ -ый начальный момент — это  $m_i = \langle \xi^i \rangle$
- $i$ -ый центральный момент — это  $\langle (\xi - \langle \xi \rangle)^i \rangle$
- Первый начальный момент — матожидание (среднее)
- Второй центральный момент — дисперсия (размах)
- **Сложно!** Как связаны моменты и гармонический анализ?

# Кумулянты случайной величины

- Часто удобнее характеризовать случайную величину последовательностью кумулянтов
- Зная  $n$  первых моментов, можно вычислить  $n$  первых кумулянтов и наоборот
- Высшие кумулянты можно приравнять к нулю (делать такое с моментами нежелательно **Сложно!** Почему? )
- Первый кумулянт — это матожидание, второй кумулянт — дисперсия

# Некоторые формулы для кумулянтов

$$k_1 = m_1$$

$$k_2 = m_2 - m_1^2$$

$$k_3 = m_3 - 3m_1m_2 + 2m_1^3$$

$$k_4 = m_4 - 3m_2^2 - 4m_1m_3 + 12m_1^2m_2 - 6m_1^4$$

# Характеристики, моменты, кумулянты

- Среднеквадратичное отклонение:

$$\sigma(\xi) = \sqrt{k_2}$$

- Оно предпочтительнее дисперсии тем, что имеет ту же размерность, что и случайная величина

- Коэффициент асимметрии:

$$\gamma_a = \frac{k_3}{k_2^{\frac{3}{2}}}$$

- Эксцесс:

$$\gamma_{\varepsilon} = \frac{k_4}{k_2^2}$$

# Ковариация и корреляция

- Ковариация показывает степень статистической связанности случайных величин:

$$\text{Cov}[\xi^1, \xi^2] = \langle \xi^1 \xi^2 \rangle - \langle \xi^1 \rangle \langle \xi^2 \rangle$$

- Ковариация независимых случайных величин равна нулю
- Нормируя ковариацию, получим коэффициент корреляции:

$$R_2 \equiv R = \frac{\text{Cov}[\xi^1, \xi^2]}{\sigma(\xi^1)\sigma(\xi^2)}$$

- Для набора  $n$  случайных величин можно записать матрицу ковариации
- **Сложно!** Определите ковариации более высокого порядка

# Популярные распределения

Если случайная величина принимает всего два значения 0 и 1 с вероятностью  $q$  и  $1 - q$ , имеем распределение Бернулли:

$$\rho(x) = q \times \delta(x) + (1 - q) \times \delta(x - 1)$$

$$m_1 = q$$

$$k_2 = q(1 - q)$$

**Сложно!** Найдите другие моменты и кумулянты

# Популярные распределения

Если случайная величина принимает  $k$  разных значений  $a_1, a_2, \dots, a_k$  с вероятностями  $q_1, q_2, \dots, q_k$ , где  $\sum q_i = 1$ , то имеем категориальное распределение:

$$\rho(x) = q_1\delta(x - a_1) + q_2\delta(x - a_2) + \dots + q_k\delta(x - a_k)$$

**Сложно!** Как определяются моменты и кумулянты этого распределения?

# Экспоненциальное распределение

- Если мы хотим иметь непрерывное распределение с пиком в районе нуля, то использовать нужно экспоненциальное распределение:

$$\rho(x, \lambda) = \lambda e^{-\lambda x}, \quad \text{где } x \geq 0$$

- Чтобы сдвинуть пик массы используется распределение Лапласа:

$$\rho(x, \mu, b) = \frac{1}{2b} e^{-\frac{x-\mu}{b}}$$

где  $b$  — параметр масштаба,  $\mu$  — параметр сдвига

# Нормальное распределение

Если задано среднее значение  $\mu$  и среднеквадратичное отклонение  $\sigma$ , то нормальное распределение имеет вид:

$$\rho(x, \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

- Нормальное распределение — самое популярное распределение
- Центральная предельная теорема — распределение суммы «хороших» случайных величин стремится к нормальному

# Распределение Хольцмарка


- Центральная предельная теорема выполняется не всегда
- Рассмотрим бесконечную вселенную, состоящую из одинаковых звёзд, распределённых случайно с постоянной плотностью и без корреляций
- Сила гравитации, действующая на одну звезду имеет распределение Хольцмарка
- Распределение Хольцмарка имеет бесконечную дисперсию

# Смеси распределений

- Можно комбинировать более простые распределения в более сложные
- Смесь распределений — категориальное распределение, в котором каждое значение случайной величины само является случайной величиной
- **Сложно!** Здесь снова возникают скрытые переменные
- Наиболее популярная смесь — гауссова


$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- Полезна для порождения  $q$  распределения Бернулли



$$\zeta(x) = \ln(1 + e^x)$$

- Полезна при порождении  $\mu$  или  $\sigma$  нормального распределения



# Информация и энтропия

Пусть имеется  $k$  равновероятных возможностей

- Априорная неопределённость, связанная с  $k$  называется энтропией  $H_{pr} = f(M)$ 
  - Она растёт с ростом  $k$
- После реализации апостериорная неопределённость  $H_{ps}$  равна нулю
- Отсюда, количество пришедшей информации равно:

$$I = H_{pr} - H_{ps} = H_{pr}$$

Как найти функцию  $f$  в выражении для  $H$ ?

- Принцип аддитивности: энтропия двух экспериментов в два раза больше,  $n$  экспериментов — в  $n$  раз больше:

$$f(m^n) = n \times f(m)$$

- Апостериорная энтропия должна быть равна нулю:  
 $f(1) = 0$
- Имеем количество информации по Хартли:

$$H = K \ln k$$

- Если  $P(\xi) = 1/k$ , то  $H = -\ln P(\xi)$

# Единицы измерения информации

- Если  $K = 1$ , информация измеряется в натах
- Если  $K = 1/\ln 2$ , информация измеряется в битах
- Если  $K$  — постоянная Больцмана ( $1.38 \cdot 10^{-23}$  Дж/К), то имеем физическую энтропию

# Неравновероятные события

- Если события неравновероятны, то  $-\ln P(\xi)$  — случайная величина
- Если мы усредним её, то получим больцмановскую энтропию:

$$H_{\xi} = \langle -\ln P(\xi) \rangle = - \sum_{\xi} P(\xi) \ln P(\xi)$$

- Энтропия неотрицательна
- Энтропия максимальна для равновероятных событий
- Для независимых  $\xi^1$  и  $\xi^2$  имеем  $H_{\xi^1, \xi^2} = H_{\xi^1} + H_{\xi^2}$
- **Сложно!** Докажите свойства энтропии

# Условная энтропия

- Условной вероятности  $P(\xi^k, \dots, \xi^n | \xi^1, \dots, \xi^{k-1})$  соответствует условная энтропия (Хартли):

$$H(\xi^k, \dots, \xi^n | \xi_1, \dots, \xi^{k-1}) = -\ln P(\xi^k, \dots, \xi^n | \xi^1, \dots, \xi^{k-1})$$

- Ей соответствует больцмановская условная энтропия:

$$H_{\xi^k, \dots, \xi^n}(|\xi^1, \dots, \xi^{k-1}) = - \sum_{\xi^k, \dots, \xi^n} P(\dots | \dots) \ln P(\dots | \dots)$$

- Для полного усреднения:

$$H_{\xi^k, \dots, \xi^n | \xi^1, \dots, \xi^{k-1}} = \langle H(\xi^k, \dots, \xi^n | \xi_1, \dots, \xi^{k-1}) \rangle$$


- Меняя  $k$  и  $n$ , получим много разных энтропий

# Иерархии случайных величин

Разложим процесс получения реализации случайной величины в дерево

- Из корня дерева будут исходить ветви, соответствующие попаданию случайной величины в один из непересекающихся интервалов
- Последующее ветвление соответствует дальнейшему дроблению интервалов
- Сумма вероятностей прохода по каждой из ветвей на заданном уровне дерева равна единице
- Листья — реализации исходной случайной величины
- **Сложно!** Это как-то связано с кодированием Хаффмана?

# Иерархии случайных величин    Пример Шеннона



# Иерархии случайных величин

- Энтропия выбора в корне дерева равна  $H_{\xi^1}$ 
  - В нашем случае  $H_{\xi^1} = 1$  бит
- Энтропия выбора в левом узле равна  $H_{\xi^2}(|\xi^1 = 1) = 0$
- Энтропия выбора в правом узле равна  $H_{\xi^2}(|\xi^1 = \{2, 3\}) = \frac{2}{3} \log_2 \frac{3}{2} + \frac{1}{3} \log_2 3$  бит
- Средняя энтропия выбора на втором этапе равна  $H_{\xi^2|\xi^1} = \frac{1}{2} H_{\xi^2}(|\xi^1 = \{2, 3\})$
- Полная энтропия равна  $H_{\xi^1, \xi^2} = \frac{1}{2} \log_2 2 + \frac{1}{3} \log_2 3 + \frac{1}{6} \log_2 6$
- Энтропия иерархически аддитивна:

$$H_{\xi^1, \dots, \xi^n} = H_{\xi^1} + H_{\xi^2|\xi^1} + \dots + H_{\xi^n|\xi^1, \dots, \xi^{n-1}}$$

# Расхождение Кульбака-Лейблера

- Различие между распределениями показывает расхождение Кульбака-Лейблера:

$$D_{KL}(\rho, \sigma) = \int d\rho(\xi) \ln \frac{\rho(\xi)}{\sigma(\xi)} \geq 0$$

- Это не расстояние
  - $D_{KL}(\rho, \sigma) \neq D_{KL}(\sigma, \rho)$
  - Это один из немногих способов определить энтропию распределения общего вида
- Ещё одна подобная мера — перекрёстная энтропия:

$$H(\rho, \sigma) = - \int d\rho(\xi) \ln \sigma(\xi)$$

# Применение энтропийных методов


- Предположим, что случайная величина  $\xi$  принимает  $k$  возможных значений
  - Пусть мы бросаем монетку, орёл — это 0, решка — 1
- Всё, что мы можем предположить на начальном этапе — что все её значения равновероятны:  $P(\xi_i) = \frac{1}{k}$ 
  - В нашем примере  $P(0) = 1/2$ ,  $P(1) = 1/2$
- Если у нас есть дополнительная информация о случайной величине (например, среднее или другие моменты), мы можем оптимизировать один из энтропийных критериев и получить более достоверное распределение

# Структурные вероятностные модели

- Часто встречаются совместные распределения большого числа величин
- Использовать многомерные распределения неэффективно
  - Сложно! Что такое «проклятие размерности»?
- Можно попытаться разложить распределение на множители:
  - Если множители — распределения вероятности, то разложение направленное
  - Если множители — произвольные функции, разложение ненаправленное

# Структурные вероятностные модели

$$\rho(a, b, c, d, e) = \rho(a)\rho(b|a)\rho(c|a, b)\rho(d|b)\rho(e|c)$$



# О лекциях

- Материал лицензирован под [CC BY SA 4.0](#)
- Правки и предложения приветствуются в виде пулл-реквестов по адресу <https://codeberg.org/fmjr/muctr>