

Нейронные сети глубокого обучения

Классическая линейная модель регрессии

Лекция 3

6 марта 2024 г.

Сукин Иван Андреевич

РХТУ им. Д.И. Менделеева

 sukin.i.a@muctr.ru

Регрессия

- Данные, которые не могут быть получены экспериментально, можно представлять в виде случайных величин
- Модель — набор ограничений на совместное распределение переменных
 - Модель представляет совокупность совместных распределений с наложенными на них условиями
- Зависимая переменная называется регрессируемой, независимые — регрессорами
- Выборка или данные — набор наблюдений регрессоров

Модель линейной регрессии удовлетворяет предположениям:

- Линейности
- Строгой экзогенности
- Отсутствия мультиколлинеарности
- Гомоскедастичности
- Отсутствия корреляции между наблюдениями

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_K x_{iK} + \varepsilon_i, \quad i = \overline{1, n}$$

- $\beta_1, \dots, \beta_K$ — неизвестные параметры, подлежащие оцениванию
- ε — значение ошибки (ненаблюдаемое)
- Выражение в правой части называется регрессией
- β_i — коэффициенты регрессии (предельные эффекты регрессоров)

$$\log(\text{ЗАРПЛАТА}_i) = \beta_1 + \beta_2 S_i + \beta_3 T_i + \beta_4 E_i + \varepsilon_i$$

или

$$\text{ЗАРПЛАТА}_i = e^{\beta_1} e^{\beta_2 S_i} e^{\beta_3 T_i} e^{\beta_4 E_i} e^{\varepsilon_i}$$

- S_i — количество лет обучения
- T_i — количество лет, отработанных на текущем месте
- E_i — стаж
- Если регрессор один, говорят о простой или парной модели регрессии
- Многие модели можно свести к линейной регрессии

- Пусть предельный эффект обучения на зарплату снижается по мере роста уровня образования
- Введём новый регрессор $V_i = S_i^2$
- Получим уравнение регрессии:

$$\log(\text{ЗАРПЛАТА}_i) = \beta_1 + \beta_2 S_i + \beta_5 V_i + \beta_3 T_i + \beta_4 E_i + \varepsilon_i$$

- Предельный эффект обучения на зарплату:

$$\frac{\partial \text{ЗАРПЛАТА}_i}{\partial S} = \beta_2 + 2\beta_5, \quad \beta_5 < 0$$

- **Сложно!** Скейлинг и степенные законы по существу линейны

В матричных обозначениях линейную регрессию можно записать в виде:

$$y = \underbrace{X \beta}_{n \times 1} + \varepsilon$$

$n \times 1 \quad n \times k \quad k \times 1 \quad n \times 1$

Линейная регрессия

Строгая экзогенность

$$\langle \varepsilon_i | X \rangle = 0, \quad i = \overline{1, n}$$

Следствия:

- Безусловное матожидание ошибки равно нулю:

$$\langle \varepsilon_i \rangle = 0, \quad i = \overline{1, n}$$

- Регрессоры ортогональны ошибке для всех наблюдений:

$$\langle x_{jk} \varepsilon_i \rangle = 0, \quad \text{для всех } i, j, k$$

- Регрессоры не коррелированы с ошибкой:

$$\text{Cov}(\varepsilon_i, x_{jk}) = 0$$

Строгая экзогенность

- В моделях временных рядов строгая экзогенность означает, что регрессоры ортогональны прошлым, текущим и будущим ошибкам
- Для временных рядов это часто неверно, однако для больших выборок можно ослабить это условие
- Пример не строго экзогенной регрессии — авторегрессия $AR(1)$:

$$y_i = \beta y_{i-1} + \varepsilon_i, \quad i = \overline{1, n}$$

- Докажите отсутствие строгой экзогенности $AR(1)$

Отсутствие мультиколлинеарности

- Матрица наблюдаемых значений регрессоров почти наверное должна иметь полный столбцовый ранг
- Это означает, что число наблюдений должно быть не меньше числа регрессоров
- **Сложно!** Также все столбцы матрицы наблюдаемых значений должны быть линейно-независимыми
- Пример: если никто не менял место работы, регрессия для зарплаты перестаёт удовлетворять условию мультиколлинеарности
 - В этом случае можно оценить только сумму коэффициентов $\beta_3 + \beta_4$, но не сами эти коэффициенты

$$\langle \varepsilon_i^2 | X \rangle = \sigma^2 > 0, \quad i = \overline{1, n}$$

$$\langle \varepsilon_i \varepsilon_j | X \rangle = 0, \quad i, j = \overline{1, n}, \quad i \neq j$$

- Для временных рядов это эквивалентно отсутствию сериальной корреляции ошибки
- Также это условия называют условием сферичности ковариационной матрицы

Случайные выборки

- Выборка (y, X) случайна, если последовательность $\{y_i, x_i\}$ независима и независимо распределена по наблюдениям
- ε_i^2 — функция от y_i и x_i
- Если $\langle \varepsilon_i \rangle$ не зависит от i имеем безусловную гомоскедастичность
- В реальности важно считать регрессоры стохастическими, а не детерминированными

Метод наименьших квадратов

Как найти значения коэффициентов β ?

- Для некоторого заданного значения $\tilde{\beta}$ остаток (residual) равен:

$$y_i - x_i^T \tilde{\beta}$$


- Сумма квадратов остатков (SSR, RSS, ESS):

$$SSR(\tilde{\beta}) = (y - X\tilde{\beta})^T (y - X\tilde{\beta})$$

- МНК-оценка (OLS-estimate):

$$b \equiv \operatorname{argmin}_{\tilde{\beta}} SSR(\tilde{\beta})$$

Метод наименьших квадратов



- Минимизируем $SSR(\tilde{\beta})$:

$$\frac{\partial SSR(\tilde{\beta})}{\partial \tilde{\beta}} \propto -X^T y + X^T X \tilde{\beta} = 0$$

- Решая эту систему уравнений, получим нормальные уравнения МНК:

$$\underset{K \times K}{X^T X} \underset{K \times 1}{b} = \underset{K \times 1}{X^T y}$$

- Сложно!** Докажите, что нормальные уравнения действительно доставляют минимум функции $SSR(\tilde{\beta})$

МНК-остатки

- Найдя МНК-оценку b , можно найти вектор МНК-остатков:

$$\underset{n \times 1}{e} \equiv y - Xb$$

- Домножив обе части этого уравнения на X^T , получим:

$$X^T e = X^T y - X^T X b = 0$$

- Нормальные уравнения являются условиями ортогональности

МНК-оценка b

- Значение b можно найти как:

$$b = (X^T X)^{-1} X^T y$$

- **Сложно!** Вспомните о псевдообратной матрице и запишите выражение для b через неё
- Подогнанное (fitted) значение y :

$$\hat{y} = Xb, \quad e = y - \hat{y}$$

МНК и истинные ошибки

- Истинные ошибки ε ненаблюдаемы
- Матрица-проектор $P = X(X^T X)^{-1} X^T$
 $n \times n$
 - Она идемпотентна: $P = PP$
 - Она отображает пространство в себя: $PX = X$
- Матрица-аннулятор $M = I - P$
 - Она идемпотентна и отображает пространство в ноль:
 $MX = 0$
- Истинные ошибки связаны с МНК-оценкой как:

$$SSR = e^T e = \varepsilon^T M \varepsilon$$

Свойства МНК-ошибок

- Дисперсия МНК-ошибки равна:

$$s^2 = \frac{e^T e}{n - K}$$

- Стандартная ошибка регрессии (стандартное отклонение, SER, SEE):

$$SER = \sqrt{s^2}$$

- Ошибка оценки связана с истинными ошибками регрессии:

$$b - \beta = (X^T X)^T X^T \varepsilon$$

Изменчивость зависимой переменной

- Цель регрессии — объяснить, как зависит зависимая переменная от значений независимых (регрессоров)
- Качество этого объяснения можно вычислить с помощью показателя «нецентрированный R^2 »:

$$R_{uc}^2 = \frac{\hat{y}^T \hat{y}}{y^T y} = 1 - \frac{e^T e}{y^T y}$$

- Верно, что $0 \leq R_{uc}^2 \leq 1$
- Чем ближе R_{uc}^2 к единице, тем лучше регрессия объясняет зависимость

Коэффициент детерминации

- Значение R_{uc}^2 учитывает также влияние константных регрессоров
- Чтобы избавиться от этого влияния, величину R_{uc}^2 нужно центрировать
- Получим коэффициент детерминации:

$$R^2 = 1 - \frac{\langle e^2 \rangle}{\langle y^2 \rangle - \langle y \rangle^2}$$

- Если среди регрессоров нет константы, R^2 может стать отрицательным
 - Регрессия без константы может аппроксимировать данные хуже чем обычное вычисление выборочного среднего

Тестирование гипотез

- Часто теория накладывает ограничения на значения коэффициентов β
- В результате МНК-оценивания b в среднем будет равно β , но конкретные значения могут отличаться
- Чтобы узнать, верно ли теоретическое ограничение, существует аппарат проверки гипотез
 - Необходимо построить тестовую статистику
 - Распределение этой статистики должно быть известно при условии истинности ограничения
 - В общем случае для этого нужно знать совместное распределение X, ε
 - Если условное распределение $\varepsilon|X$ нормальное, можно не знать распределения X

Тестирование гипотез

- Тестируемое ограничение (например $\beta_1 = 1$) называется нулевой гипотезой
- Нулевая гипотеза — ограничение на поддерживаемую гипотезу — набор предположений, позволяющий получить тестовую статистику
 - В нашем случае поддерживаемая гипотеза — нормальность условного распределения ε
- Модель правильно специфицирована, если поддерживаемая гипотеза верна
- Если модель неправильно специфицирована, тестовая статистика не несёт информации о выполнении нулевой гипотезы

Нормально распределённые ошибки

Насколько допустимо предположение, что ошибки распределены нормально?

- Часто ошибка включает большое количество факторов, не охваченных регрессорами (центральная предельная теорема!)
- В других случаях ошибка возникает вследствие измерений
 - Ошибки измерений очень часто распределены нормально
- Полагаем:

$$\rho(\varepsilon|X) \propto N(0, \sigma^2 \mathbf{1})$$

$$\rho((b - \beta)|X) \propto N(0, \sigma^2(X^T X))$$

Гипотезы об отдельных коэффициентах

- Простейшая гипотеза имеет вид:

$$H_0 : \beta_k = \bar{\beta}_k$$

- Альтернативная гипотеза:

$$H_1 : \beta_k \neq \bar{\beta}_k$$

- Ошибка оценки имеет отклонение:

$$\rho((b_k - \bar{\beta}_k)|X) \propto N(0, \sigma^2 \cdot ((X^T X)^{-1})_{kk})$$

- Нормируя, получим, что следующая величина имеет распределение $N(0, 1)$:

$$z_k = \frac{b_k - \bar{\beta}_k}{\sqrt{\sigma^2 \cdot ((X^T X)^{-1})_{kk}}}$$

t-статистика

- В реальности мы не знаем величину σ^2 , но мы знаем её оценку s^2
- Если заменить σ^2 на s^2 в выражении для z , получим t-статистику, имеющую распределение Стюдента с $n - K$ степенями свободы:

$$\rho_t^{n-K}(b_k - \bar{\beta}_k) = \frac{\Gamma\left(\frac{n-K+1}{2}\right) \left(1 + \frac{(b_k - \bar{\beta}_k)^2}{n-K}\right)^{-\frac{n-K+1}{2}}}{\Gamma\left(\frac{n-K}{2}\right) \sqrt{(n-K)\pi}}$$

- $\Gamma(z+1) = z\Gamma(z)$:

$$\Gamma(z) = \int_0^{+\infty} x^{z-1} e^{-x} dx, \quad z > 0$$

t-тест

Тестирование гипотезы с помощью t-статистики:

1. Вычисляем стандартную ошибку МНК-оценки коэффициента β_k :

$$SE(b_k) = \sqrt{s^2 \cdot ((X^T X)^{-1})_{kk}}$$

2. Вычисляем t-отношение (t-ratio, t-value):

$$t_k = \frac{b_k - \bar{\beta}_k}{SE(b_k)}$$

t-тест

4. Фиксируем уровень значимости α (например $\alpha = 0.95$)
5. Находим такое значение t_α^{n-K} , что

$$\int_{-t_\alpha^{n-K}}^{t_\alpha^{n-K}} \rho_t^{n-K}(x) dx = \alpha$$

6. H_0 не отвергается, если $t_k \in [-t_\alpha^{n-K}, t_\alpha^{n-K}]$, в противном случае H_0 отвергается
 - Вероятность отвергнуть H_0 , когда она верна, равна $1 - \alpha$


Доверительный интервал

- Другая формулировка проверки гипотезы — попадание $\bar{\beta}_k$ в доверительный интервал:

$$[b_k - SE(b_k) \cdot t_{\alpha}^{n-K}, b_k + SE(b_k) \cdot t_{\alpha}^{n-K}]$$

- Если b_k попадает в этот интервал, нулевая гипотеза принимается
- Доверительный интервал тем уже, чем уже стандартная ошибка

t-статистика



Линейные гипотезы

- Линейная гипотеза общего вида имеет вид:

$$H_0 : R\beta = r$$

- Пример: предполагаем, что образование и продолжительность работы на текущем месте имеют одинаковое влияние на зарплату, а стаж не имеет никакого влияния ($\beta_2 = \beta_3$, $\beta_4 = 0$)
- Эта гипотеза в матричных терминах формулируется как:

$$R = \begin{bmatrix} 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad r = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

- Будем предполагать, что в системе нет лишних уравнений и противоречий

F-отношение

- Для линейной нулевой гипотезы, можно составить F-отношение:

$$F = \frac{(Rb - r)^T [R(X^T X)^{-1} R^T]^{-1} (Rb - r)}{\#r \cdot s^2}$$

- Здесь $\#r$ — число строк в матрице R
- Оно имеет распределение Фишера:

$$\rho_F(x, \#r, n - K) = \frac{\Gamma\left(\frac{\#r}{2} + \frac{n-K}{2}\right) \sqrt{\frac{(\#rx)^{\#r} (n-K)^{n-K}}{(\#rx + n-K)^{\#r + n-K}}}}{x \Gamma\left(\frac{\#r}{2}\right) \Gamma\left(\frac{n-K}{2}\right)}$$

F-тест


Тестирование гипотезы с помощью F-статистики:

1. Вычисляем F-отношение
2. Фиксируем уровень значимости α (например $\alpha = 0.95$)
3. Находим такое значение $F_\alpha(\#r, n - K)$, что


$$\int_0^{F_\alpha(\#r, n-K)} \rho_F(x, \#r, n - K) dx = \alpha$$

4. H_0 не отвергается, если $F < F_\alpha(\#r, n - K)$, в противном случае H_0 отвергается

F-статистика



Сравнение t- и F- тестов



Максимальное правдоподобие

- Метод максимального правдоподобия нужен, чтобы выбрать такие параметры оцениваемого распределения, при которых вероятность получить рассматриваемую выборку максимальна
- Предполагаем, что плотность выборки принадлежит семейству $f(y, X, \zeta)$
 - f — функция правдоподобия
 - ζ — истинное значение вектора параметров
- ML-оценка максимизирует f с учётом имеющейся выборки

Условная функция правдоподобия

- Функцию правдоподобия можно разложить на множители:

$$f(y, X, \zeta) = g(y|X, \theta) \cdot h(X, \psi)$$

- θ и ψ — части вектора ζ , отвечающие, соответственно за условную и частную функции плотности
- Для линейной регрессии $\theta = [\beta, \sigma^2]$, но функция h неизвестна
- Если $\tilde{\theta}$ и $\tilde{\psi}$ не зависят друг от друга, максимизацию можно проводить независимо
 - ML-оценка θ доставляет максимум условной функции правдоподобия

Правдоподобие линейной регрессии

- При принятых предположениях ошибка линейной регрессии имеет распределение $N(0, \sigma^2)$
- Условная функция распределения:

$$g(y|X) = \frac{1}{(2\pi\sigma^2)^{n/2}} e^{-\frac{(y-X\beta)^T(y-X\beta)}{2\sigma^2}}$$

- Логарифмируя, получим логарифмическую функцию правдоподобия:

$$\ln L(\tilde{\beta}, \tilde{\sigma}^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\tilde{\sigma}^2) - \frac{1}{2\tilde{\sigma}^2} (y - X\tilde{\beta})^T (y - X\tilde{\beta})$$

Максимизация правдоподобия

- Поскольку $\tilde{\beta}$ и $\tilde{\sigma}^2$ независимы, можно проводить максимизацию отдельно
- Максимизация по $\tilde{\beta}$ — это просто МНК
- Получаем концентрированную функцию правдоподобия:

$$-\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\tilde{\sigma}^2) - \frac{1}{2\tilde{\sigma}^2} e^T e \rightarrow \max_{\tilde{\sigma}^2}$$

- **Сложно!** Максимизируйте эту функцию

Максимизация правдоподобия

- ML-оценка σ^2 совпадает с МНК-оценкой:

$$\sigma^2 = \frac{n - K}{n} s^2$$

- Эта оценка смещённая, но смещение уменьшается с ростом числа наблюдений

Наилучшие оценки

- Теорема Гаусса-Маркова: МНК-оценка b является наилучшей в классе линейных несмещённых оценок (BLUE)
- МНК-оценка b также является лучшей среди всех несмещённых оценок, если ошибка распределена нормально
 - Это означает, что любая другая оценка обладает «большей» дисперсией (ковариационной матрицей)
 - **Сложно!** Узнайте про неравенство Крамера-Рао

О лекциях

- Материал лицензирован под [CC BY SA 4.0](#)
- Правки и предложения приветствуются в виде пулл-реквестов по адресу <https://codeberg.org/fmjr/muctr>