

Нейронные сети глубокого обучения

Глубокие нейросетевые модели. Функции потерь

Лекция 5

3 апреля 2024 г.

Сукин Иван Андреевич

РХТУ им. Д.И. Менделеева

 sukin.i.a@muctr.ru

Многослойные перцептроны

- Чем больше нейронов содержит скрытый слой двухслойной сети, тем лучше её описательные способности
- Имея достаточное количество нейронов на скрытом слое, можно приблизить любую многомерную функцию
- К сожалению, для многих полезных функций количество требуемых скрытых нейронов слишком велико
- Добавление новых скрытых слоёв позволяет уменьшить сложность сети при той же предсказательной способности


Композиция нейросетей

- Простейший случай усложнения структуры сети — композиция двух сетей
- Вспомним простой двухслойный перцептрон:




$$y = (w^2)^T \text{relu}(w^1 x_i + b^1) + b_1^2$$

- Он имеет один вход и один выход
- Соединим два таких перцептрона, подав выход одного на вход другого

Комбинация двухслойных перцептронов




Комбинация двухслойных перцептронов



Комбинация двухслойных перцептронов

- С использованием ReLU мы получаем кусочно-линейную аппроксимацию
- Количество линейных участков возрастает с ростом числа слоёв
- Первая сеть «складывает» входное пространство
- Итоговое число линейных участков равно произведению числа линейных участков для каждой сети

Пример приближения глубокой сетью



Глубокие сети

- Можно рассматривать произвольную сеть, каждый слой которой выполняет аффинное преобразование с последующим пропусканием через функцию активации
- Каждый слой складывает входное пространство, обрезает его с помощью функции активации, а потом рекомбинирует результат
- Обрезка позволяет создавать новые узлы изменения наклона функции

Гиперпараметры

- Количество нейронов в слое — ширина слоя D_k
- Количество скрытых слоёв — глубина сети
- Общее количество нейронов — ёмкость сети
- Все эти величины — гиперпараметры, они задаются перед обучением
- Каждая комбинация гиперпараметров описывает семейство функций
- Задание весов определяет конкретную функцию из семейства

Общий вид глубокой сети

- Пусть k -ый скрытый слой из N вычисляет вектор

$$\underbrace{h_k}_{D_k} = f_A(\underbrace{b_{k-1}}_{D_k} + \underbrace{W_{k-1}}_{D_k \times D_{k-1}} \underbrace{h_{k-1}}_{D_{k-1}})$$

- Нулевой слой — входной: $h_0 = x$
- Выходной слой — обычное аффинное преобразование:

$$y = b_N + W_N h_N$$

- Эта система уравнений определяет глубокую сеть прямого распространения — многослойный перцептрон

Функции потерь глубоких сетей

- Сумма квадратов отклонений в линейной регрессии — функция потерь
- Функция потерь определяет суммарное качество предсказания сети — она критерий качества
- Среднеквадратичная функция потерь применяется, когда сеть имеет один выход
- Будем предполагать, что сеть вычисляет условную плотность распределения $p(y|x)$
 - Более качественные предсказания обеспечивают более высокую вероятность получения исходной выборки

Предсказание распределений

Как сеть вычисляет условную плотность распределения?

- Задаём некоторое параметрическое распределение $p(y|\theta)$ на пространстве выходов
- С помощью сети оцениваем его параметры (возможно, часть из них)
- Пример:
 - Пространство выходов — $\mathbb{R}$
 - Возьмём нормальное распределение $p(y|\theta) = N(\mu, \sigma^2)$,
 $\theta = [\mu, \sigma^2]$
 - Сеть может оценить μ

Максимальное правдоподобие

- Каждое значение y_i из выборки должно иметь высокую вероятность относительно распределения $\rho(y|\theta)$
- Выбираем такие веса сети, что они максимизируют вероятность каждого значения из выборки:

$$\hat{W} = \operatorname{argmax}_W \left[\prod_i \rho(y_i | f(x_i, W)) \right]$$

- При каких предположениях имеет смысл эта формула?

Логарифмическое правдоподобие

- Для больших выборок произведение, стоящее в функции правдоподобия, становится очень маленьким числом
- Логарифм — монотонная функция и не меняет положения максимума
- Функцию потерь обычно минимизируют
- Получим функцию отрицательного логарифмического правдоподобия:

$$J(W) = - \sum_i \ln \rho(y_i | f(x_i, W))$$

Переход к значениям

- Наша сеть теперь предсказывает параметры распределения
- Мы хотим, чтобы она предсказывала значения
- Максимальное правдоподобие позволяет сделать предсказание:

$$\hat{y} = \operatorname{argmax}_y \rho(y|f(x, W))$$

- Для нормального распределения $\hat{y}$ — это среднее μ

Алгоритм построения функции потерь

1. Выбираем распределение $\rho(y|\theta)$
2. Формулируем сеть в таких терминах, чтобы она предсказывала не y , а θ
3. Выбираем и минимизируем по W функцию:

$$J(W) = - \sum_i \ln \rho(y_i | f(x_i, W))$$

4. Чтобы предсказать y максимизируем $\rho(y|f(x, W))$

Глубокая регрессия


- В случае сети со скалярным выходом можно выбрать нормальное распределение
- Минимизация функции отрицательного логарифмического правдоподобия приведёт к методу наименьших квадратов
- Предсказание сети будет равно среднему значению y
- Можно также добавить σ^2 в список «весов» сети
 - На самом деле это что-то среднее между гиперпараметром и весом
 - **Сложно!** Какой вид тогда примет функция потерь $J(W, \sigma^2)$?

Гетероскедастическая регрессия


- Если предположить, что дисперсия у наблюдений различна, получим гетероскедастическую модель, оценивающую среднее $\mu_i = f_1(x_i, W)$
- Чтобы обучить сеть для этой модели, добавляем σ в список оцениваемых параметров: $f_2(x_i, W)$
- Функция потерь тогда примет вид:

$$J(W) = \sum_i \left(\ln \sqrt{2\pi f_2(x_i, W)} + \frac{(y_i - f_1(x_i, W))^2}{2f_2(x_i, W)} \right)$$

Гомоскедастическая регрессия



Гетероскедастическая регрессия



Двоичная классификация

- Пространство y имеет вид $\{0, 1\}$
- Выход сети нужно пропустить через сигмоиду $\frac{1}{1+e^{-z}}$
- Предполагаем, что y имеет распределение Бернулли:

$$\rho(y|q) = \begin{cases} 1 - q, & y = 0, \\ q, & y = 1 \end{cases}$$

- Пользуясь максимальным правдоподобием, получим функцию потерь в виде двоичной перекрестной энтропии:

$$J(W) = - \sum_i \left[y_i \ln \frac{1}{1 + e^{-f(x_i, W)}} + (1 - y_i) \ln \left(1 - \frac{1}{1 + e^{-f(x_i, W)}} \right) \right]$$

Мультиклассовая классификация

- Выбираем категориальное распределение:

$$\rho(y|q) = q_k, \quad y = \bar{y}_k, \quad q_k \in [0, 1], \quad \sum_k q_k = 1$$

- Сеть имеет K выходов, каждый нормализован как:

$$\text{softmax}_k(z) = \frac{e^{z_k}}{\sum_{\text{Все } k} e^z}$$

- Функция потерь будет иметь вид:

$$J(W) = - \sum_i \left(f_{y_i}(x, W) - \ln \sum_k e^{f_k(x, W)} \right)$$

Принципы выбора распределений

Тип данных	Распределение	Применение
Одномерные, непрерывные, неограничен- ные	Одномерное нормальное	Регрессия
Многомерные, непрерывные, неограничен- ные	Многомерное нормальное	Многомерная регрессия
Одномерные, непрерывные, неограничен- ные	Лапласа или Стьюдента	Робастная ре- грессия

Принципы выбора распределений

Тип данных	Распределение	Применение
Одномерные, непрерывные, неограничен- ные	Гауссова смесь	Мультимодаль- ная регрессия
Одномерные, непрерывные, ограниченные снизу	Экспоненциаль- ное, Эрланга, χ^2 (Гамма)	Предсказание отрезков
Одномерные, непрерывные, ограниченные	Бета	Предсказание соотношений

Принципы выбора распределений

Тип данных	Распределение	Применение
Одномерные, непрерывные, периодические	фон Мизеса	Предсказание направлений
Одномерные, двоичные	Бернулли	Двоичная клас- сификация
Одномерные дискретные, ограниченные	Категориальное	Мультиклассо- вая классифи- кация

Принципы выбора распределений

Тип данных	Распределение	Применение
Одномерные, дискретные, ограниченные снизу	Пуассона	Предсказание количества
Многомерное, дискретное, перестановка	Плакетта-Люса	Ранжирование

Функции потерь для многих выходов

- Часто выход сети многомерный
- Обычно считают, что выходы независимы, так же, как и ошибки
- Тогда принцип максимального правдоподобия приводит к функции потерь:

$$J(W) = - \sum_i \sum_d \ln \rho(y_{id} | f_d(x, W))$$

- d — наборы независимых выходов

О лекциях

- Материал лицензирован под [CC BY SA 4.0](#)
- Правки и предложения приветствуются в виде пулл-реквестов по адресу <https://codeberg.org/fmjr/muctr>