

Нейронные сети глубокого обучения

Глубокие нейросетевые модели. Функции потерь

Лекция 3

1 марта 2025 г.

Сукин Иван Андреевич

РХТУ им. Д.И. Менделеева

 sukin.i.a@muctr.ru

- Любая нейронная сеть представляет собой семейство функций
- Функции отображают входные данные на выходные
- Конкретный член семейства определяется значениями параметров (весов) сети ϕ
- Обучение сети — подбор таких значений ϕ , чтобы отображение было в некотором смысле «наилучшим»

- Такая постановка задачи требует наличия обучающей выборки $\{x_i, y_i\}$ входных и соответствующих выходных векторов
- Функция потерь (критерий качества, целевая функция) $L[\phi]$ возвращает единственное число, показывающее степень расхождения между предсказаниями модели $f[x_i, \phi]$ и «реальными» значениями y_i
- Во время обучения мы подбираем такие значения ϕ , чтобы значение функции L было минимальным для обучающей выборки
- Пример функции потерь — среднеквадратичное расхождение

Максимальное правдоподобие

- Рассмотрим модель $f[x, \phi]$ с параметрами ϕ и входными данными x
- Обычно мы считаем, что модель предсказывает значения y
- Теперь будем считать, что модель вычисляет распределение условной вероятности $P(y|x)$
- Функция потерь должна накладывать требование: значения y из обучающей выборки должны иметь высокие условные вероятности в распределении $P(y|x)$

- Как преобразовать модель в форму, предсказывающую распределение вероятности?
- Выберем параметрическое распределение $P(y|\theta)$
- Обучим сеть таким образом, чтобы она предсказывала параметры распределения θ
- Предположим, исходная сеть предсказывает значения некоторой вещественной переменной
- Разумно выбрать нормальное распределение для этой переменной
- Тогда сеть должна предсказать параметры μ и σ^2 этого распределения

Критерий максимального правдоподобия

- Теперь наша модель вычисляет различные параметры распределения $\theta_i = f[x, \phi]$ для каждого набора входных данных x_i
- Каждое значение y_i из обучающей выборки должно иметь высокую вероятность при распределении $P(y_i|\theta_i)$
- Выберем параметры модели так, чтобы максимизировать эту вероятность:

$$\begin{aligned}\hat{\phi} &= \operatorname{argmax}_{\phi} \prod_{i=1}^I P(y_i|x_i) = \operatorname{argmax}_{\phi} \prod_{i=1}^I P(y_i|\theta_i) = \\ &= \operatorname{argmax}_{\phi} \prod_{i=1}^I P(y_i|f[x_i, \phi])\end{aligned}$$

- Выведенный критерий является критерием максимального правдоподобия, а выражение под аргмаксимумом — правдоподобием
- Мы предположили, что данные имеют одинаковое распределение
- Также мы предположили, что распределения для каждого из обучающих векторов независимы
- Это частые предположения в задачах обучения (i.i.d.), но они выполняются не всегда

Логарифмическое правдоподобие

- Критерий максимального правдоподобия трудно применять на практике
- Каждый множитель $P(y_i|f[x_i, \phi])$ может быть очень маленьким
- Можно логарифмировать этот критерий:

$$\begin{aligned}\hat{\phi} &= \operatorname{argmax}_{\phi} \prod_{i=1}^I P(y_i|f[x_i, \phi]) = \operatorname{argmax}_{\phi} \ln \prod_{i=1}^I P(y_i|f[x_i, \phi]) = \\ &= \operatorname{argmax}_{\phi} \sum_{i=1}^I \ln P(y_i|f[x_i, \phi])\end{aligned}$$

- Этот критерий эквивалентен, потому что логарифм — монотонная функция
- Мы перешли от произведения к сумме

- Функцию потерь обычно минимизируют, если исходить из её физического смысла
- Чтобы перейти от критерия максимального логарифмического правдоподобия к функции потерь, нужно умножить критерий на -1 :

$$\begin{aligned}\hat{\phi} &= \operatorname{argmin}_{\phi} \left[- \sum_{i=1}^I \ln P(y_i | f[x_i, \phi]) \right] = \\ &= \operatorname{argmin}_{\phi} L[\phi]\end{aligned}$$

- $L[\phi]$ — искомая функция потерь

Обратный вывод

- Мы научили сеть предсказывать параметры распределения
- Как, зная распределение, предсказать конкретное значение y для известного x ?
- Нужно найти аргмаксимум:

$$\hat{y} = \operatorname{argmax}_y P(y|f[x, \hat{\phi}])$$

Алгоритм построения функции потерь

1. Выберите подходящее распределение $P(y|\theta)$, исходя из природы исходных данных
2. Переформулируйте модель для предсказания параметров распределения $\theta = f[x, \phi]$ и $P(y|\theta) = P(y|f[x, \phi])$
3. Для обучения модели найдите параметры $\hat{\phi}$, минимизирующие отрицательное логарифмическое правдоподобие:

$$\hat{\phi} = \operatorname{argmin}_{\phi} L[\phi] = \operatorname{argmin}_{\phi} \left[- \sum_{i=1}^I \ln P(y_i | f[x_i, \phi]) \right]$$

4. Для предсказания на тестовой выборке максимизируйте получившееся распределение $P(y|f[x, \hat{\phi}])$ по y

Пример: одномерная регрессия

- В задаче одномерной регрессии мы предсказываем скалярное значение y
- Выберем одномерное нормальное распределение по y , оно определяется двумя параметрами — μ и σ^2 :

$$P(y|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - \mu)^2}{2\sigma^2} \right]$$

- Модель должна предсказывать один или несколько параметров:

$$P(y|f[x, \phi], \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - f[x, \phi])^2}{2\sigma^2} \right]$$

- Воспользуемся функцией потерь:

$$\begin{aligned} L[\phi] &= - \sum_{i=1}^I \ln P(y|f[x, \phi], \sigma^2) = \\ &= - \sum_{i=1}^I \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y-f[x, \phi])^2}{2\sigma^2} \right] \right) \end{aligned}$$

- Нужно найти такие значения $\hat{\phi}$, чтобы эта функция имела минимальное значение

Метод наименьших квадратов

- Преобразуем функцию потерь:

$$\begin{aligned}\hat{\phi} &= \operatorname{argmin}_{\phi} \left[- \sum_{i=1}^I \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[- \frac{(y-f[x,\phi])^2}{2\sigma^2} \right] \right) \right] = \\ &= \operatorname{argmin}_{\phi} \left[- \sum_{i=1}^I \left(\ln \frac{1}{\sqrt{2\pi\sigma^2}} - \frac{(y-f[x,\phi])^2}{2\sigma^2} \right) \right] = \\ &= \operatorname{argmin}_{\phi} \left[- \sum_{i=1}^I - \frac{(y-f[x,\phi])^2}{2\sigma^2} \right] = \\ &= \operatorname{argmin}_{\phi} \left[\sum_{i=1}^I (y-f[x,\phi])^2 \right]\end{aligned}$$

- Последнее выражение представляет метод наименьших квадратов

Обратный вывод

- Наша сеть теперь предсказывает μ вместо y
- Для предсказания y найдём аргмаксимум:

$$\hat{y} = \operatorname{argmax}_y P(y|f[x, \hat{\phi}], \sigma^2)$$

- Для нормального распределения максимизация приводит к среднему значению:

$$\hat{y} = \mu = f[x, \hat{\phi}]$$

Оценка дисперсии

- Мы предсказали только среднее значение, но дисперсия осталась неопределённой
- Выражение для МНК не зависит от дисперсии
- Мы можем рассматривать дисперсию как параметр обучения:

$$\hat{\phi}, \hat{\sigma}^2 = \operatorname{argmin}_{\phi, \sigma^2} \left[- \sum_{i=1}^I \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y - f[x, \phi])^2}{2\sigma^2} \right] \right) \right]$$

- Модель предсказывает значение μ , но значение дисперсии получается в процессе обучения

Гетероскедастическая регрессия

- Рассмотренная модель подразумевает, что данные имеют одинаковую дисперсию
- Это предположение не всегда верно
- Чтобы это учесть, модель должна предсказывать и μ и σ^2
- Важно, что дисперсия — положительное число
- Получим сеть:

$$\begin{aligned}\mu &= f_1[x, \phi] \\ \sigma^2 &= f_2[x, \phi]^2\end{aligned}$$

- Функция потерь:

$$\hat{\phi} = \operatorname{argmin}_{\phi} \left[- \sum_{i=1}^I \left(\ln \frac{1}{\sqrt{2\pi f_2[x_i, \phi]^2}} - \frac{(y_i - f_1[x_i, \phi])^2}{2f_2[x_i, \phi]^2} \right) \right]$$

Бинарная классификация

- Задача бинарной классификации сводится к распределению входных данных $\mathbf{x}$ по двум классам $\{0, 1\}$
- Мы называем y меткой
- В качестве распределения выбираем распределение Бернулли:

$$P(y|q) = \begin{cases} 1 - q, & y = 0 \\ q, & y = 1 \end{cases}$$

или

$$P(y|q) = (1 - q)^{1-y} \cdot q^y$$

- Модель должна предсказывать параметр q
- Параметр q может лежать только в интервале $[0, 1]$
- Мы должны пропустить выход сети через логистическую сигмоиду:

$$\text{sig}[z] = \frac{1}{1 + \exp[-z]}$$

- Мы предсказываем $q = \text{sig}[f[x, \phi]]$

- Правдоподобие имеет вид:

$$P(y|x) = (1 - \text{sig}[f[x, \phi]])^{1-y} \cdot \text{sig}[f[x, \phi]]^y$$

- Функция потерь:

$$L[\phi] = \sum_{i=1}^I -(1 - y_i) \ln (1 - \text{sig}[f[x_i, \phi]]) - y_i \ln \text{sig}[f[x_i, \phi]]$$

- Эта функция также является перекрёстной энтропией
- Для вывода можно положить $y = 1$, когда $q > 0.5$ и $y = 0$ в противном случае

Мультиклассовая классификация

- Задача мультиклассовой классификации — распределение входных данных по K классам:
 $y \in \{1, 2, \dots, K\}$
- Выберем категориальное распределение с параметрами $q_1, q_2, \dots, q_K$
- Предсказания сети должны лежать в интервале $[0, 1]$, а их сумма должна быть равна единице
- Для обеспечения этого пропустим выходы сети через функцию

$$\text{softmax}_k[z] = \frac{\exp[z_k]}{\sum_{j=1}^K \exp[z_j]}$$

- Правдоподобие для этой сети:

$$P(y = k|x) = \text{softmax}_k[f[x, \phi]]$$

- Функция потерь:

$$\begin{aligned} L[\phi] &= - \sum_{i=1}^I \ln \text{softmax}_{y_i}[f[x, \phi]] = \\ &= - \sum_{i=1}^I \left(f_{y_i}[x_i, \phi] - \ln \sum_{j=1}^K \exp[f_j[x_i, \phi]] \right) \end{aligned}$$

- Эта функция также является перекрёстной энтропией
- Для обратного вывода нужно выбрать наиболее вероятную категорию

Принципы выбора распределений

Тип данных	Распределение	Применение
Одномерные, непрерывные, неограничен- ные	Одномерное нормальное	Регрессия
Многомерные, непрерывные, неограничен- ные	Многомерное нормальное	Многомерная регрессия
Одномерные, непрерывные, неограничен- ные	Лапласа или Стьюдента	Робастная ре- грессия

Принципы выбора распределений

Тип данных	Распределение	Применение
Одномерные, непрерывные, неограничен- ные	Гауссова смесь	Мультимодаль- ная регрессия
Одномерные, непрерывные, ограниченные снизу	Экспоненциаль- ное, Эрланга, χ^2 (Гамма)	Предсказание отрезков
Одномерные, непрерывные, ограниченные	Бета	Предсказание соотношений

Принципы выбора распределений

Тип данных	Распределение	Применение
Одномерные, непрерывные, периодические	фон Мизеса	Предсказание направлений
Одномерные, двоичные	Бернулли	Двоичная клас- сификация
Одномерные дискретные, ограниченные	Категориальное	Мультиклассо- вая классифи- кация

Принципы выбора распределений

Тип данных	Распределение	Применение
Одномерные, дискретные, ограниченные снизу	Пуассона	Предсказание количества
Многомерное, дискретное, перестановка	Плакетта-Люса	Ранжирование

Сети с многими выходами

- Большинство реальных сетей имеют множество выходов
- Проще всего считать каждое предсказание независимым:

$$P(y|f[x, \phi]) = \prod_d P(y_d|f_d[x\phi])$$

- Функция потерь будет иметь вид:

$$L[\phi] = - \sum_{i=1}^I \sum_d \ln P(y_{id}|f_d[x_i, \phi])$$

Перекрёстная энтропия

- Альтернативой максимизации правдоподобия может быть минимизация перекрёстной энтропии
- Идея метода состоит в выборе таких параметров θ , которые минимизируют расстояние между наблюдаемым $q(y)$ и предсказываемым распределением $P(y|\theta)$
- Это расстояние можно измерить как расхождение Кульбака-Лейблера:

$$D_{KL}[q||p] = \int_{-\infty}^{\infty} q(z) \ln \frac{q(z)}{p(z)} dz$$

- Обычно наблюдаемое распределение сосредоточено в отдельных точках:

$$q(y) = \frac{1}{I} \sum_{i=1}^I \delta(y - y_i)$$

- Минимизируем расхождение Кульбака-Лейблера для наших распределений:

$$\begin{aligned} \hat{\theta} &= \operatorname{argmin}_{\theta} \left(\int_{-\infty}^{\infty} q(z) \ln q(z) dz - \int_{-\infty}^{\infty} q(z) \ln P(y|\theta) dy \right) = \\ &= \operatorname{argmin}_{\theta} - \int_{-\infty}^{\infty} q(y) \ln P(y|\theta) dy \end{aligned}$$

- Оставшееся слагаемое называется перекрёстной энтропией
- Она показывает уровень неопределённости, который остаётся, когда принимаем во внимание известные данные
- Получим:

$$\begin{aligned}
 \hat{\theta} &= \operatorname{argmin}_{\theta} \left[- \int_{-\infty}^{\infty} \left(\frac{1}{I} \sum_{i=1}^I \delta(y - y_i) \ln P(y|\theta) dy \right) \right] = \\
 &= \operatorname{argmin}_{\theta} \left[-\frac{1}{I} \sum_{i=1}^I \ln P(y_i|\theta) \right] = \\
 &= \operatorname{argmin}_{\theta} - \sum_{i=1}^I \ln P(y_i|\theta)
 \end{aligned}$$

- Критерии минимальной перекрёстной энтропии и максимального правдоподобия эквивалентны

Нестатистические функции потерь

- В настоящее время большинство функций потерь выбираются рассмотренным способом
- Тем не менее, функция потерь необязательно должна быть обоснована статистически
- Подходят любые функции так или иначе показывающие расхождение между обучающими и предсказываемыми значениями
- Примеры: шарнирные потери (hinge loss), экспоненциальные потери (в AdaBoost)

О лекциях

- Материал лицензирован под [CC BY SA 4.0](#)
- Правки и предложения приветствуются в виде пулл-реквестов по адресу <https://codeberg.org/fmjr/muctr>