Нейронные сети глубокого обучения
Трансформеры. Самовнимание

Лекция 5
22 марта 2025 г.

Сукин Иван Андреевич
РХТУ им. Д.И. Менделеева
sukin.i.a@muctr.ru

Мотивация

- Свёрточные сети отлично подходят для обработки данных, лежащих на регулярной сетке
- Такими данными могут быть изображения или звук
- Данные для свёрточных сетей представляют огромное количество входных переменных, что затрудняет использование полносвязных сетей
- Каждый свёрточный слой эксплуатирует сходство между ближайшими элементами данных

- Обработка текстовых данных сопряжена с рядом трудностей
- Количество входных переменных также велико
- Для каждого элемента смысл может не зависеть от позиции: не нужно заново изучать слово «собака», когда оно снова встречается в тексте
- Текстовые последовательности различаются длиной и нет простого способа их масштабировать

- В качестве примера рассмотрим отзыв на кафе: «Ресторан оставил приятные впечатления! Вкусная еда, уютная атмосфера и вежливый персонал. Обслуживание быстрое, блюда подают горячими и красиво оформленными. Отличное место, чтобы хорошо провести время. Рекомендую!»
- Мы можем хотеть узнать, положительный этот отзыв или отрицательный, или получить ответы на вопросы типа «есть ли в этом кафе мороженое?»

- Размер входных данных может быть большим: каждое из 26 слов может быть закодировано эмбеддингом (вектором вложения) длиной 1024
- Каждый обучающий пример может (и будет) иметь различную длину. Сеть должна иметь возможность иметь общие параметры для разных участков входных данных
- Язык многозначен, может содержать анафоры и т.д.
  - «К женщине подошёл мужчина с собачкой. Он взял её на руки» — к какому слову относится местоимение «её»?

Самовнимание, основанное на скалярном произведении

- Нам необходимы механизм, чтобы
  - Использовать общие параметры для работы с длинными входными векторами переменной длины
  - Создавать связи между представлениями слов, зависящие от самих слов
- Такой механизм называется «самовниманием» (self-attention)
- Пусть обычный слой нейронной сети $f(x)$ принимает на вход вектор-столбец x длины D и вычисляет следующую функцию:

$$f(x) = \mathsf{relu}(\beta + \Omega x)$$

- Блок самовнимания принимает N входных векторов-столбцов длины D и возвращает N векторов-столбцов длины D
- В контексте обработки языка каждый вектор-столбец представляет собой слово или фрагмент слова
- Вычисляются «значения» v_m для всех $1 \leqslant m \leqslant N$:

$$v_m = \beta_v + \Omega_v x_m$$

- n-ый компонент самовнимания:

$$\mathsf{sa}_n(x_1, \ldots, x_N) = \sum_{m=1}^{N} a(x_m, x_n) v_m$$

- Скалярные веса $a(x_m, x_n)$ называются вниманием, которое n-ый выход уделяет m-ому входу
- Верно, что:

$$\sum_{m=1}^{N} a(x_m, x_n) = 1, \quad a(x_m, x_n) \geqslant 0$$

- Самовнимание можно рассматривать как смешивание входных данных в различных пропорциях

- Для каждого входного вектора используются одни и те же веса Ω_ν и смещения β_ν
- Объём вычислений растёт линейно с увеличением длины входной последовательности N
- Количество весов внимания растёт квадратично с ростом N

- Вычисление самовнимания — нелинейная операция
- Это пример гиперсети, одна часть которой вычисляет параметры другой
- Вычислим «запросы» и «ключи»:

$$q_n = \beta_q + \Omega_q x_n, \quad k_m = \beta_k + \Omega_k x_m$$

- Чтобы вычислить матрицу внимания, нужно пропустить скалярные произведения ключей и запросов через softmax:

$$a(x_m, x_n) = \mathsf{softmax}_m(k^T q_n) = \frac{e^{k_m^T q_n}}{\sum_{j=1}^{N} e^{k_j^T q_n}}$$

- Термины «запросы» и «ключи» происходят из области информационного поиска
- Скалярное произведение служит мерой сходства между входами
- Использование функции softmax означает, что векторы «соревнуются» друг с другом за долю в итоговом результате
- Запросы и ключи должны иметь одинаковые размерности (но они могут отличаться от размерности значений)
- Параметрами сети являются β_v, Ω_v, β_q, Ω_q, β_k, Ω_k

Матричная форма

- Пусть входные данные упорядочены в виде матрицы X размера $D \times N$
- Тогда:

$$V(X) = \beta_o \otimes 1 + \Omega_v X$$
$$Q(X) = \beta_q \otimes 1 + \Omega_q X$$
$$K(X) = \beta_k \otimes 1 + \Omega_k X$$
$$Sa(X) = V(X) \cdot \mathsf{softmax}(K^T Q)$$

О лекциях

- Материал лицензирован под CC BY SA 4.0
- Правки и предложения приветствуются в виде пулл-реквестов по адресу https://codeberg.org/fmjr/muctr