Нейронные сети глубокого обучения
Слои трансформеров

Лекция 6
28 марта 2025 г.

Сукин Иван Андреевич
РХТУ им. Д.И. Менделеева
sukin.i.a@muctr.ru

Позиционное кодирование

- Механизм самовнимания не принимает в расчёт информацию о порядке векторов x_n
- В естественных языках порядок слов важен
- Для позиционного кодирования к входной матрице X добавляется матрица Π с данными о позициях
- Матрица Π может быть задана и получена в процессе обучения

Относительное позиционное кодирование

- Входом блока самовнимания могут быть целое предложение, несколько предложений или фрагмент предложения
- В этом случае абсолютная позиция слова не имеет такого значения, как относительное положение слов
- В этом случае параметрами обучения могут быть числа $\pi_{a,b}$, которые прибавляются или умножаются на элементы матрицы внимания и отражают влияние относительных позиций слов

Масштабирование самовнимания

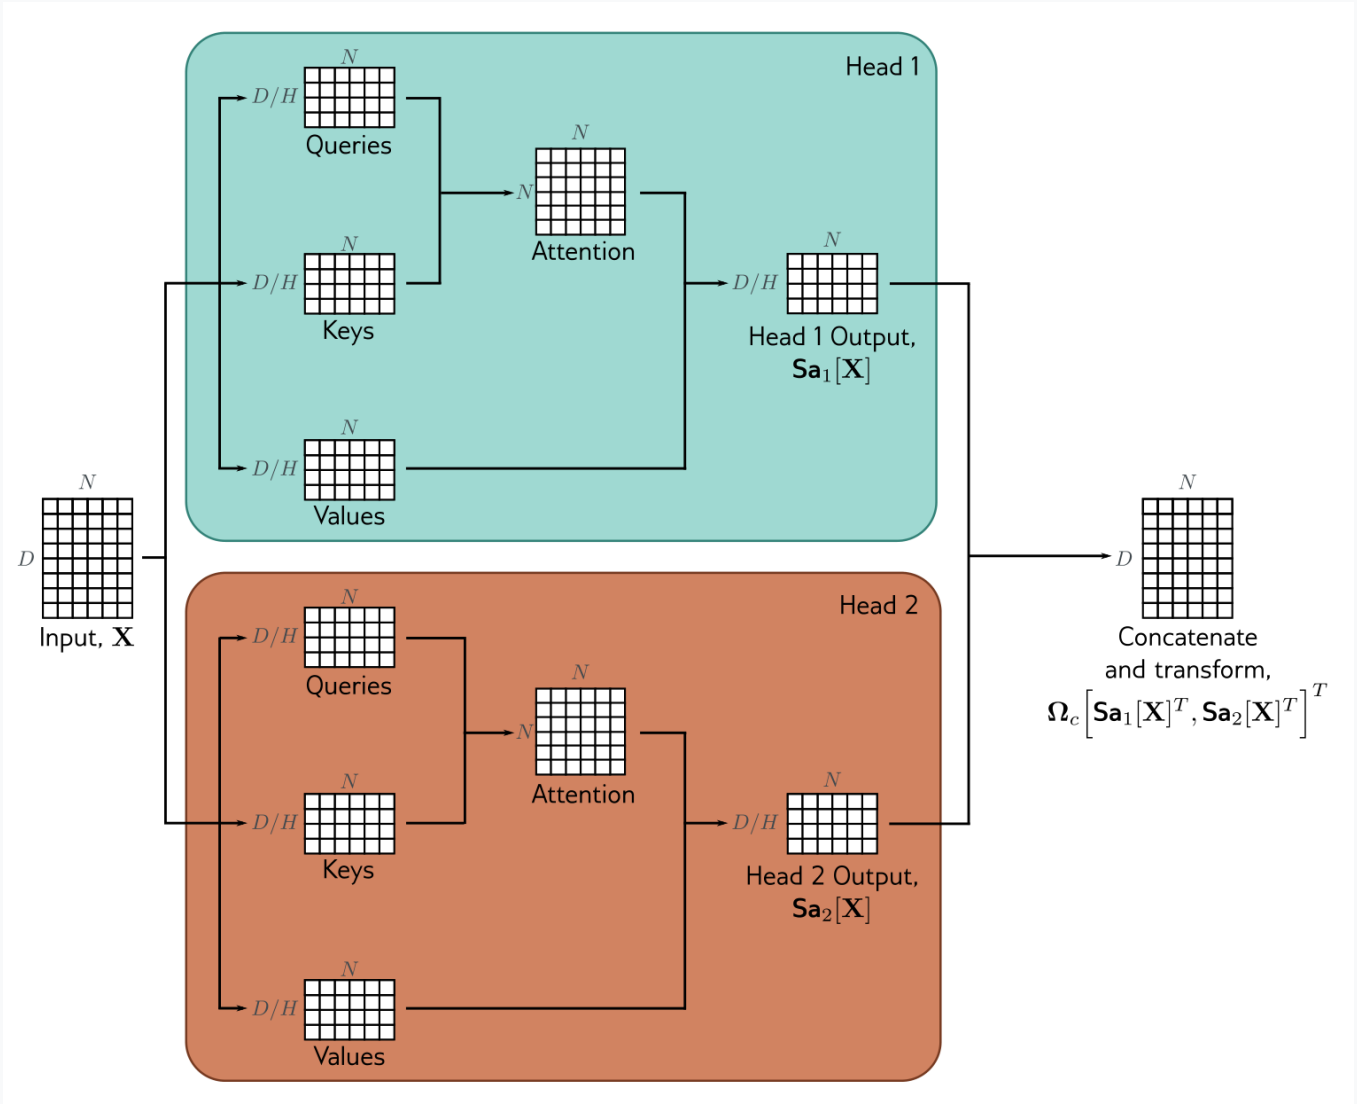
- Вычисление матрицы самовнимания может приводить к малым значениям градиентов и малой скорости обучения
- Чтобы исправить эту проблему, нужно масштабировать вычисление матрицы самовнимания:

$$\mathsf{Sa}(X) = V \cdot \mathsf{softmax}\left(\frac{K^T Q}{\sqrt{D_q}}\right)$$

Многозначное самовнимание

- Зачастую матрица самовнимания может вычисляться блочным образом
- Если есть h блоков:

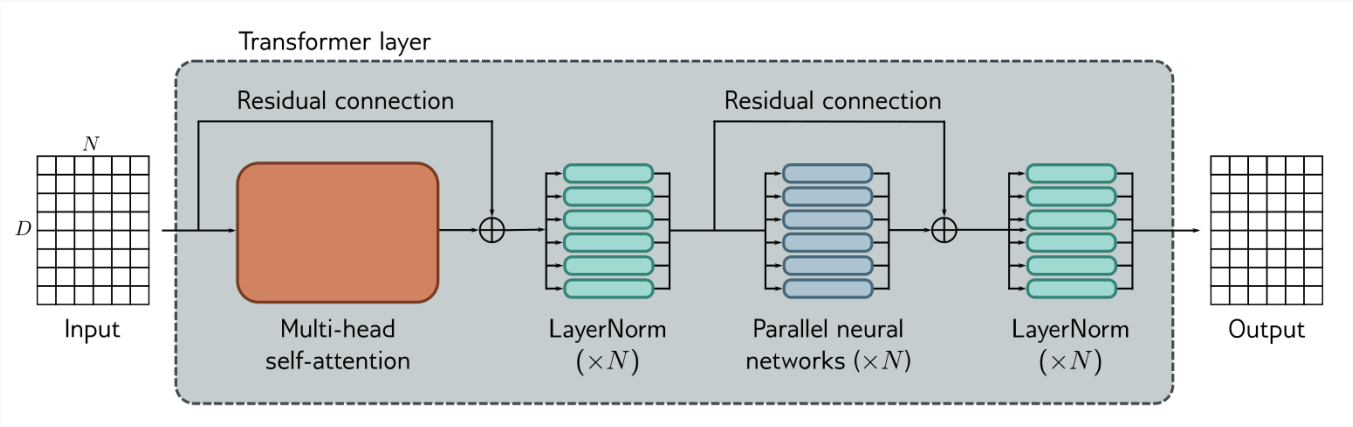
$$
\begin{aligned}
V_h &= \beta_{vh} \otimes 1 + \Omega_{vh} X \\
Q_h &= \beta_{qh} \otimes 1 + \Omega_{qh} X \\
K_h &= \beta_{kh} \otimes 1 + \Omega_{kh} X \\
\mathsf{Sa}(X) &= V_h \cdot \mathsf{softmax}\left(\frac{K_h^T Q_h}{\sqrt{D_q}}\right) \\
\mathsf{MhSa}(X) &= \Omega_c \left[\mathsf{Sa}_1(X)^T, \ldots, \mathsf{Sa}_H(X)^T\right]^T
\end{aligned}
$$


Head 1
N
D/H
Queries
N
N
Attention
N
D/H
Keys
N
D/H
Head 1 Output,
$\mathbf{Sa}_1[\mathbf{X}]$
N
D/H
Values
N
D
Input, $\mathbf{X}$
Head 2
N
D/H
Queries
N
N
Attention
N
D/H
Keys
N
D/H
Head 2 Output,
$\mathbf{Sa}_2[\mathbf{X}]$
N
D/H
Values
N
D
Concatenate
and transform,
$\mathbf{\Omega}_c\left[\mathbf{Sa}_1[\mathbf{X}]^T, \mathbf{Sa}_2[\mathbf{X}]^T\right]^T$

Слои трансформеров

- Блок самовнимания является лишь частью более обширного слоя трансформера
- Слой трансформера:

$$
\begin{aligned}
X &= X + \mathsf{MhSa}(X) \\
X &= \mathsf{LayerNorm}(X) \\
x_n &= x_n + \mathsf{mlp}(x_n) \\
X &= \mathsf{LayerNorm}(X)
\end{aligned}
$$


Transformer layer
Residual connection
Residual connection
N
D
Input
Multi-head
self-attention
LayerNorm
(×N)
Parallel neural
networks (×N)
LayerNorm
(×N)
Output

О лекциях

- Материал лицензирован под CC BY SA 4.0
- Правки и предложения приветствуются в виде пулл-реквестов по адресу https://codeberg.org/fmjr/muctr