Нейронные сети глубокого обучения
Кодировщики и декодировщики

Лекция 7
5 апреля 2025 г.

Сукин Иван Андреевич
РХТУ им. Д.И. Менделеева
sukin.i.a@muctr.ru

Токенизация

- Для обработки текстов они должны быть преобразованы в векторную форму
- Этот процесс называется токенизацией
- Текст разбивается на токены, входящие в словарь возможных токенов
  - Некоторые слова (например, имена) не входят в словарь
  - Не совсем ясно, как обрабатывать пунктуацию, но это важно
  - В словаре должны содержаться различные токены для различных форм одного и того же слова

- Можно разбивать текст на достаточно малые токены, чтобы учесть пунктуацию
- После этого сети придётся научиться узнавать связи между токенами
- На практике словарь состоит из часто встречающихся слов и частей слов
- Словарь создаётся с помощью токенизатора

- Рассмотрим пример (для простоты исключим пунктуацию и заглавные буквы, а символы перевода строки и пробелы обозначим как «_»):

  мороз и солнце день чудесный
  еще ты дремлешь друг прелестный
  пора красавица проснись
  открой сомкнуты негой взоры
  навстречу северной авроры
  звездою севера явись

На первом этапе посчитаем частоты:

_	е	р	о	с	н	в	а	ы	т	й	д	ь	у	и	з	п	м	л	к	ч	ц	г	я	ю	щ	ш
22	16	14	13	11	9	8	7	6	5	5	5	4	4	4	4	3	3	3	3	2	2	2	1	1	1	1

На втором этапе объединяем самую часто встречающуюся пару токенов, у нас это «й_»:

_	е	р	о	с	н	в	а	ы	т	й_	д	ь	у	и	з	п	м	л	к	ч	ц	г	я	ю	щ	ш
17	16	14	13	11	9	8	7	6	5	5	5	4	4	4	4	3	3	3	3	2	2	2	1	1	1	1

На третьем этапе объединяем «о» и «р»:

_	е	с	р	о	н	в	а	ы	т	й_	д	ор	ь	у	и	з	п	м	л	к	ч	ц	г	я	ю	щ	ш
17	16	11	10	9	9	8	7	6	5	5	5	4	4	4	4	4	3	3	3	3	2	2	2	1	1	1	1

Продолжая итерации, получим словарь, заполненный токенами и их частотами

Алгоритм описан в статье Sennrich R., Haddow B., Birch A. Neural Machine Translation of Rare Words with Subword Units, 2015, arXiv:1508.07909

Эмбеддинги

- Каждый токен в словаре отображается на уникальный эмбеддинг
- Все эмбеддинги для словаря сохраняются в матрице Ω_e размера $D \times |V|$
- N входных токенов закодированы в матрице T размера $|V| \times N$, где в каждом столбце единица стоит только в одной строке
- Эмбеддинги для входныз данных вычисляются как $X = \Omega_e T$
- Матрица Ω_e является параметром сети
- Типичные значения $D = 1024$, $|V| = 30000$

Модель трансформеров

- Итоговая матрица X пропускается через последовательность из K слоёв трансформеров
- Существуют три типа моделей трансформеров:
  - Кодировщики преобразуют эмбеддинги в некоторое представление
  - Декодировщики предсказывают следующий токен в тексте
  - Кодировщики-декодировщики преобразуют один текст в другой

Кодировщик — BERT

- Модель BERT использует словарь на 30000 токенов с эмбеддингами длины 1025
- Сеть состоит из 24 слоёв трансформеров, в каждом из которых есть 16-значный блок самовнимания (матрицы Ω_{vh}, Ω_{qh}, Ω_{kh} имеют размеры 64×1024)
- Каждая сеть прямого распространения имеет один скрытый слой из 4096 нейронов
- Суммарное количество параметров примерно 340 миллионов
- По современным меркам это небольшая модель

- Кодировщики зачастую используют трансферное обучение
- На этапе предобучения параметры модели устанавливаются с помощью самообучения на большом корпусе текстов
- Цель предобучения — получение общей информации о статистике языка
- На этапе тонкой настройки модель учится решать более конкретную задачу

Предобучение

- Модели типа BERT на этапе предобучения учатся предсказывать пропущенные слова в тексте
- Во время этого этапа максимальный размер входных данных — 512 токенов с размером пакета 256
- Модель обучается в течение миллиона шагов (примерно 50 эпох) на корпусе из 3.3 миллиарда слов
- На этапе предобучения модель получает некоторое представление о синтаксисе

На этапе тонкой настройки кодировщик учится решать задачи вида:

- Классификация текста, определение тона текста, его общих характеристик. Результат — число от 0 до 1
- Классификация слов, определение типа каждого слова. Каждый входной эмбеддинг отображается на вектор, в котором единственная единица соответствует определённому классу
- Предсказание отрывков текста. Кодировщику передается вопрос и некоторый текст, при этом кодировщик должен указать отрывок в тексте, где содержится ответ на вопрос. Каждому токену сопоставляются два числа: «вероятности» того, что отрывок закончится или начнётся в этом месте. Эти два набора чисел пропускаются через softmax

Декодировщик — GPT

- Архитектура декодировщика похожа на архитектуру кодировщика
- Декодировщик решает другую задачу — генерация следующего токена
- Передавая результат на вход модели, можно получать осмысленный текст
- GPT — языковая модель с авторегрессией

Авторегрессия

$$
\begin{aligned}
&P(\text{мороз и солнце день чудесный}) = \\
&= P(\text{мороз}) \times P(\text{и}|\text{мороз}) \times \\
&\times P(\text{солнце}|\text{мороз и} \times P(\text{день}|\text{мороз и солнце}) \times \\
&\times P(\text{чудесный}|\text{мороз и солнце день})
\end{aligned}
$$

Авторегрессионная модель предсказывает условные распределения вероятностей $P(t_n|t_1, \ldots, t_{n-1})$

Замаскированное самовнимание

- Для обучения декодировщика мы подбираем веса, максимизирующие логарифм вероятности входного текста в авторегрессионной модели
- Однако, если мы будем передавать на вход весь текст, который модель должна предсказать, она может «схитрить», поскольку будет иметь полный контекст
- Токены взаимодействуют только в блоке самовнимания
- Чтобы сеть «не знала» о существовании продолжения текста, нужно в блоке самовнимания установить внимание для правых токенов в минус бесконечность
- Такой механизм называется замаскированным самовниманием

Кодировщики-декодировщики — машинный перевод

- Задача машинного перевода — проблема преобразования текста в текст
- Один из основных подходов — использование кодировщика-декодировщика
- Помимо последовательного соединения кодировщика и декодировщика используется механизм перекрёстного самовнимания в декодировщике:
  - Изначально трансформеры декодировщика состоят из блока замаскированного самовнимания и последующего многослойного перцептрона
  - В новой модели между этими двумя блоками вставляется ещё один блок самовнимания, запросы которого вычисляются с использованием X декодировщика, а ключи и значения — с использованием X кодировщика

О лекциях

- Материал лицензирован под CC BY SA 4.0
- Правки и предложения приветствуются в виде пулл-реквестов по адресу https://codeberg.org/fmjr/muctr